TUGAS AKHIR - SM234801

PENERAPAN KOMBINASI METODE RESNET DAN BI-GRU UNTUK KLASIFIKASI GENRE MUSIK BERBASIS FUSI CITRA *SCALOGRAM-SPECTROGRAM*

ANGELA ADYTHA PUTRI
NRP 5002211131

Dosen Pembimbing
Dr. Dwi Ratna Sulistyaningrum, S.Si, MT
NIP 19690405 199403 2 003

Program Studi Sarjana
Departemen Matematika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember
Surabaya

TUGAS AKHIR - SM234801

PENERAPAN KOMBINASI METODE RESNET DAN BI-GRU UNTUK KLASIFIKASI GENRE MUSIK BERBASIS FUSI CITRA *SCALOGRAM-SPECTROGRAM*

ANGELA ADYTHA PUTRI

NRP 5002211131

Dosen Pembimbing

Dr. Dwi Ratna Sulistyaningrum, S.Si, MT

NIP 19690405 199403 2 003

Program Sarjana

Departemen Matematika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2026

FINAL PROJECT - SM234801

APPLICATION OF A COMBINATION OF RESNET AND BI-GRU METHODS FOR SCALOGRAM-SPECTROGRAM IMAGE FUSION-BASED MUSIC GENRE CLASSIFICATION

ANGELA ADYTHA PUTRI

NRP 5002211131

Supervisors

Dr. Dwi Ratna Sulistyaningrum, S.Si, MT

NIP 19690405 199403 2 003

Bachelor Program

Departement of Mathematics

Faculty of Scientics

Institut Teknologi Sepuluh Nopember

Surabaya

2026

LEMBAR PENGESAHAN

PENERAPAN KOMBINASI METODE RESNET DAN BI-GRU UNTUK KLASIFIKASI GENRE MUSIK BERBASIS FUSI CITRA *SCALOGRAM-SPECTROGRAM*

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Matematika pada
Program Studi S-1 Matematika
Departemen Matematika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember

Oleh: **ANGELA ADYTHA PUTRI**
NRP. 5002211131

Surabaya, Januari 2026
Disetujui oleh Tim Penguji Tugas Akhir:

Pembimbing

1. Dr. Dwi Ratna Sulistyaningrum, S.Si, MT
   NIP. 19690405 199403 2 003 (.....)

Penguji

1. Dr. Drs. Bandung Arry S., MI.Komp
   NIP. 19630605 198903 1 003 (.....)
2. Dr. Budi Setiyono, S.Si, MT
   NIP. 19720207 199702 1 001 (.....)
3. Alvida Mustika Rukmi, S.Si, M.Si
   NIP. 19720715 199802 2 001 (.....)

Mengetahui,
Kepala Departemen Matematika
Fakultas Sains dan Analitika Data

Dr. Didik Khusnul Arif, S.Si, M.Si
NIP. 19730930 199702 1 001

Dipindai dengan CamScanner

PERNYATAAN ORISINALITAS

Yang bertanda tangan di sini:

Nama Mahasiswa / NRP	:	Angela Adytha Putri / 5002211131
Departemen	:	Matematika
Dosen Pembimbing	:	Dr. Dwi Ratna Sulistyaningrum, S.Si, MT

dengan ini menyatakan bahwa Tugas Akhir dengan judul "**PENERAPAN KOMBINASI METODE RESNET DAN BI-GRU UNTUK KLASIFIKASI GENRE MUSIK BERBASIS FUSI CITRA *SCALOGRAM-SPECTROGRAM***" adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Surabaya, 21 Januari 2026

Mengetahui
Dosen Pembimbing

Dr. Dwi Ratna Sulistyaningrum, S.Si, MT
NIP. 19690405 199403 2 003

Mahasiswa



Angela Adytha Putri
NRP. 5002211131

Dipindai dengan CamScanner

ABSTRAK

PENERAPAN KOMBINASI METODE RESNET DAN BI-GRU UNTUK KLASIFIKASI GENRE MUSIK BERBASIS FUSI CITRA *SCALOGRAM-SPECTROGRAM*

Nama Mahasiswa / NRP	:	Angela Adytha Putri / 5002211131
Departemen	:	Matematika FSAD - ITS
Dosen Pembimbing	:	Dr. Dwi Ratna Sulistyaningrum, S.Si, MT

Abstrak

Musik memiliki berbagai macam genre yang berperan penting dalam pengelompokkan dan sistem rekomendasi lagu. Klasifikasi genre musik menjadi salah satu permasalahan dalam bidang pengolahan sinyal audio karena karakteristik sinyal yang kompleks dan bervariasi. Penelitian ini mengusulkan metode klasifikasi genre musik dengan memanfaatkan kombinasi arsitektur *Residual Network* (ResNet) dan *Bidirectional Gated Recurrent Unit* (Bi-GRU) menggunakan representasi citra sinyal audio. Sinyal audio pada dataset GTZAN diubah menjadi citra skalogram menggunakan *Continuous Wavelet Transform* (CWT) dan citra spektrogram menggunakan *Short-Time Fourier Transform* (STFT). Citra yang dihasilkan selanjutnya dipotong menjadi 10 bagian dan difusikan dengan menggunakan skalogram sebagai lapisan R, spektrogram sebagai lapisan G, serta hasil penggabungan keduanya menggunakan operasi aritmatika dan fungsi agregasi sebagai lapisan B. Citra hasil fusi digunakan sebagai *input* pada model ResNet-BiGRU. Model ResNet-BiGRU dimodifikasi dengan penambahan lapisan *Adaptive Max Pooling*, *Batch Normalization*, dan *Dropout* setelah proses ekstraksi fitur oleh ResNet. Hasil pengujian menunjukkan bahwa skenario fusi *weighted average* dengan nilai parameter $\alpha = 0.5$ memberikan performa terbaik dengan akurasi validasi sebesar 96.19%.

Kata kunci: *Fusi, Genre Musik, Klasifikasi, Skalogram, Spektrogram*

ABSTRACT

APPLICATION OF A COMBINATION OF RESNET AND BI-GRU METHODS FOR SCALOGRAM-SPECTROGRAM IMAGE FUSION-BASED MUSIC GENRE CLASSIFICATION

Student Name / NRP	:	Angela Adytha Putri / 5002211131
Departement	:	Mathematics SCIENTICS - ITS
Advisor	:	Dr. Dwi Ratna Sulistyaningrum, S.Si, MT

Abstract

Music has various genres that play an important role in music grouping and song recommendation system. Music genre classification is one of the challenges in the field of audio signal processing due to the complex and diverse characteristics of audio signals. This research proposes a music genre classification method by utilizing a combination of Residual Network (ResNet) and Bidirectional Gated Recurrent Unit (Bi-GRU) architectures using audio signal image representations. The audio signals from the GTZAN dataset are transformed into scalogram images using Continuous Wavelet Transform (CWT) and spectrogram images using Short-Time Fourier Transform (STFT). The resulting images are then segmented into 10 parts and fused by assigning the scalogram as the R channel, the spectrogram as the G channel, and the combination of both using arithmetic operations and aggregation functions as the B channel. The fused images are used as an input to the ResNet-BiGRU model. The ResNet-BiGRU model is modified by adding Adaptive Max Pooling, Batch Normalization, and Dropout layers after the feature extraction process performed by ResNet. Experimental results show that the weighted average fusion scenario with a parameter value of $\alpha = 0.5$ achieves the best performance, with a validation accuracy of 96.19%.

Keywords: *Classification, Fusion, Music Genre, Scalogram, Spectrogram*

KATA PENGANTAR

Puji syukur kepada Allah Yang Maha Esa karena atas rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul:

"PENERAPAN KOMBINASI METODE RESNET DAN BI-GRU UNTUK KLASIFIKASI GENRE MUSIK BERBASIS FUSI CITRA *SCALOGRAM-SPECTROGRAM*"

sebagai salah satu persyaratan akademis dalam menyelesaikan Program Sarjana Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember Surabaya. Tugas Akhir ini dapat diselesaikan dengan baik berkat kerja sama, bantuan, dan dukungan dari banyak pihak. Sehubungan dengan hal itu, penulis ingin mengucapkan terima kasih dan penghargaan kepada:

1. Kedua orang tua tercinta atas doa, kasih sayang, dukungan moral, dan semangat yang tiada henti dalam setiap langkah perjalanan pendidikan penulis.
2. Bapak Dr. Didik Khusnul Arif, S.Si, M.Si selaku Kepala Departemen Matematika Institut Teknologi Sepuluh Nopember di periode saat Tugas Akhir ini disusun.
3. Ibu Dr. Dwi Ratna Sulistyaningrum, S.Si, MT selaku dosen pembimbing Tugas Akhir penulis yang telah dengan sabar memberikan bimbingan, arahan, serta masukan yang sangat berarti selama proses penyusunan Tugas Akhir ini.
4. Bapak Dr. Drs. Bandung Arry S., MI.Komp, Bapak Dr. Budi Setiyono, S.Si, MT, dan Ibu Alvida Mustika Rukmi, S.Si, M.Si selaku dosen penguji yang telah memberikan banyak kritik dan saran yang membangun untuk membantu penyelesaian Tugas Akhir ini.
5. Ibu Soleha, S.Si, M.Si selaku dosen wali yang telah mendampingi, mendukung, dan memberikan arahan kepada penulis selama masa perkuliahan.
6. Bapak/Ibu dosen pengajar yang tidak dapat penulis sebutkan satu per satu, yang telah mendedikasikan diri memberikan pengajaran dan pengalaman yang bermanfaat kepada penulis, serta segenap Karyawan, Tendik dan keluarga besar Departemen Matematika Institut Teknologi Sepuluh Nopember atas dukungan dan bantuannya.

Penulis menyadari bahwa Tugas Akhir ini masih jauh dari kesempurnaan. Oleh karena itu, penulis mengharapkan saran dan kritik dari pembaca. Akhir kata, semoga Tugas Akhir ini bermanfaat bagi semua pihak yang berkepentingan.

Surabaya, 29 Desember 2025

Angela Adytha Putri

Dipindai dengan CamScanner

DAFTAR ISI

LEMBAR PENGESAHAN ii

PERNYATAAN ORISINALITAS iii

ABSTRAK v

ABSTRACT vii

KATA PENGANTAR ix

DAFTAR ISI xi

DAFTAR GAMBAR xv

DAFTAR TABEL xvii

BAB I PENDAHULUAN 1
- 1.1 Latar Belakang . . . 1
- 1.2 Rumusan Masalah . . . 2
- 1.3 Batasan Masalah . . . 2
- 1.4 Tujuan . . . 2
- 1.5 Manfaat . . . 2

BAB II TINJAUAN PUSTAKA 3
- 2.1 Penelitian Terdahulu . . . 3
- 2.2 Klasifikasi Genre Musik . . . 4
- 2.3 Normalisasi Audio . . . 4
- 2.4 *Wavelet Transform* (WT) . . . 5
- 2.5 *Short-Time Fourier Transform* (STFT) . . . 7
- 2.6 Fusi Citra . . . 11
- 2.7 *Data Splitting* . . . 14
- 2.8 *Deep Learning* . . . 15
  - 2.8.1 *Neural Network* . . . 16
  - 2.8.2 *Convolutional Neural Network* (CNN) dan *Residual Network* (ResNet) . . . 21
  - 2.8.3 *Recurrent Neural Network* (RNN) dan *Bidirectional Recurrent Unit* (Bi-GRU) . . . 22
- 2.9 Resolusi Waktu dan Frekuensi Transfrormasi . . . 23
  - 2.9.1 Prinsip Ketidakpastian . . . 23
  - 2.9.2 Multi Resolusi . . . 24
- 2.10 *Confusion Matrix* dan Metrik Evaluasi . . . 25

BAB III METODOLOGI 29
- 3.1 Studi Literatur . . . 30
- 3.2 Pengumpulan Dataset . . . 30
- 3.3 Pembuatan Program . . . 30
  - 3.3.1 Normalisasi Audio . . . 30

3.3.2 Ekstraksi Fitur 30
3.3.3 *Cropping Image* 30
3.3.4 Fusi Citra 31
3.3.5 *Data Splitting* 31
3.3.6 Implementasi Kombinasi Model *Residual Network* (ResNet) dan *Bidirectional Gated Recurrent Unit* (Bi-GRU) 31
3.4 Pengujian dan Simulasi 32
3.5 Kesimpulan dan Saran 32
BAB IV PERANCANGAN DAN IMPLEMENTASI SISTEM 33
4.1 Pengambilan Data 33
4.2 Perancangan Program 34
4.2.1 Normalisasi Audio 34
4.2.2 Perancangan Tahap Esktraksi Fitur 35
4.2.3 Perancangan Tahap *Cropping Image* 43
4.2.4 Perancangan Tahap Fusi Citra 43
4.2.5 *Data Splitting* 49
4.2.6 Perancangan Model ResNet-BiGRU 51
4.2.7 Proses Perhitungan *Pooling Layer* dan *Batch Normalization* 52
4.2.8 Perhitungan *Loss* 53
4.3 Perancangan Hasil Klasifikasi 53
4.4 Implementasi Program 55
4.4.1 Implementasi Normalisasi Audio 55
4.4.2 Implementasi Ekstraksi Fitur 55
4.4.3 Implementasi *Cropping Image* 55
4.4.4 Implementasi Fusi Citra 56
4.4.5 Implementasi *Data Splitting* 57
4.4.6 Implementasi Model ResNet-BiGRU 58
4.4.7 Implementasi Pengujian Program 61
BAB V HASIL DAN PEMBAHASAN 63
5.1 Ekstraksi Fitur 63
5.2 Hasil Pelatihan Model 67
5.3 Evaluasi Kinerja Model 81
5.3.1 Dataset Sekunder 81
5.3.2 Dataset Primer 83
5.4 Pembahasan 87
BAB VI KESIMPULAN DAN SARAN 89
6.1 Kesimpulan 89
6.2 Saran 89
DAFTAR PUSTAKA 91
DAFTAR LAMPIRAN 97
Lampiran 1 Performansi Model 97
Lampiran 1.1 Akurasi Model dengan Modifikasi *Hyperparameter* 97
Lampiran 1.2 *Loss* Model dengan Modifikasi *Hyperparameter* 99
Lampiran 2 *Confusion Matrix* 103
Lampiran 2.1 *Confusion Matrix* Dataset Sekunder 103

Lampiran 2.2 *Confusion Matrix* Dataset Primer pada Menit 0:30-1:00 . 103
Lampiran 2.3 *Confusion Matrix* Dataset Primer pada Menit 1:00-1:30 . 104
Lampiran 2.4 *Confusion Matrix* Dataset Primer pada Menit 1:30-2:00 . 105
Lampiran 2.5 *Confusion Matrix* Dataset Primer pada Menit 2:00-2:30 . 106
Lampiran 2.6 *Confusion Matrix* Dataset Primer pada Menit 2:30-3:00 . 107
Lampiran 2.7 *Confusion Matrix* Dataset Primer pada Bagian *Reff* 108
Lampiran 3 Metrik Evaluasi 110
Lampiran 3.1 Metrik Evaluasi Dataset Sekunder 110
Lampiran 3.2 Metrik Evaluasi Dataset Primer pada Menit 0:30-1:00 . . 110
Lampiran 3.3 Metrik Evaluasi Dataset Primer pada Menit 1:00-1:30 . . 110
Lampiran 3.4 Metrik Evaluasi Dataset Primer pada Menit 1:30-2:00 . . 110
Lampiran 3.5 Metrik Evaluasi Dataset Primer pada Menit 2:00-2:30 . . 111
Lampiran 3.6 Metrik Evaluasi Dataset Primer pada Menit 2:30-3:00 . . 111
Lampiran 3.7 Metrik Evaluasi Dataset Primer pada Bagian *Reff* 111
Lampiran 4 Pengujian Menggunakan Dataset Primer 113
Lampiran 4.1 Klasifikasi Genre Musik pada Menit 0:30-1:00 113
Lampiran 4.2 Klasifikasi Genre Musik pada Menit 1:00-1:30 114
Lampiran 4.3 Klasifikasi Genre Musik pada Menit 1:30-2:00 115
Lampiran 4.4 Klasifikasi Genre Musik pada Menit 2:00-2:30 116
Lampiran 4.5 Klasifikasi Genre Musik pada Menit 2:30-3:00 118
Lampiran 4.6 Klasifikasi Genre Musik pada Bagian *Reff* 119
UCAPAN TERIMA KASIH 121
BIODATA PENULIS 123

DAFTAR GAMBAR

Gambar 2.1 Pengaruh Normalisasi 5
Gambar 2.2 Visualisasi *Scalogram* 7
Gambar 2.3 Grafik Hann *window* 8
Gambar 2.4 DFT mengubah sinyal dalam domain waktu menjadi domain frekuensi 9
Gambar 2.5 Representasi proses STFT 10
Gambar 2.6 Visualisasi *Spectrogram* 11
Gambar 2.7 Proses Fusi Citra: (a) *Grayscale Spectrogram* dan *Scalogram*, (b) Komponen RGB Fusi Citra, (c) Hasil Fusi Citra 12
Gambar 2.8 Ilustrasi *Data Splitting* 14
Gambar 2.9 Ilustrasi *Deep Learning* 15
Gambar 2.10 Contoh *Pooling Layer* 16
Gambar 2.11 *Dropout Layer* 17
Gambar 2.12 Grafik ReLU *Activation Function* 18
Gambar 2.13 Grafik Sigmoid *Activation Function* 19
Gambar 2.14 Grafik Tanh *Activation Function* 19
Gambar 2.15 Grafik Softmax *Activation Function* 20
Gambar 2.16 Arsitektur ResNet 22
Gambar 2.17 Arsitektur Bi-GRU 23
Gambar 2.18 Resolusi Waktu dan Frekuensi *Spectrogram* dan *Scalogram* 24
Gambar 2.19 *Confusion Matrix* 25
Gambar 2.20 *Confusion Matrix Multiclass* 26

Gambar 3.1 *Flowchart* Penelitian 29

Gambar 4.1 Contoh *Waveforms* Dataset GTZAN untuk Masing-Masing Genre 33
Gambar 4.2 Contoh *Waveforms* Dataset Primer untuk Masing-Masing Genre . . 34
Gambar 4.3 Contoh Citra *Scalogram* 38
Gambar 4.4 Contoh Citra *Spectrogram* 43
Gambar 4.5 Visualisasi *Cropping Image* 43
Gambar 4.6 Skenario Fusi dengan Fungsi *Maximum* 44
Gambar 4.7 Skenario Fusi dengan Fungsi *Minimum* 45
Gambar 4.8 Skenario Fusi dengan Fungsi *Average* 45
Gambar 4.9 Skenario Fusi dengan Fungsi *Addition* 46
Gambar 4.10 Skenario Fusi dengan Fungsi *Subtraction* 47
Gambar 4.11 Skenario Fusi dengan Fungsi *Multiplication* 47
Gambar 4.12 Skenario Fusi dengan Fungsi *Division* 48
Gambar 4.13 Skenario Fusi dengan Fungsi *Weighted Average* dengan $\alpha = 0.1$ . . . 49
Gambar 4.14 Arsitektur Model ResNet-BiGRU 51

Gambar 5.1 Contoh Citra *Scalogram* Masing-Masing Genre 63
Gambar 5.2 Contoh Citra *Spectrogram* Masing-Masing Genre 64

Gambar 5.3 Contoh Citra Fusi dengan Metode *Maximum* 64
Gambar 5.4 Contoh Citra Fusi dengan Metode *Minimum* 64
Gambar 5.5 Contoh Citra Fusi dengan Metode *Average* 65
Gambar 5.6 Contoh Citra Fusi dengan Metode *Addition* 65
Gambar 5.7 Contoh Citra Fusi dengan Metode *Subtraction* 65
Gambar 5.8 Contoh Citra Fusi dengan Metode *Multiplication* 66
Gambar 5.9 Contoh Citra Fusi menggunakan Metode *Division* 66
Gambar 5.10 Contoh Citra Fusi dengan Metode *Weighted Average* 66
Gambar 5.11 Grafik Akurasi Model Percobaan Ke-4 68
Gambar 5.12 Grafik *Loss* Model Percobaan Ke-4 69
Gambar 5.13 Grafik Akurasi Model dengan Metode Fusi *Maximum* 70
Gambar 5.14 Grafik *Loss* Model dengan Metode Fusi *Maximum* 70
Gambar 5.15 Grafik Akurasi Model dengan Metode Fusi *Minimum* 71
Gambar 5.16 Grafik *Loss* Model dengan Metode Fusi *Minimum* 71
Gambar 5.17 Grafik Akurasi Model dengan Metode Fusi *Average* 72
Gambar 5.18 Grafik *Loss* Model dengan Metode Fusi *Average* 72
Gambar 5.19 Grafik Akurasi Model dengan Metode Fusi *Addition* 73
Gambar 5.20 Grafik *Loss* Model dengan Metode Fusi *Addition* 73
Gambar 5.21 Grafik Akurasi Model dengan Metode Fusi *Subtraction* 74
Gambar 5.22 Grafik *Loss* Model dengan Metode Fusi *Subtraction* 74
Gambar 5.23 Grafik Akurasi Model dengan Metode Fusi *Multiplication* 75
Gambar 5.24 Grafik *Loss* Model dengan Metode Fusi *Multiplication* 75
Gambar 5.25 Grafik Akurasi Model dengan Metode Fusi *Division* 76
Gambar 5.26 Grafik *Loss* Model dengan Metode Fusi *Division* 76
Gambar 5.27 Grafik Akurasi Model dengan Metode Fusi *Weighted Average* 78
Gambar 5.28 Grafik *Loss* Model dengan Metode Fusi *Weighted Average* 78
Gambar 5.29 Grafik Akurasi Model Menggunakan *Group Shuffle Split* 79
Gambar 5.30 Grafik *Loss* Model Menggunakan *Group Shuffle Split* 79
Gambar 5.31 Grafik Akurasi Model Menggunakan *Average Pooling Layer* 80
Gambar 5.32 Grafik *Loss* Model Menggunakan *Average Pooling Layer* 81
Gambar 5.33 *Confusion Matrix* Dataset Sekunder dengan *Hyperparameter* Terbaik 82
Gambar 5.34 *Confusion Matrix* Dataset Primer dengan *Hyperparameter* Terbaik 84

DAFTAR TABEL

Tabel 2.1 Referensi Utama 3

Tabel 4.15 Skenario Fusi 49
Tabel 4.16 Jumlah Dataset 50
Tabel 4.17 *Hyperparameter* Model ResNet-BiGRU pada Penelitian Ini 52
Tabel 4.18 *Input Shape* dan *Output Shape* Setiap *Layer* 52

Tabel 5.1 Hasil Akurasi Model dengan Modifikasi *Hyperparameter* 67
Tabel 5.2 Hasil *Loss* Model dengan Modifikasi *Hyperparameter* 68
Tabel 5.3 Hasil Performansi dari Setiap Metode Fusi 69
Tabel 5.4 Hasil Performansi Model Menggunakan Metode Fusi *Maximum* 70
Tabel 5.5 Hasil Performansi Model Menggunakan Metode Fusi *Minimum* 71
Tabel 5.6 Hasil Performansi Model Menggunakan Metode Fusi *Average* 72
Tabel 5.7 Hasil Performansi Model Menggunakan Metode Fusi *Addition* 73
Tabel 5.8 Hasil Performansi Model Menggunakan Metode Fusi *Subtraction* . . . 74
Tabel 5.9 Hasil Performansi Model Menggunakan Metode Fusi *Multiplication* . 75
Tabel 5.10 Hasil Performansi Model Menggunakan Metode Fusi *Division* 76
Tabel 5.11 Hasil Performansi Model Menggunakan Metode Fusi *Weighted Average* 77
Tabel 5.12 Hasil Performansi Model Berdasarkan Metode *Split* 78
Tabel 5.13 Hasil Performansi Model dengan Modifikasi *Pooling Layer* 80
Tabel 5.14 Hasil Performansi Model 81
Tabel 5.15 Metrik Evaluasi Tiap Model 83
Tabel 5.16 Hasil Evaluasi Model Menggunakan *Input* Fitur yang Berbeda 83
Tabel 5.17 Hasil Klasifikasi Genre Musik Beberapa Dataset Primer 85
Tabel 5.18 Hasil Klasifikasi Genre Musik pada Bagian Lagu Berbeda 85
Tabel 5.19 Akurasi Pengujian pada Bagian Lagu Berbeda 87

BAB I
PENDAHULUAN

1.1 Latar Belakang

Salah satu komponen budaya yang memainkan peran penting dalam eksistensi manusia adalah musik. Konsumsi musik telah berevolusi dari format fisik ke format digital seiring dengan kemajuan teknologi, yang ditandai dengan kemunculan layanan *streaming* musik seperti *Spotify*, *Apple Music*, dan *YouTube Music* yang menyediakan jutaan lagu dari berbagai genre. Salah satu metode utama untuk membantu orang menemukan musik yang sesuai dengan selera mereka adalah dengan mengelompokkan musik berdasarkan genre (Fardhani et al., 2021).

Genre musik merupakan salah satu aspek penting dalam industri musik yang digunakan untuk mengklasifikasikan dan merekomendasikan lagu kepada pendengar. Dengan semakin berkembangnya jumlah koleksi musik digital, kebutuhan akan sistem klasifikasi otomatis yang akurat menjadi semakin krusial. Klasifikasi genre musik tidak hanya berguna dalam sistem rekomendasi musik, tetapi juga dalam analisis musikologi, pemfilteran konten, dan aplikasi pencarian berbasis audio. Sistem klasifikasi yang efisien dapat membantu pengguna menemukan musik yang sesuai dengan preferensi mereka dengan lebih mudah, serta memungkinkan industri musik untuk mengoptimalkan strategi pemasaran dan distribusi kontennya.

Salah satu teknik yang umum digunakan dalam *deep learning* untuk klasifikasi genre musik adalah transformasi sinyal audio menjadi representasi citra, seperti *spectrogram*. *Spectrogram* merupakan representasi visual dari spektrum frekuensi suatu sinyal audio yang dihasilkan melalui *Short-Time Fourier Transform* (STFT) (Choi et al., 2016). Meskipun demikian, penggunaan satu jenis representasi citra sering kali tidak cukup untuk menangkap semua fitur yang relevan dari sinyal audio. Dalam beberapa penelitian, pendekatan yang menggabungkan beberapa representasi citra, seperti fusi antara *scalogram* dan *spectrogram*, terbukti dapat meningkatkan performa klasifikasi (Ng et al., 2020). *Scalogram*, yang dihasilkan melalui *Continuous Wavelet Transform* (CWT), mampu menangkap informasi frekuensi dalam berbagai skala waktu dengan lebih baik dibandingkan *spectrogram* konvensional (T G et al., 2024).

Selain pemilihan representasi citra, pemodelan fitur hasil ekstraksi juga menjadi faktor penting dalam meningkatkan kinerja sistem klasifikasi genre musik. Beberapa penelitian sebelumnya umumnya menggunakan model *Convolutional Neural Network* (CNN), seperti ResNet, untuk mengekstraksi fitur spasial dari citra audio. ResNet memiliki keunggulan dalam mengekstraksi fitur visual yang kompleks melalui mekanisme *residual learning*, namun pendekatan ini masih memiliki keterbatasan dalam memodelkan hubungan sekuensial antar fitur yang merepresentasikan dinamika temporal sinyal audio (Ashraf et al., 2023). Sementara itu, sinyal audio memiliki karakteristik temporal yang kuat, sehingga informasi urutan antar segmen waktu perlu dimodelkan secara eksplisit.

Berdasarkan permasalahan tersebut, pada penelitian Tugas Akhir ini dikembangkan model klasifikasi genre musik yang menggabungkan metode *Residual Network* (ResNet) dan *Bidirectional Gated Recurrent Unit* (Bi-GRU) dengan memanfaatkan fusi citra *scalogram* dan *spectrogram*. ResNet digunakan untuk mengekstrak fitur spasial dari citra

(He et al., 2016), sementara Bi-GRU digunakan untuk menangkap informasi temporal dari fitur yang telah diekstraksi (Zhang, 2023). Kombinasi kedua metode ini diharapkan dapat meningkatkan akurasi klasifikasi dibandingkan dengan pendekatan konvensional yang hanya menggunakan satu jenis representasi citra atau satu jenis model *deep learning*. Dengan menggabungkan kekuatan ekstraksi fitur dari ResNet dan pemrosesan informasi sekuensial dari Bi-GRU, model yang dikembangkan diharapkan mampu memberikan hasil yang lebih akurat dan stabil dalam klasifikasi genre musik.

1.2 Rumusan Masalah

Penelitian ini difokuskan pada perumusan masalah sebagai berikut:

1. Bagaimana penerapan kombinasi metode ResNet dan Bi-GRU untuk klasifikasi genre musik berbasis fusi citra *scalogram-spectrogram*?
2. Bagaimana kinerja dari kombinasi metode ResNet dan Bi-GRU untuk klasifikasi genre musik berbasis fusi citra *scalogram-spectrogram*?

1.3 Batasan Masalah

Penelitian ini dibatasi pada ruang lingkup tertentu agar analisis tetap terfokus dan sesuai dengan pendekatan kombinasi metode ResNet dan Bi-GRU, dengan batasan masalah sebagai berikut:

1. Data yang digunakan adalah dataset GTZAN sebagai data sekunder yang berisi 1000 audio dengan 10 genre di mana di dalam setiap genre terdapat masing-masing 100 file audio dengan durasi 30 detik dan data primer yang dikumpulkan secara langsung oleh penulis berupa 50 lagu dengan 10 genre yang serupa dengan genre pada dataset GTZAN di mana di dalam setiap genre terdapat masing-masing 5 lagu.
2. Genre yang terdapat pada dataset GTZAN adalah *blues, classical, country, disco, hiphop, jazz, metal, pop, reggae, dan, rock*.

1.4 Tujuan

Penelitian ini bertujuan untuk menjawab permasalahan yang telah dirumuskan melalui pendekatan kombinasi metode ResNet dan Bi-GRU, dengan tujuan sebagai berikut:

1. Menerapkan kombinasi metode ResNet dan Bi-GRU untuk klasifikasi genre musik berbasis fusi citra *scalogram-spectrogram*.
2. Mengetahui kinerja dari kombinasi metode ResNet dan Bi-GRU untuk klasifikasi genre musik berbasis fusi citra *scalogram-spectrogram*.

1.5 Manfaat

Penelitian ini diharapkan dapat memberikan sejumlah manfaat sebagai berikut:

1. Memberikan kontribusi dalam pengembangan model klasifikasi genre musik berbasis *deep learning* yang lebih akurat dan efisien.
2. Menyediakan pendekatan baru dengan kombinasi ResNet dan Bi-GRU yang dapat diaplikasikan pada berbagai permasalahan klasifikasi sinyal audio lainnya.
3. Membantu pengembangan sistem rekomendasi musik yang lebih baik dengan klasifikasi genre yang lebih akurat.

BAB II
TINJAUAN PUSTAKA

Bab ini menyajikan ringkasan dari hasil temuan terdahulu beserta dengan teori yang digunakan.

2.1 Penelitian Terdahulu

Tabel 2.1 Referensi Utama

Referensi	Judul	Pokok Bahasan
(Pimenta-Zanon et al., 2021)	*Complex Network-Based Approach for Feature Extraction and Classification of Musical Genres*	Ekstraksi fitur dan klasifikasi genre musik dengan pendekatan jaringan kompleks. Metode ini mengubah sinyal audio menjadi jaringan kompleks dan memperoleh hasil akurasi yang lebih tinggi dibandingkan metode konvensional.
(Wiraguna & Putri, 2023)	Klasifikasi Genre Musik Menggunakan *Support Vector Machine* Berdasarkan *Spectral Features*	Klasifikasi genre musik menggunakan *Support Vector Machine* (SVM) dengan fitur spektral seperti *Spectral Centroid* dan *Spectral Bandwidth*. Hasilnya menunjukkan bahwa SVM dengan fitur spektral dapat menghasilkan performa klasifikasi yang kompetitif.
(Pratama, 2021)	KLASIFIKASI GENRE MUSIK POPULER MENGGUNAKAN METODE *CONVOLUTIONAL NEURAL NETWORK* DENGAN *DATA AUGMENTATION*	Penerapan *Convolutional Neural Network* (CNN) dengan augmentasi data untuk klasifikasi genre musik. Teknik ini terbukti meningkatkan akurasi secara signifikan dibandingkan metode tanpa augmentasi.

Referensi	Judul	Pokok Bahasan
(Ramírez & Flores, 2019)	*Machine Learning for Music Genre: Multifaceted Review and Experimentation with Audioset*	Peninjauan dan eksperimen klasifikasi genre musik dengan berbagai algoritma *machine learning* menggunakan dataset Audioset. NN menunjukkan performa terbaik dalam menangkap fitur representatif dari musik.
(Paramarta, 2023)	FUSI CITRA *SCALOGRAM* BERBASIS WAVELET DAN *SPECTOGRAM* UNTUK KLASIFIKASI GENRE MUSIK MENGGUNAKAN METODE MUSICRECNET	Penerapan MusicRecNet dalam mengklasifikasikan genre musik menggunakan fusi citra CWT *scalogram* dan STFT *spectogram*. Penelitian ini dilakukan dengan melakukan *tuning hyperparameter* secara berulang hingga diperoleh kombinasi *hyperparameter* yang menghasilkan akurasi validasi terbaik.
Penelitian Tugas Akhir	PENERAPAN KOMBINASI METODE RESNET DAN BI-GRU UNTUK KLASIFIKASI GENRE MUSIK BERBASIS FUSI CITRA *SCALOGRAM-SPECTROGRAM*	Pada penelitian ini, akan dilakukan kombinasi ResNet dan Bi-GRU untuk klasifikasi genre musik.

2.2 Klasifikasi Genre Musik

Klasifikasi genre musik merupakan salah satu tugas utama dalam pengolahan sinyal audio yang bertujuan untuk mengelompokkan musik ke dalam kategori tertentu berdasarkan karakteristik tertentu yang terkait dengan instrumentasi, struktur ritmis, dan *pitch* musik (Giri, 2024). Genre musik memiliki pola akustik yang khas, seperti ritme, harmoni, dan spektrum frekuensi, yang dapat diekstraksi untuk membangun model klasifikasi otomatis.

Pendekatan awal dalam klasifikasi genre musik banyak menggunakan teknik berbasis fitur statistik dan *machine learning* tradisional, seperti *Support Vector Machine* (SVM) dan *K-Nearest Neighbors* (KNN). Namun, pendekatan ini memiliki keterbatasan dalam menangkap pola kompleks dari sinyal audio. Dengan perkembangan *deep learning*, metode berbasis jaringan saraf tiruan, terutama CNN dan RNN, mulai digunakan untuk meningkatkan akurasi klasifikasi genre musik (Zhang, 2023).

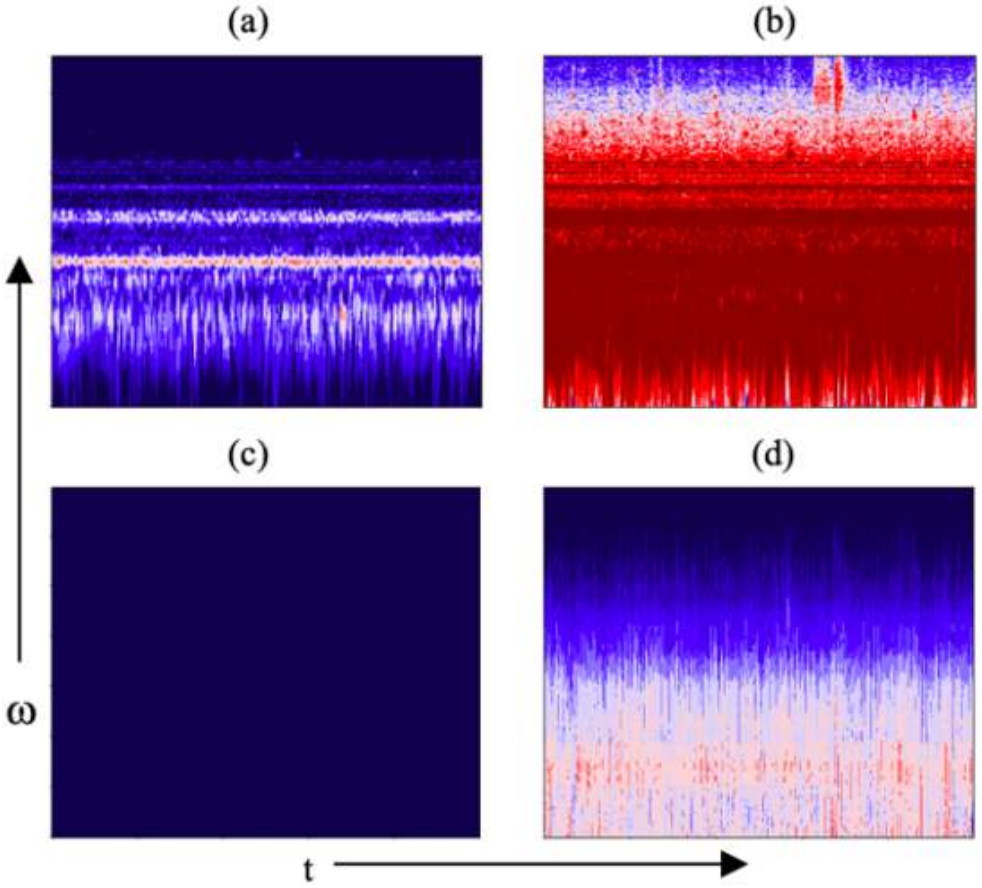
2.3 Normalisasi Audio

Kondisi perekaman data audio seringkali bervariasi pada kenyataannya. Akibatnya, amplitudo audio yang direkam dapat berbeda untuk jenis kesalahan yang serupa pada situasi yang berbeda, atau bahkan dalam situasi yang serupa jika posisi mikrofon atau getarannya berubah. Misalnya, menempatkan mikrofon lebih dekat akan menghasilkan

amplitudo rekaman yang lebih tinggi, sementara menempatkannya lebih jauh akan menghasilkan amplitudo yang lebih rendah. Untuk mengurangi efek dari variasi ini, perlu dilakukan normalisasi audio untuk membatasi amplitudo sinyal dalam rentang tertentu (Phan, 2024). Amplitudo maksimum dari sebuah sinyal, dilambangkan sebagai $\max(|x|)$, dihitung, dan semua sampel lainnya dinormalisasi dengan nilai maksimum ini, seperti yang dijelaskan dalam Persamaan 2.1

$$x^{norm} = \frac{x}{\max(|x|)}. \tag{2.1}$$

Langkah ini bertujuan untuk membuat struktur sinyal audio dengan jenis kesalahan yang serupa menjadi lebih seragam dan untuk menonjolkan perbedaan di antara sinyal-sinyal dengan jenis kesalahan yang berbeda. Normalisasi memang secara signifikan meningkatkan visibilitas *scalogram* dan *spectrogram* yang dihasilkan, seperti yang diilustrasikan pada Gambar 2.1. Jika tidak ada normalisasi yang diterapkan seperti pada Gambar 2.1(a) dan Gambar 2.1(c), akan sulit bagi pengamat manusia untuk melihat peta panas *scalogram* dan *spectrogram*. Sebaliknya, pada Gambar 2.1(b) dan Gambar 2.1(d) saat normalisasi diterapkan, peta panas divisualisasikan dengan lebih jelas.



Gambar 2.1 Pengaruh Normalisasi
Sumber: (Phan, 2024)

2.4 *Wavelet Transform* (WT)

Wavelet Transform (WT) merupakan teknik yang digunakan untuk mengubah sinyal kedalam representasi *time-scale* sehingga fitur-fitur penting pada sinyal dapat diperkuat

untuk proses analisis lebih lanjut (Addison, 2017). Dengan menggunakan metode ini, sebuah sinyal diuraikan dari domain waktu ke dalam domain waktu-skala dan dinyatakan pada Persamaan 2.2

$$X_{CWT}(a,b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} x(t)\psi\left(\frac{t-b}{a}\right) dt \tag{2.2}$$

dengan

$X_{CWT}(a,b)$	:	Hasil transformasi CWT pada translasi waktu dan frekuensi
b	:	Parameter translasi waktu
a	:	Parameter skala frekuensi
$x(t)$	:	Sinyal asli dalam domain waktu
ψ	:	*Mother wavelet*
t	:	Parameter waktu.

WT bergantung pada parameter skala dan translasi. Faktor normalisasi memastikan normalisasi energi sinyal tetap terjaga di seluruh skala. Selama proses transformasi, *mother wavelet* mengalami pelebaran pada skala besar (frekuensi rendah) dan kontraksi pada skala kecil (frekuensi tinggi), kemudian digeser sepanjang waktu oleh parameter translasi untuk menghitung kecocokan terhadap sinyal asli. Hasil proses ini berupa matriks koefisien yang memetakan perubahan energi sinyal pada berbagai skala dan waktu. *Mother wavelet* yang umum digunakan adalah *wavelet morlet* dengan persamaan

$$\psi(t) = e^{-\frac{t^2}{2}} \cos 5t. \tag{2.3}$$

Pada sinyal diskrit, perhitungan WT dilakukan dengan mendiskritkan integral menjadi penjumlahan sesuai interval *sampling* (Lin & Qu, 2000), yang diformulasikan pada Persamaan 2.4

$$X_{DWT}(m,k) = \frac{1}{\sqrt{m}} \sum_{-\infty}^{\infty} x(n)\psi\left(\frac{n-k}{m}\right) \tag{2.4}$$

dengan

$X_{DWT}(m,k)$	:	Hasil transformasi DWT pada skala dan translasi
$x(n)$	:	Sinyal asli dalam domain diskrit
ψ	:	*Mother wavelet*
n	:	Indeks waktu diskrit
m	:	Parameter skala
k	:	Parameter translasi.

Pada *Continuous Wavelet Transform* (CWT), translasi terjadi pada setiap sampel sehingga menghasilkan matriks berdimensi (N, m), dengan N mewakili panjang sinyal dan m mewakili jumlah skala. Sebaliknya, *Discrete Wavelet Transform* (DWT) diimplementasikan melalui *bank filter*, yang secara komputasi lebih efisien daripada CWT. Namun, hasil dari DWT bukan berupa matriks dua dimensi, sehingga DWT kurang sesuai untuk aplikasi yang memerlukan peta panas seperti visualisasi energi frekuensi.

Scalogram adalah hasil dari *Continuous Wavelet Transform* (CWT) yang diperoleh dengan cara menghitung magnitudo hasil CWT yang direpresentasikan dalam bentuk

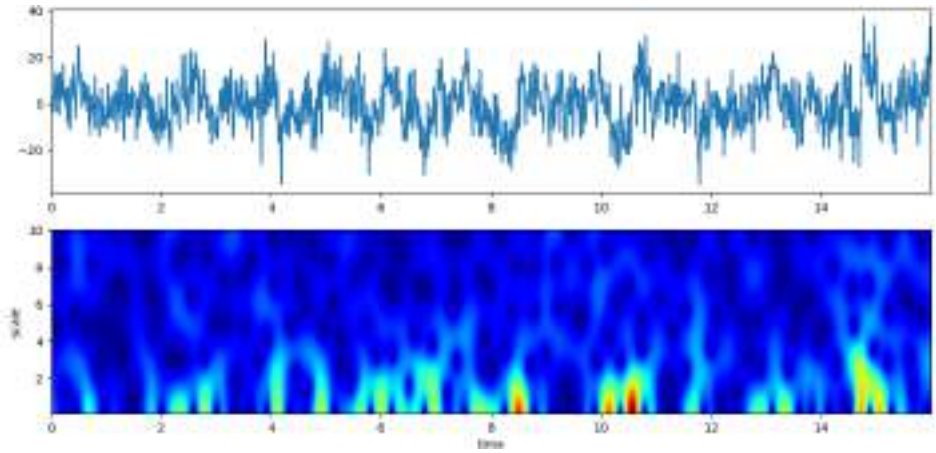
power (Aslan & Akin, 2022) dengan persamaan berikut.

$$\text{power}(a, b) = |X_{CWT}(a, b)|^2 \tag{2.5}$$

Magnitudo *scalogram* kemudian dikonversi ke dalam skala desibel (dB) menggunakan transformasi logaritmik dengan tujuan untuk meningkatkan interpretasi. Proses ini dilakukan dengan menggunakan Librosa, dengan formula (Keller, 2022)

$$W_{dB} = 10 \times \log_{10}(|X_{CWT}(a, b)|^2 + \varepsilon) \tag{2.6}$$

dengan ε adalah nilai kecil untuk menghindari kesalahan logaritma pada nol. *Scalogram* direpresentasikan sebagai peta panas dengan intensitas yang diekspresikan melalui serangkaian warna. Intensitas warna pada setiap piksel *scalogram* sesuai dengan tingkat energi sinyal pada frekuensi dan waktu tertentu. Sebagai contoh, warna berkisar dari biru tua, yang menunjukkan energi yang lebih rendah, sedangkan merah menunjukkan energi yang lebih tinggi, seperti yang diilustrasikan pada Gambar 2.2.



Gambar 2.2 Visualisasi *Scalogram*
Sumber: (SPKIT Development Team, 2023a)

Dalam konteks pengolahan sinyal musik, *scalogram* digunakan untuk memvisualisasikan distribusi energi sinyal di seluruh dimensi waktu dan frekuensi, sehingga memungkinkan ekstraksi fitur yang lebih kaya dibandingan dengan metode konvensional. Dengan keunggulannya dalam menangkap informasi lokal dalam berbagai skala frekuensi, *scalogram* menjadi pilihan yang efektif dalam tugas klasifikasi genre musik (Hangting et al., 2018).

Dalam klasifikasi genre musik, penggunaan *scalogram* memiliki beberapa keunggulan. *Scalogram* mampu menyesuaikan resolusi temporal dan frekuensial secara adaptif. Selain itu, *scalogram* dapat direpresentasikan sebagai citra, sehingga memungkinkan pemanfaatan model *deep learning* berbasis CNN seperti ResNet untuk melakukan ekstraksi fitur dan klasifikasi (He et al., 2016).

2.5 *Short-Time Fourier Transform* (STFT)

Short-Time Fourier Transform (STFT) adalah metode yang digunakan untuk menganalisis sinyal dengan membaginya menjadi segmen berdasarkan *frame* waktu dan melakukan *Fourier Transform* (FT) pada setiap segmen, yang diformulasikan pada

Persamaan 2.7 (Müller, 2015).

$$X_{STFT}(\tau, \omega) = \int_{-\infty}^{\infty} x(t)\gamma(t-\tau)e^{-j\omega t}\, dt \tag{2.7}$$

dengan

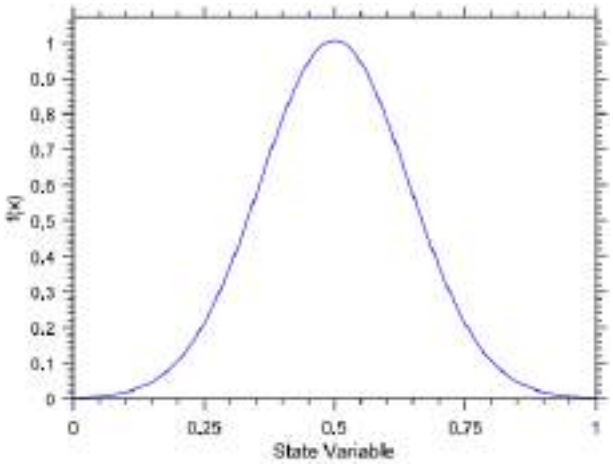
$X_{STFT}(\tau, \omega)$	:	Hasil transformasi STFT kontinu
τ	:	Parameter waktu (posisi *window*)
ω	:	Variabel frekuensi sudut
$x(t)$	:	Sinyal asli dalam domain waktu
$\gamma(t-\tau)$	:	Fungsi *window* yang digeser ke posisi waktu τ
t	:	Parameter waktu
j	:	Unit imajiner dalam persamaan kompleks

Metode ini memungkinkan analisis sinyal secara simultan dalam pergeseran frekuensi dan pergeseran waktu. STFT menghitung spektrum dalam periode waktu yang singkat dengan menerapkan fungsi *windowing* untuk mengisolasi bagian tertentu dari sinyal dan meminimalkan kebocoran spektral, sehingga meningkatkan akurasi spektrum (Gharaibeh, 2021). Hal ini memungkinkannya untuk merekam tidak hanya frekuensi yang ada dalam sinyal tetapi juga cara frekuensi ini bervariasi dari waktu ke waktu. Salah satu jenis *window* yang dikenal baik untuk menyeimbangkan antara ketepatan frekuensi dan ketepatan waktu adalah *Hann window* (Hassnain & Mehmood, 2024) dengan formula yang tertera pada Persamaan 2.8 (Qizhen, 2024).

$$\gamma(n) = \frac{1}{2}\left(1 - \cos\left(\frac{2\pi n}{N-1}\right)\right),\ 0 \leq n \leq N-1. \tag{2.8}$$

dengan

$\gamma(n)$	:	Nilai *window* pada indeks ke-n
n	:	Indeks posisi dalam *window*
N	:	Panjang *window*



Gambar 2.3 Grafik Hann *window*
Sumber: (Zafar et al., 2022)

Dalam penerapan digital, sinyal diproses dalam format waktu diskrit dan STFT dihitung dengan panjang *window* N, yang disebut sebagai ukuran *frame*, yang diformulasikan pada Persamaan 2.9

$$X_{STFT}(m,k) = \sum_{n=0}^{N-1} x(n)\gamma(n - mH)e^{-\frac{j2\pi kn}{N}} \tag{2.9}$$

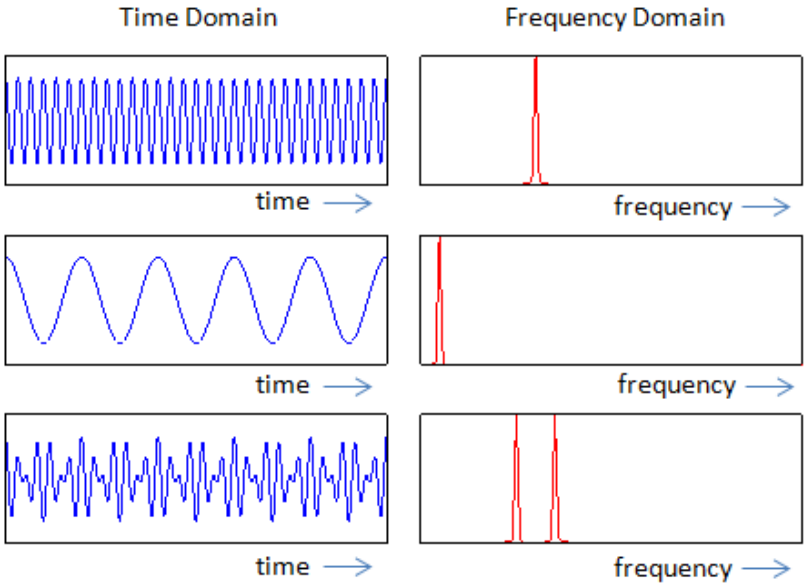
dengan

$X_{STFT}(m,k)$	:	Hasil transformasi STFT diskrit
$x(n)$	:	Sinyal asli dalam domain diskrit
$\gamma(n - mH)$	:	Fungsi *window* yang digeser ke posisi waktu tertentu
m	:	*Frame* ke-m
M	:	Panjang total data
H	:	*Hop size*
j	:	Unit imajiner dalam persamaan kompleks
k	:	Frekuensi ke-k
n	:	Indeks waktu diskrit sinyal asli
N	:	Panjang *window*

Pada Persamaan 2.9, terdapat bagian yang merepresentasikan komponen inti dari *Discrete Fourier Transform* (DFT), yaitu persamaan sebagai berikut.

$$X_{DFT}(k) = \sum_{n=0}^{N-1} x(n)e^{-\frac{j2\pi kn}{N}} \tag{2.10}$$

DFT digunakan untuk mengubah sinyal diskrit dalam domain waktu menjadi representasi dalam domain frekuensi (Lenssen, 2013).

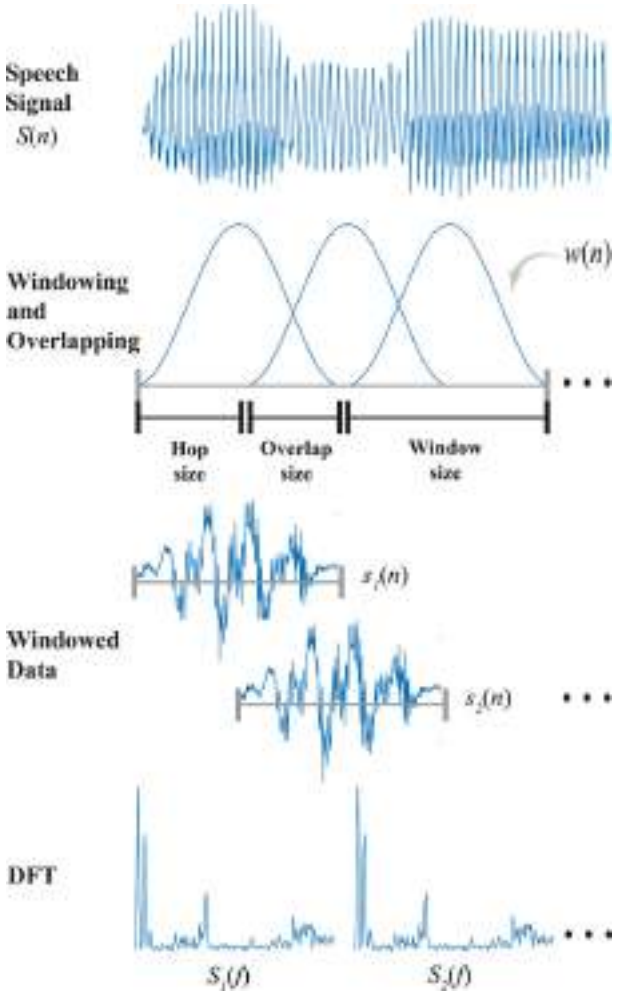


Gambar 2.4 DFT mengubah sinyal dalam domain waktu menjadi domain frekuensi

Dengan demikian, pada setiap *frame* hasil pemotongan sinyal, STFT menghitung DFT untuk mendapatkan distribusi energi frekuensi yang terkandung di dalamnya.

Hal ini menunjukkan bahwa STFT pada dasarnya merupakan kombinasi dari proses pemblokkan sinyal menjadi *frame*, penerapan fungsi *window*, dan transformasi DFT pada setiap *frame*.

Jika pergeseran dilakukan satu per satu sampel, hasilnya akan banyak data yang mirip karena spektrum antar sampel berdekatan hampir sama. Untuk mengatasi hal ini digunakan langkah pergeseran yang lebih besar yang disebut sebagai *hop size*. Pilihan ini memberikan keseimbangan antara mencapai resolusi waktu yang tinggi dan mengelola banyaknya data secara efektif (Müller, 2015). Setiap titik data sampel yang digunakan untuk menghitung STFT disebut sebagai indeks *frame*. Dalam setiap *frame*, penghitungan FT dari sinyal diskrit dari N titik waktu menghasilkan vektor frekuensi dengan N titik. Karena sifat simetris spektrum Fourier, hanya separuh pertama spektrum yang biasanya dipertimbangkan untuk menghindari data ganda. Akibatnya, *output* dari STFT disusun sebagai matriks dengan baris mewakili frekuensi dan kolom mewakili *frame* waktu. Untuk memperjelas tahapan komputasi yang dilakukan, proses *Short-Time Fourier Transform* dapat digambarkan dalam bentuk diagram alur seperti pada Gambar 2.5.



Gambar 2.5 Representasi proses STFT
Sumber: (Almaghrabi et al., 2023)

Berikutnya, hasil implementasi *Short-Time Fourier Transform* (STFT) dikonversi ke dalam bentuk *spectrogram* dengan menghitung mengnitudo dari hasil STFT yang

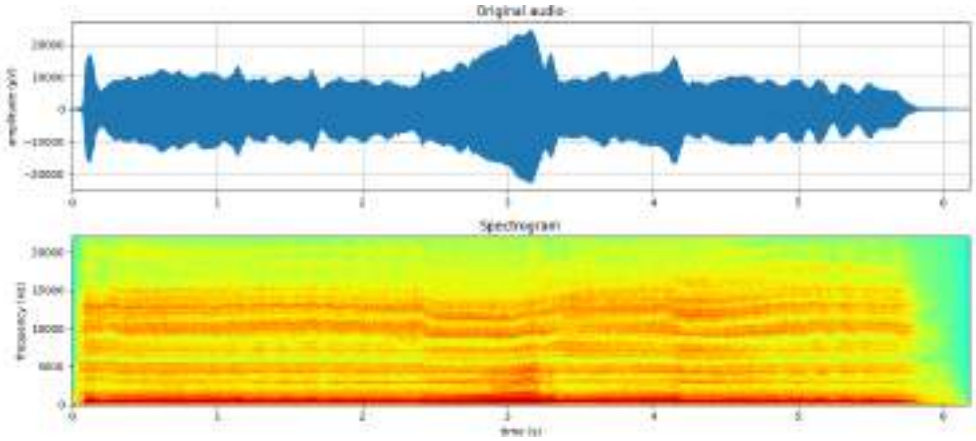
direpresentasikan dalam bentuk *power* (Jopri et al., 2017) dengan persamaan sebagai berikut.

$$\text{power}(m,k) = |X_{STFT}(m,k)|^2 \tag{2.11}$$

Magnitudo *spectrogram* kemudian dikonversi ke dalam skala desibel (dB) menggunakan transformasi logaritmik dengan tujuan untuk meningkatkan interpretasi. Proses ini dilakukan dengan menggunakan Librosa, dengan formula sebagai berikut (Keller, 2022).

$$S_{dB} = 10 \times \log_{10}(|X_{STFT}(m,k)|^2 + \varepsilon) \tag{2.12}$$

dengan ε adalah nilai kecil untuk menghindari kesalahan logaritma pada nol. *Spectrogram* biasanya digunakan untuk meningkatkan visualisasi hasil STFT karena memberikan informasi yang kaya tentang karakteristik spektral dari sinyal, seperti nada (Hartono et al., 2023), harmoni, dan ritme (Mertins, 2001). Direpresentasikan sebagai jenis gambar peta panas, *spectrogram* memberikan representasi dua dimensi dari energi sinyal pada dimensi waktu yang disusun di sepanjang sumbu x dan frekuensi yang disusun di sepanjang sumbu y. Intensitas warna pada setiap piksel *spectrogram* sesuai dengan tingkat energi sinyal pada frekuensi dan waktu tertentu. Sebagai contoh, warna berkisar dari hijau, yang menunjukkan energi yang lebih rendah, sedangkan merah menunjukkan energi yang lebih tinggi, seperti yang diilustrasikan pada Gambar 2.6.



Gambar 2.6 Visualisasi *Spectrogram*
Sumber: (SPKIT Development Team, 2023b)

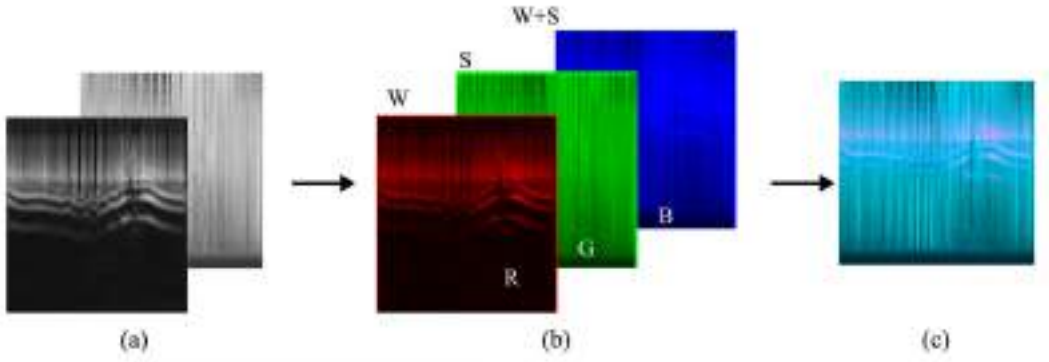
2.6 Fusi Citra

Fusi citra adalah proses menggabungkan informasi dari dua atau lebih citra yang diperoleh dari sensor berbeda. Tujuannya adalah untuk menyatukan informasi yang saling melengkapi atau mengurangi informasi yang berulang, sehingga menghasilkan satu citra baru yang lebih jelas, lengkap, dan informatif dibandingkan dengan citra dari masing-masing sensor secara terpisah (Chen et al., 2021).

Secara umum, teknik fusi citra terbagi menjadi 2 kelas, yaitu teknik yang terkait warna, dan juga teknik dengan metode statistik atau numerik (Putra & Setiawan, 2021). Beberapa contoh teknik terkait warna terdiri dari komposisi lapisan warna RGB (*Red*, *Green*, *Blue*) (JUANDRI & Anwar, 2023), *grayscale* (Wu & Toet, 2014), dan IHV (Intensitas, *Hue*, *Value*) (Parwatiningtyas, 2010). Pendekatan statistik menggunakan

saluran statistik termasuk korelasi (*Principal Components Analysis* (PCA)), dan filter (*high pass*) (Putra & Setiawan, 2021), sedangkan metode numerik meliputi operasi aritmatika seperti penjumlahan, rata-rata, pengurangan, perkalian (Suthakar et al., 2014), nilai minimal, dan nilai maksimal (Mahadevan & Barani, 2012). Selain itu, teknik fusi citra juga dapat dibagi menjadi 4 tingkat, yaitu *signal level*, *pixel/data level*, *feature level*, dan *decision level*. Dalam fusi berbasis sinyal (*signal based fusion*), sinyal dari berbagai sensor berbeda digabungkan untuk menciptakan sinyal baru dengan rasio *signal-to-noise* yang lebih baik daripada sinyal yang asli. Fusi berbasis piksel (*pixel based fusion*) adalah penggabungan data mentah dari berbagai sumber menjadi satu data baru dengan resolusi tunggal. Hasilnya diharapkan dapat memberikan informasi yang lebih informatif dibandingkan data aslinya. Fusi tingkat fitur (*feature level fusion*) adalah proses mengekstraksi berbagai fitur, seperti tepi, sudut, garis, atau parameter tekstur dari berbagai sumber data, lalu menggabungkannya menjadi satu atau lebih peta fitur. Fusi ini biasanya digunakan sebagai *input* pada tahap *preprocessing*, misalnya untuk segmentasi citra atau deteksi perubahan. *Decision level fusion* adalah proses menggabungkan hasil dari beberapa algoritma untuk menghasilkan satu keputusan akhir. Jika hasil dari algoritma berbeda dinyatakan dalam bentuk tingkat keyakinan (*confidence*) dan bukan keputusan langsung, maka disebut fusi lunak (*soft fusion*). Sebaliknya, jika hasilnya berupa keputusan pasti, maka disebut fusi keras (*hard fusion*).

Representasi citra berwarna dalam ruang warna RGB terdiri atas tiga kanal warna utama, yaitu merah (R), hijau (G), dan biru (B), yang masing-masing dapat dimanipulasi secara independen. Oleh karena itu, citra *grayscale* dapat dipetakan ke salah satu kanal warna dengan mengatur kanal lainnya bernilai nol (Gonzalez & Woods, 2018). Berdasarkan konsep tersebut, untuk menggabungkan representasi CWT dan STFT ke dalam satu citra, nilai *grayscale* pada *scalogram* digunakan sebagai kanal R, nilai *grayscale* pada *spectrogram* digunakan sebagai kanal G, dan kanal B didapat dari hasil penggabungan *grayscale scalogram* dengan *grayscale spectrogram* (Niroshana et al., 2021). Proses fusi citra *scalogram* dan *spectrogram* dapat dilihat pada Gambar 2.7.



Gambar 2.7 Proses Fusi Citra: (a) *Grayscale Spectrogram* dan *Scalogram*, (b) Komponen RGB Fusi Citra, (c) Hasil Fusi Citra
Sumber: (Niroshana et al., 2021)

Teknik fusi citra yang akan digunakan dalam penelitian ini adalah fusi citra berbasis piksel (*pixel based fusion*) yang melibatkan operasi aritmatika dan fungsi agregasi (Mahadevan & Barani, 2012; Suthakar et al., 2014).

1. *Maximum*

Citra kanal B diperoleh dengan memilih intensitas maksimal piksel yang sesuai dari citra *scalogram* dan *spectrogram*.

$$B = \sum_{i=1}^{m} \sum_{j=1}^{n} \max\{R_{ij}, G_{ij}\} \tag{2.13}$$

2. *Minimum*
   Citra kanal B diperoleh dengan memilih intensitas minimal piksel yang sesuai dari citra *scalogram* dan *spectrogram*.

$$B = \sum_{i=1}^{m} \sum_{j=1}^{n} \min\{R_{ij}, G_{ij}\} \tag{2.14}$$

3. *Average* (rata-rata)
   Citra kanal B diperoleh dengan mengambil rata-rata intensitas piksel yang sesuai dari citra *scalogram* dan *spectrogram*.

$$B = \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{n} (R_{ij} + G_{ij}) \tag{2.15}$$

4. *Addition* (penjumlahan)
   Citra kanal B diperoleh dengan melakukan operasi penjumlahan intensitas piksel yang sesuai dari citra *scalogram* dan *spectrogram*.

$$B = \sum_{i=1}^{m} \sum_{j=1}^{n} (R_{ij} + G_{ij}) \tag{2.16}$$

5. *Subtraction* (pengurangan)
   Citra kanal B diperoleh dengan melakukan operasi pengurangan intensitas piksel yang sesuai dari citra *scalogram* dan *spectrogram*.

$$B = \sum_{i=1}^{m} \sum_{j=1}^{n} (R_{ij} - G_{ij}) \tag{2.17}$$

6. *Multiplication* (perkalian)
   Citra kanal B diperoleh dengan melakukan operasi perkalian intensitas piksel yang sesuai dari citra *scalogram* dan *spectrogram*.

$$B = \sum_{i=1}^{m} \sum_{j=1}^{n} (R_{ij} \times G_{ij}) \tag{2.18}$$

7. *Division* (pembagian)
   Citra kanal B diperoleh dengan melakukan operasi pembagian intensitas piksel yang sesuai dari citra *scalogram* dan *spectrogram*.

$$B = \sum_{i=1}^{m} \sum_{j=1}^{n} \frac{R_{ij}}{G_{ij}} \tag{2.19}$$

8. *Weighted average* (pembobotan)
   Citra kanal B diperoleh dengan melakukan pembobotan intensitas piksel yang sesuai dari citra *scalogram* dan *spectrogram*.

$$B = \sum_{i=1}^{m} \sum_{j=1}^{n} (\alpha R_{ij} + (1 - \alpha) G_{ij}) \tag{2.20}$$

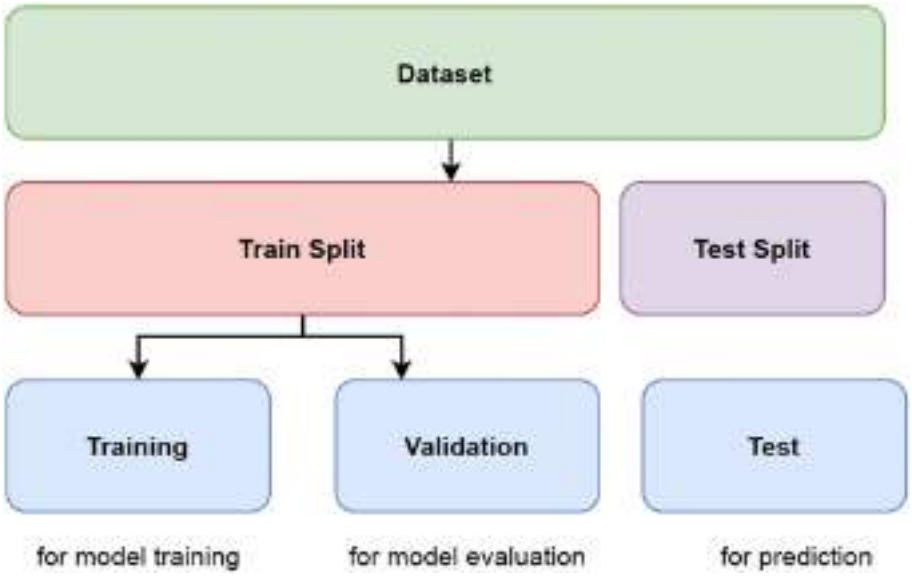
   dengan α adalah nilai bobot yang menentukan bobot relatif dari piksel-piksel yang sesuai dari citra *scalogram* dan *spectrogram*. α menentukan kontribusi citra *scalogram* dan *spectrogram* terhadap citra kanal B. Jika nilai α terlalu kecil, citra kanal B hampir sama dengan citra *spectrogram*. Sedangkan jika nilai α terlalu besar, citra kanal B hampir sama dengan citra *scalogram*.

Setelah didapatkan citra kanal B, dilanjutkan dengan menggabungkan *scalogram*, *spectrogram*, dan citra kanal B menggunakan *pixel based fusion* penjumlahan dengan formula:

$$RGB = R + G + B. \tag{2.21}$$

2.7 *Data Splitting*

Data splitting adalah proses pembagian dataset ke dalam 3 *subset*, yaitu data latih, data validasi, dan data uji. Data latih adalah bagian dari data yang digunakan untuk melatih model, sehingga model dapat belajar mengenali pola dan mengoptimalkan parameter yang dimilikinya. Data validasi digunakan untuk memantau dan menyesuaikan proses pembelajaran model, sehingga dapat membantu dalam mengevaluasi performa serta pemilihan model yang paling optimal. Sementara itu, data uji digunakan pada tahap akhir untuk menguji model yang dilatih, dengan tujuan mengevaluasi kinerja akhir model dan algoritma yang digunakan (Sarno et al., 2023).



Gambar 2.8 Ilustrasi *Data Splitting*
Sumber: (Kavitha et al., 2022)

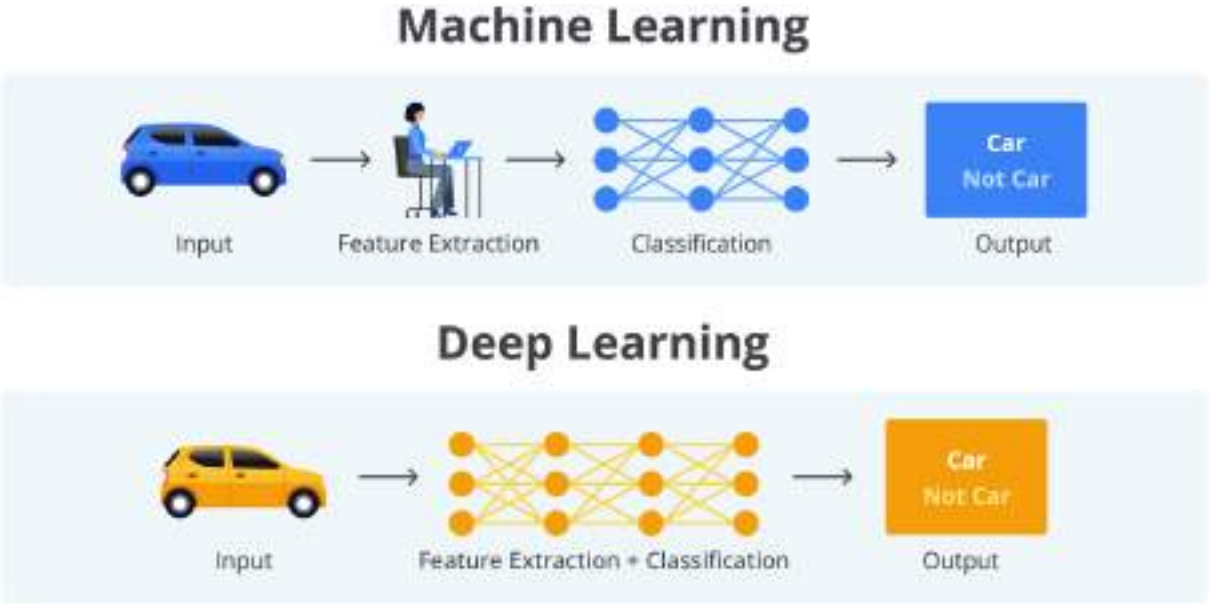
Metode *data splitting* yang digunakan pada penelitian ini meliputi *Group Shuffle Split*

dan *Stratified Sampling* per kelas. *Group Shuffle Split* merupakan metode pembagian data berbasis kelompok, yang memastikan setiap kelompok data hanya muncul satu kali pada *subset* data uji, serta terlebih dahulu diacak sebelum proses pembagian dilakukan (Munoz, 2023). Sementara itu, *Stratified Sampling* diterapkan dengan membagi dataset ke dalam beberapa strata berdasarkan karakteristik kelas. Selanjutnya, data pada setiap strata dibagi secara independen ke dalam data latih, data validasi, dan data uji, sehingga proporsi data pada setiap kelas tetap terjaga (Qian, 2010).

2.8 *Deep Learning*

Deep learning merupakan bagian dari *machine learning* yang menggunakan *multiple layers* pada *Neural Network* (NN) untuk mempelajari pola dari tingkat informasi sederhana hingga abstrak (Chahal & Gulia, 2019), sehingga mampu meniru cara kerja otak manusia (Sarno et al., 2023). Lapisan awal biasanya mempelajari pola sederhana, sedangkan lapisan yang lebih dalam menangkap pola yang semakin kompleks dan abstrak. Kemampuan mempelajari representasi ini membuat *deep learning* efektif dalam memodelkan pola kompleks yang sulit ditangkap oleh metode *machine learning* tradisional (Bengio et al., 2017). Representasi ini memungkinkan *deep learning* mencapai performa unggul dalam menyelesaikan berbagai tugas seperti klasifikasi, deteksi objek, atau prediksi (Suryantara, 2024).

Algoritma *machine learning* konvensional tidak mampu belajar secara langsung dari data mentah. Algoritma tersebut memerlukan rekayasa fitur yang cermat serta keahlian domain yang sangat spesifik untuk mengekstraksi fitur dari data mentah, yang selanjutnya digunakan sebagai representasi internal guna mengidentifikasi pola dari fitur tersebut. Pada *deep learning*, tahap awal dalam prosedur *machine learning* tersebut tidak lagi diperlukan karena telah diotomatisasi. *Deep learning* mampu mengekstraksi fitur baru secara otomatis langsung dari data mentah (Chahal & Gulia, 2019).



Gambar 2.9 Ilustrasi *Deep Learning*
Sumber: (Afinda, 2024)

Proses pelatihan pada *deep learning* dilakukan melalui *forward propagation* untuk menghasilkan prediksi, kemudian dilanjutkan dengan *back propagation* untuk menghitung

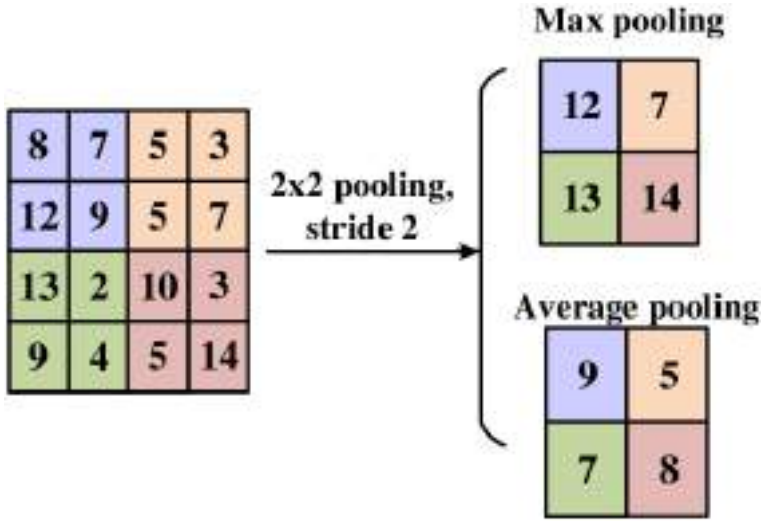
gradien dari *loss function* terhadap setiap bobot dalam jaringan dan memperbaruinya menggunakan metode penurunan gradien (*gradient descent*) agar menghasilkan *output* yang diinginkan (Suryantara, 2024).

2.8.1 *Neural Network*

Neural Network (NN) atau jaringan saraf tiruan adalah model matematis yang terinspirasi oleh struktur dan fungsi otak manusia yang terdiri dari *input layer*, *hidden layer*, dan *output layer* (Suryantara, 2024). Beberapa *layer* yang ada pada *Neural Network* dijelaskan berikut ini.

Pooling Layer

Pooling layer menggantikan *output* pada suatu lokasi dengan *summary statistic* dari *output* di sekitarnya. *Pooling Layer* yang paling banyak dikenal merupakan *Max Pooling* dan *Average Pooling*. *Max Pooling* mengambil nilai *output* maksimum dari area persegi di sekitarnya, sedangkan *Average Pooling* mengambil nilai *output* rata-rata dari area persegi di sekitarnya (Bengio et al., 2017). Contoh aplikasi *Pooling Layer* dapat dilihat pada Gambar 2.10.



Gambar 2.10 Contoh *Pooling Layer*
Sumber: (Yingge et al., 2020)

Batch Normalization

Batch Normalization merupakan teknik untuk menormalisasi aktivasi pada *intermediate layer* dalam *deep learning* yang dapat meningkatkan akurasi serta mempercepat proses pelatihan (Bjorck et al., 2018). Persamaan *Batch Normalization* (Ioffe & Szegedy, 2015) dapat dilihat pada Persamaan 2.22 untuk menghitung *batch mean*, Persamaan 2.23 untuk menghitung *batch variance*, Persamaan 2.24 untuk normalisasi, dan Persamaan 2.25 untuk mendapatkan hasil *Batch Normalization*.

$$\mu_{\mathcal{B}} = \frac{1}{m}\sum_{i=1}^{m} x_i \tag{2.22}$$

$$\sigma_{\mathcal{B}}^2 = \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_{\mathcal{B}})^2 \tag{2.23}$$

$$\widehat{x_i} = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}} \tag{2.24}$$

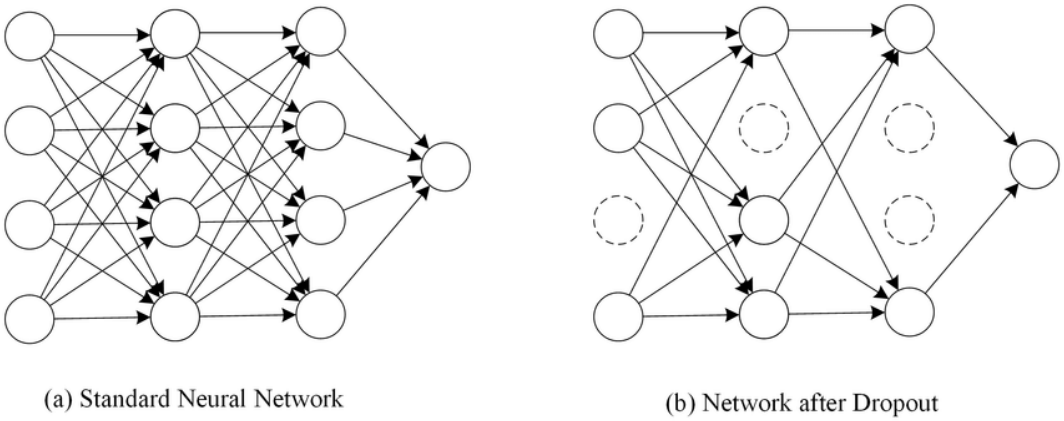
$$\mathrm{BN}_{\gamma,\beta}(x_i) = \gamma\widehat{x_i} + \beta \tag{2.25}$$

dengan

$\mu_{\mathcal{B}}$	:	Rata-rata nilai dalam *batch*
x_i	:	Nilai *input* ke-i dalam satu *batch*
m	:	Jumlah total elemen dalam satu *batch*
$\sigma_{\mathcal{B}}^2$	:	Varians dari *batch*
$\widehat{x_i}$	:	Nilai normalisasi dari elemen x_i
γ	:	Parameter skala
β	:	Parameter geser

Dropout

Dropout merupakan algoritma pelatihan yang bekerja dengan memonaktifkan beberapa neuron secara acak dengan probabilitas p selama proses pelatihan untuk mencegah terjadinya *co-adaption* antar *feature detector* (Baldi & Sadowski, 2013). Penerapan *Dropout Layer* dapat ditunjukkan pada Gambar 2.11.



Gambar 2.11 *Dropout Layer*
Sumber: (Khalifa & Frigui, 2016)

Activation Function

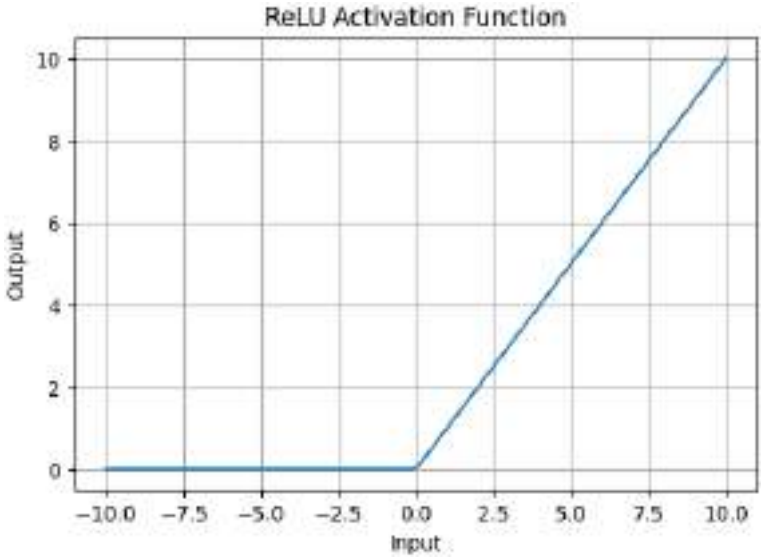
Activation Function digunakan untuk mengubah sinyal *input* menjadi sinyal *output* yang kemudian dijadikan sebagai sinyal *input* di *layer* berikutnya (Sharma et al., 2017). *Activation Function* yang umum digunakan dalam *Neural Network* adalah *Rectified Linear Unit* (ReLu), sigmoid, *Hyperbolic Tangent* (Tanh), dan softmax.

1. ReLu
   ReLu merupakan fungsi aktivasi non linier yang bekerja dengan menonaktifkan sebuah neuron hanya ketika *output* dari transformasi liniernya bernilai nol (Sharma

et al., 2017). Persamaan 2.26 merupakan fungsi aktivasi ReLU (Rasamoelina et al., 2020).

$$ReLU(x) = \max(0, x) \tag{2.26}$$

dengan x sebagai nilai *input* yang masuk ke neuron pada *layer* ReLU.

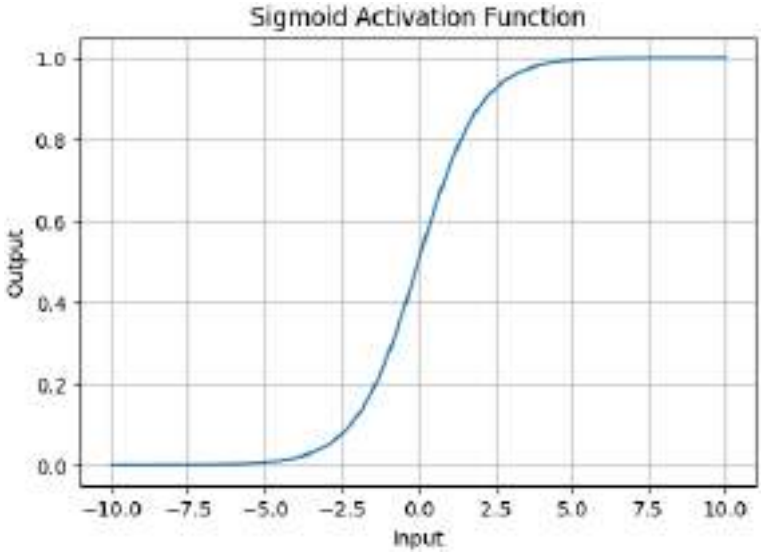


Gambar 2.12 Grafik ReLU *Activation Function*
Sumber: (GeeksforGeeks, 2025)

2. Sigmoid
   Sigmoid merupakan fungsi aktivasi non linier yang bekerja dengan mentransformasikan nilai *input* dari rentang $(-\infty, +\infty)$ menjadi nilai *output* dalam rentang $[0, 1]$. Persamaan 2.27 merupakan fungsi aktivasi sigmoid (Rasamoelina et al., 2020).

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{2.27}$$

dengan x sebagai nilai *input* yang masuk ke neuron pada *layer* sigmoid.

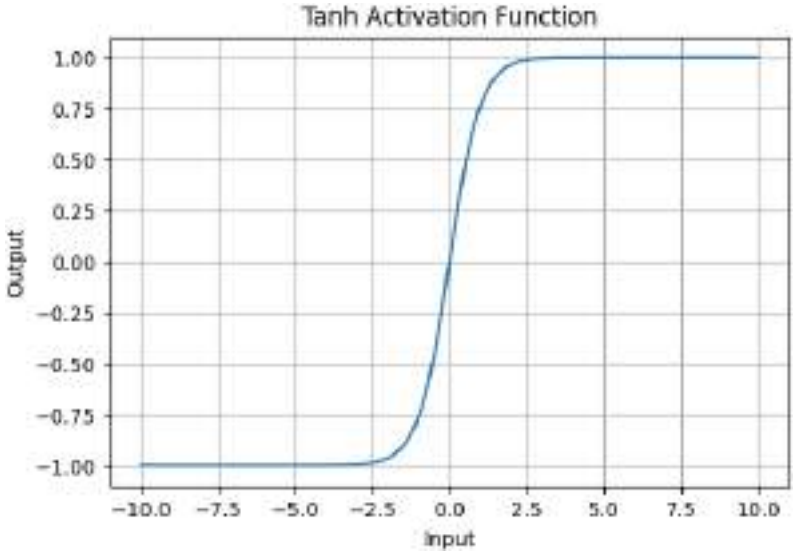


Gambar 2.13 Grafik Sigmoid *Activation Function*
Sumber: (GeeksforGeeks, 2025)

3. Tanh
   Tanh merupakan fungsi aktivasi non linier hasil modifikasi sigmoid yang bekerja dengan mentransformasikan nilai *input* menjadi nilai *output* dalam rentang [-1,1]. Persamaan 2.28 merupakan fungsi aktivasi tanh (Rasamoelina et al., 2020).

$$tanh(x) = \frac{2}{1 + e^{-2x}} - 1 \tag{2.28}$$

   dengan x sebagai nilai *input* yang masuk ke neuron pada *layer* tanh.



Gambar 2.14 Grafik Tanh *Activation Function*
Sumber: (GeeksforGeeks, 2025)

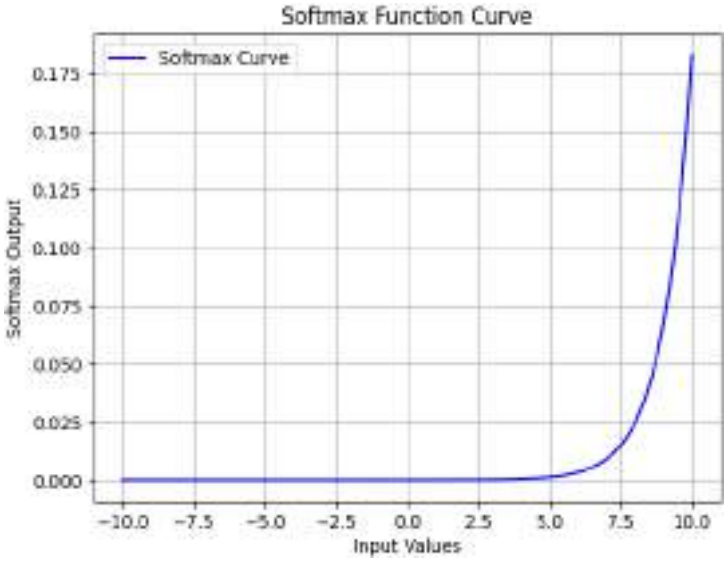
4. Softmax
   Softmax merupakan fungsi aktivasi non linier yang paling umum dipakai untuk

menangani permasalahan *multi-class*. Softmax bekerja dengan mentransformasikan *output Neural Network* dari setiap kelas ke bentuk probabilitas dalam rentang $[0, 1]$ dengan syarat bahwa total probabilitas bernilai 1. Persamaan 2.29 merupakan fungsi aktivasi softmax (Sarno et al., 2023).

$$\psi(\vec{z})_i = \frac{e^{z_i}}{\sum_{j=1}^{k} e^{z_j}} \tag{2.29}$$

dengan

$\vec{z}$	:	Vektor input
e^{z_i}	:	Fungsi eksponensial standar untuk vektor *input*
e^{z_j}	:	Fungsi eksponensial standar untuk vektor *output*
k	:	Jumlah kelas



Gambar 2.15 Grafik Softmax *Activation Function*
Sumber: (GeeksforGeeks, 2025)

Fully Connected Layer

Fully Connected Layer, juga dikenal sebagai *Dense Layer*, adalah lapisan pada jaringan saraf, dengan setiap neuron terhubung dengan setiap neuron dalam lapisan sebelumnya dan sesudahnya. Lapisan ini paling umum digunakan dalam jaringan saraf Multi-Layer Perceptron (MLP) untuk mempelajari hubungan kompleks antara fitur-fitur *input*. Dengan keterhubungan yang kuat, lapisan ini membantu jaringan dalam memahami pola-pola penting pada data *input* (Afinda, 2024).

Loss Function

Loss function digunakan untuk mengevaluasi seberapa baik model memprediksi hasil dibandingkan dengan nilai sebenarnya. Semakin rendah nilai *loss*, kinerja model menjadi semakin baik. Dalam *multi-class classification*, *loss function* yang digunakan adalah

Categorical Cross Entropy (CCE) *Loss* dengan persamaan berikut ini (Rusiecki, 2019).

$$L = -\sum_{i=1}^{k} y_i \log(\hat{y}_i) \tag{2.30}$$

dengan

L : Nilai *loss*
y_i : Label sebenarnya dalam bentuk *one-hot* (1 untuk kelas benar, 0 untuk kelas lainnya)
$\hat{y}_i$: Probabilitas prediksi model untuk kelas ke-i
k : Jumlah kelas

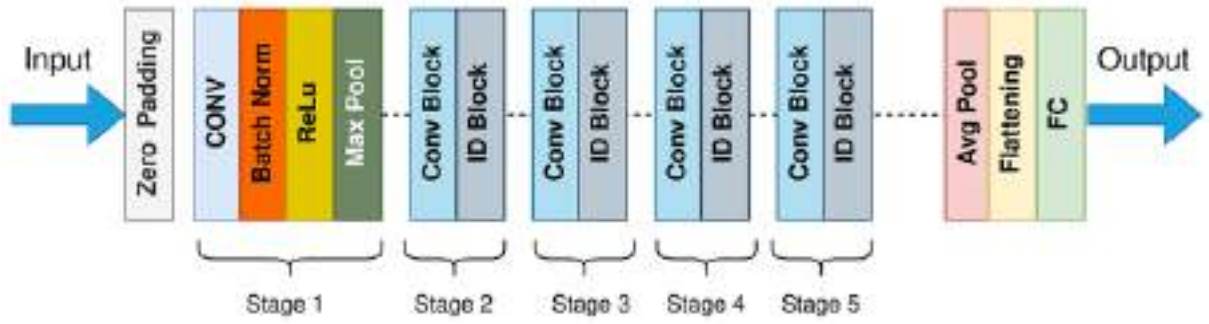
2.8.2 *Convolutional Neural Network* (CNN) dan *Residual Network* (ResNet)

Desain jaringan saraf yang sangat efisien untuk memproses data gambar adalah *Convolutional Neural Networks* (CNN). CNN beroperasi dengan mengekstraksi fitur dari gambar input menggunakan lapisan konvolusi, dan kemudian mengurangi dimensi fitur yang dihasilkan menggunakan lapisan penggabungan. CNN mampu mengenali pola yang signifikan dalam gambar (Ibitoye, 2021), seperti tepi dan tekstur, yang digunakan dalam berbagai aplikasi, seperti kategorisasi gambar dan deteksi objek. Sebagai contoh, Kulkarni (2022) menjelaskan CNN digunakan untuk berbagai tugas klasifikasi gambar dengan mengoptimalkan lapisan konvolusi dan pooling untuk mengekstraksi fitur secara lebih efisien.

Namun, meskipun CNN sangat efektif, jaringan saraf dalam yang sangat dalam dapat mengalami masalah degradasi performa. Untuk mengatasi masalah ini, *Residual Network* (ResNet) dikembangkan. ResNet, yang diperkenalkan oleh He et al. (2016) menggunakan teknik yang disebut *residual learning* dengan mengintegrasikan *skip connections* atau *shortcut connections* pada arsitektur jaringan. Dengan pendekatan ini, sinyal dapat melewati beberapa lapisan jaringan tanpa perubahan yang signifikan, yang mengurangi masalah *vanishing gradient*. Kelebihan utama ResNet adalah kemampuannya untuk melatih jaringan yang sangat dalam tanpa kehilangan akurasi, yang menjadikannya sangat berguna dalam tugas pengenalan gambar dan analisis pola.

Kombinasi CNN dan ResNet juga menunjukkan hasil yang menjanjikan dalam klasifikasi genre musik, yang menjadi fokus Tugas Akhir ini. Setyoko (2024) mengembangkan model *hybrid* yang menggabungkan kekuatan CNN dalam ekstraksi fitur citra dan ResNet untuk meningkatkan akurasi klasifikasi genre musik. Dalam penelitian ini, fusi citra dari *spectrogram* dan *mel-spectrogram* digunakan untuk menangkap informasi temporal dan frekuensi dalam sinyal musik, yang kemudian diproses dengan CNN dan ResNet untuk menghasilkan klasifikasi yang lebih akurat. Penelitian lainnya oleh Zhang (2023) juga menunjukkan bagaimana penggunaan ResNet dapat meningkatkan pengolahan fitur dalam musik dan memberikan hasil klasifikasi genre yang lebih baik.

Secara keseluruhan, penerapan CNN untuk ekstraksi fitur citra dan ResNet untuk mengatasi masalah kedalaman jaringan dapat memberikan keuntungan yang signifikan dalam klasifikasi genre musik berbasis fusi citra *scalogram* dan *spectrogram*, yang merupakan inti dari penelitian ini.



Gambar 2.16 Arsitektur ResNet
Sumber: (Mukherjee, 2022)

2.8.3 *Recurrent Neural Network* (RNN) dan *Bidirectional Recurrent Unit* (Bi-GRU)

Jenis jaringan saraf tiruan yang disebut *Recurrent Neural Network* (RNN) dibuat untuk memproses data berurutan dengan mempertahankan hubungan temporal antara potongan data. Tidak seperti jaringan saraf *feedforward* biasa, RNN memiliki kemampuan unik untuk menyimpan dan memanfaatkan informasi dari langkah sebelumnya melalui memori *internal*-nya, sehingga mampu memproses data yang bersifat sekuensial (Mienye et al., 2024). RNN memiliki kemampuan untuk memproses data berurutan, seperti teks, sinyal suara, dan musik, menjadikannya sangat cocok untuk tugas klasifikasi genre musik berbasis fitur temporal. Dalam klasifikasi genre musik, RNN bekerja dengan mengolah representasi spektrum audio dalam bentuk citra *spectrogram* atau *scalogram* yang telah diekstrak sebelumnya menggunakan CNN atau ResNet. Namun, RNN memiliki beberapa keterbatasan, seperti masalah *vanishing gradient* yang menyebabkan hilangnya informasi penting dalam urutan yang panjang (Ren, 2025). Untuk mengatasi masalah ini, dikembangkan varian RNN yang lebih canggih, seperti *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU).

GRU adalah jenis jaringan saraf rekuren yang dikembangkan sebagai alternatif dari LSTM dengan struktur yang lebih sederhana namun tetap mampu menangani masalah *vanishing gradient* (Chung et al., 2014). GRU memiliki dua gerbang utama, yaitu:

1. *Update Gate*, yang mengontrol seberapa banyak informasi dari langkah sebelumnya akan dibawa ke langkah saat ini.

2. *Reset Gate*, yang menentukan seberapa banyak informasi dari langkah sebelumnya yang akan dilupakan.

GRU memiliki performa yang lebih baik dibandingkan LSTM karena jumlah parameternya lebih sedikit, sehingga lebih efisien untuk digunakan dalam tugas klasifikasi genre musik berbasis data audio (Chung et al., 2014).

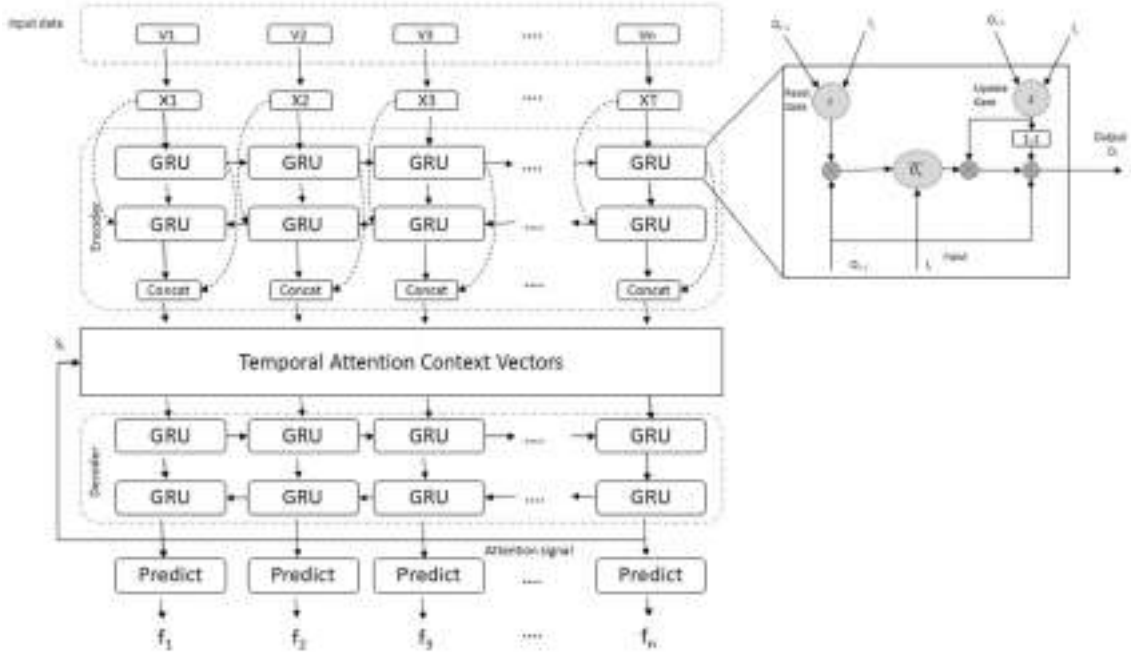
Bidirectional Gated Recurrent Unit (Bi-GRU) adalah pengembangan dari GRU yang memproses data dalam dua arah, yaitu maju (*forward*) dan mundur (*reverse*). Dengan pendekatan ini, Bi-GRU dapat menangkap informasi dari konteks sebelumnya dan setelahnya dalam sebuah urutan data, sehingga memberikan pemahaman yang lebih komprehensif tentang pola dalam sinyal audio (Yadav et al., 2023).

Dalam klasifikasi genre musik, Bi-GRU dapat digunakan untuk menangani informasi temporal yang kompleks dalam citra spektrum audio. Studi oleh Zhang (2023)

menunjukkan bahwa kombinasi ResNet dan Bi-GRU menghasilkan peningkatan akurasi dalam klasifikasi genre musik dibandingkan dengan metode berbasis CNN, Bi-GRU, atau ResNet saja.

Penggunaan RNN dan Bi-GRU dalam klasifikasi genre musik biasanya dikombinasikan dengan CNN untuk menghasilkan model hibrida yang mampu menangani fitur spasial dan temporal secara bersamaan. CNN berfungsi untuk mengekstraksi fitur dari citra *scalogram* atau *spectrogram*, sedangkan Bi-GRU memproses urutan fitur yang telah diekstrak untuk mempertimbangkan hubungan temporalnya.

Penelitian oleh Ghosh and Riad (2022) menunjukkan bahwa model CNN-BiGRU dapat mencapai akurasi lebih tinggi dalam klasifikasi genre musik dibandingkan dengan model berbasis CNN saja. Penggunaan Bi-GRU memungkinkan model untuk lebih memahami konteks temporal dalam musik, yang sangat penting untuk membedakan genre berdasarkan pola ritme dan harmoni.



Gambar 2.17 Arsitektur Bi-GRU
Sumber: (Balti et al., 2024)

2.9 Resolusi Waktu dan Frekuensi Transfrormasi

2.9.1 Prinsip Ketidakpastian

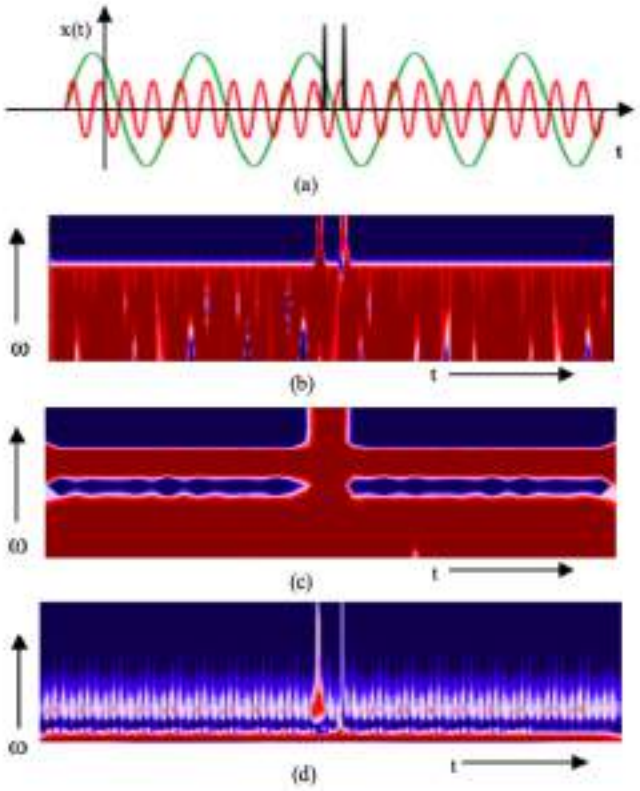
Untuk mencapai analisis sinyal yang komprehensif, resolusi waktu dan resolusi frekuensi harus dimaksimalkan. Hal ini berarti menangkap variasi sinyal dengan pergeseran minimal dalam waktu dan frekuensi. Namun, prinsip ketidakpastian (Phan, 2024) memberlakukan batasan pada pertukaran antara resolusi waktu dan frekuensi, seperti yang dijelaskan dalam (2.5). Memanfaatkan selang waktu yang singkat (Δt yang bernilai kecil) memungkinkan resolusi waktu yang tinggi dalam STFT atau WT, tetapi menghasilkan resolusi frekuensi yang buruk ($\Delta\omega$ yang bernilai besar). Sebaliknya, menggunakan selang waktu yang besar menghasilkan resolusi waktu yang buruk tetapi

meningkatkan resolusi frekuensi.

$$\Delta t,\ \Delta\omega \geq \frac{1}{2} \tag{2.31}$$

2.9.2 Multi Resolusi

Gambar 2.18 memberikan perbandingan visual dari WT melalui *scalogram* dan STFT melalui *spectrogram*. Seperti yang digambarkan, sinyal waktu $x(t)$ berisi dua komponen periodik dan dua impuls Dirac, seperti yang ditunjukkan pada Gambar 2.18(a). *Spectrogram* $x(t)$ dengan jendela pendek, diilustrasikan pada Gambar 2.18(b), menawarkan resolusi waktu yang tinggi tetapi resolusi frekuensi yang rendah. Akibatnya, dua impuls yang berbeda terlihat jelas di bagian tengah, sedangkan dua komponen pada sumbu frekuensi digabungkan. Gambar 2.18(c) menunjukkan *spectrogram* dengan jendela yang panjang, yang memberikan resolusi waktu yang rendah tetapi resolusi frekuensi yang tinggi. Hal ini menghasilkan dua garis horizontal merah yang terpisah dengan jelas yang menunjukkan komponen frekuensi, tetapi kedua impuls digabungkan di bagian tengah. Sebaliknya, *scalogram* pada Gambar 2.18(d) secara efektif merepresentasikan kedua impuls yang berbeda dan dua garis horizontal merah yang terpisah. Kemampuan *scalogram* ini disebabkan oleh fitur multiresolusi dari WT, yang mencapai resolusi waktu yang tinggi pada frekuensi tinggi dan resolusi frekuensi tinggi pada frekuensi rendah.



Gambar 2.18 Resolusi Waktu dan Frekuensi *Spectrogram* dan *Scalogram*
Sumber: (Phan, 2024)

2.10 *Confusion Matrix* dan Metrik Evaluasi

Confusion Matrix adalah matriks berbentuk persegi dengan ukuran $N \times N$, dengan N adalah jumlah *output classes*, yang di dalam penelitian ini merujuk kepada banyaknya genre musik yang akan diprediksi. Setiap baris matriks mewakili jumlah *instance* dari kelas yang diprediksi, sedangkan setiap kolom mewakili jumlah *instance* dari kelas sebenarnya. Dengan demikian, matriks ini memberikan rincian akurasi dan kesalahan prediksi yang dibuat oleh model klasifikasi, baik untuk klasifikasi biner (dua kelas) maupun multikelas (lebih dari dua kelas) (Patro & Patra, 2015). *Confusion matrix* membantu mengevaluasi kinerja model klasifikasi apa yang sudah benar dan jenis kesalahan apa yang mungkin terjadi. Metrik yang dihasilkan dari matriks ini juga membantu menentukan langkah terbaik untuk meningkatkan performa model. Karena *Confusion Matrix* hanya bisa dibuat untuk data yang sudah memiliki nilai *output* yang diketahui, penggunaannya terbatas pada metode *supervised learning*.

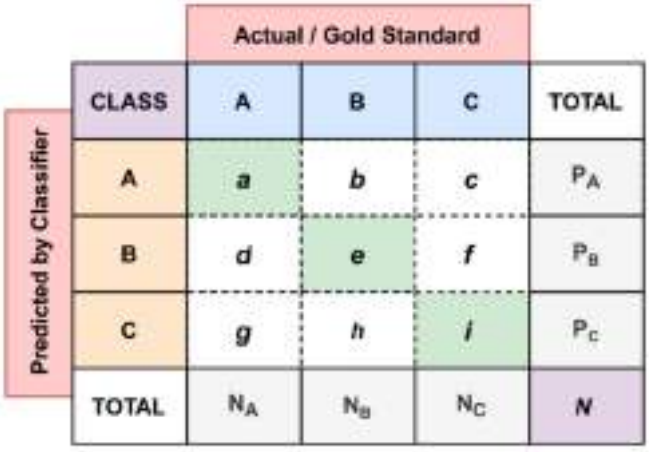
Sebuah algoritma klasifikasi berfungsi untuk menentukan apakah suatu peristiwa tertentu terjadi atau tidak. Hasil prediksi dari algoritma ini hanya memiliki dua kemungkinan nilai, yaitu positif yang berarti peristiwa tersebut terjadi, dan negatif yang berarti peristiwa tersebut tidak terjadi. Dalam proses evaluasi model *deep learning*, terdapat dua komponen utama yang dibandingkan, yaitu label aktual yang merupakan jawaban benar yang sudah diketahui sebelumnya dari data uji, dan label prediksi yang merupakan hasil keluaran dari model. Perbandingan antara kedua komponen ini kemudian disajikan dalam bentuk *confusion matrix* yang memperlihatkan struktur umum seperti yang tercantum pada Gambar 2.19. *Confusion matrix* ini sangat penting karena dapat membantu untuk melihat tingkat akurasi prediksi model, letak kesalahan yang sering terjadi, serta mengevaluasi dan meningkatkan performa model secara keseluruhan.

		Actual Values	
		Positive	**Negative**
Predicted Values	**Positive**	True Positive (TP)	False Positive (Type I error)
	Negative	False Negative (Type II error)	True Negative

Gambar 2.19 *Confusion Matrix*
Sumber: (Sathyanarayanan & Tantri, 2024)

True Positive (TP) adalah kondisi ketika baik nilai aktual maupun nilai prediksi bernilai positif. *False Positive* (FP) adalah kondisi ketika nilai aktualnya adalah negatif, tapi model memprediksinya sebagai nilai positif. Sebaliknya, *False Negative* (FN) adalah kondisi ketika model menghasilkan prediksi sebagai nilai negatif sedangkan nilai aktualnya adalah positif. Untuk kondisi yang terakhir, *True Negative* (TN) adalah kondisi ketika baik nilai aktual maupun nilai prediksi bernilai negatif.

Dalam kasus klasifikasi *multiclass*, metrik yang didefinisikan untuk klasifikasi biner seperti yang tertera pada Gambar 2.19 tidak berlaku sepenuhnya, karena karakterisasi TP, TN, FP, dan FN tidak berlaku dalam kasus ini. Sebagai gantinya, analisis dapat difokuskan pada kelas tertentu. Sekelompok metrik untuk setiap kelas dapat didefinisikan berdasarkan pendekatan ini. Lalu dengan menggabungkan metrik-metrik ini secara tepat, maka bisa dihasilkan metrik untuk seluruh *confusion matrix* (Markoulidakis et al., 2021). Sebagai contoh, diberikan *confusion matrix* berukuran 3×3 sebagai berikut.



Gambar 2.20 *Confusion Matrix Multiclass*
Sumber: (Bhardwaj et al., 2022)

dengan total sampel di kelas A, B, dan C adalah N_A, N_B, dan N_C, sedangkan total prediksi di kelas A, B, dan C adalah P_A, P_B, dan P_C. Selain itu, N menandakan total keseluruhan sampel, yaitu:

$$\text{total sampel } (N) = N_A + N_B + N_C = P_A + P_B + P_C \tag{2.32}$$

dengan rumus perhitungan untuk tiap kelas sebagai berikut (Golchafun, 2024).

$$\begin{aligned}
&TP(A) = a && TP(B) = e && TP(C) = i \\
&FN(A) = d + g && FN(B) = b + h && FN(C) = c + f \\
&FP(A) = b + c && FP(B) = d + f && FP(C) = g + h \\
&TN(A) = e + f + h + i && TN(B) = a + c + g + i && TN(C) = a + b + d + e.
\end{aligned}$$

Setelah *confusion matrix* didapatkan, tahap selanjutnya adalah melakukan pengujian dengan menghitung nilai metrik evaluasi untuk mengukur tingkat performansi model (Hilmiaji et al., 2021; Erbani et al., 2024).

1. Akurasi
   Akurasi adalah jumlah data yang diprediksi dengan benar dari semua data yang ada.

$$accuracy\ (acc) = \frac{TP + TN}{TP + FN + FP + TN} \tag{2.33}$$

2. Presisi
   Presisi digunakan untuk mengukur seberapa akurat prediksi kelas positif yang dibuat oleh model. Artinya, ketika suatu model memprediksi suatu data sebagai kelas positif, presisi menghitung seberapa sering prediksi tersebut benar.

$$precision\ (P) = \frac{TP}{TP + FP} \tag{2.34}$$

3. *Recall*

Recall digunakan untuk mengukur kemampuan model untuk menemukan seluruh nilai positif dalam suatu dataset.

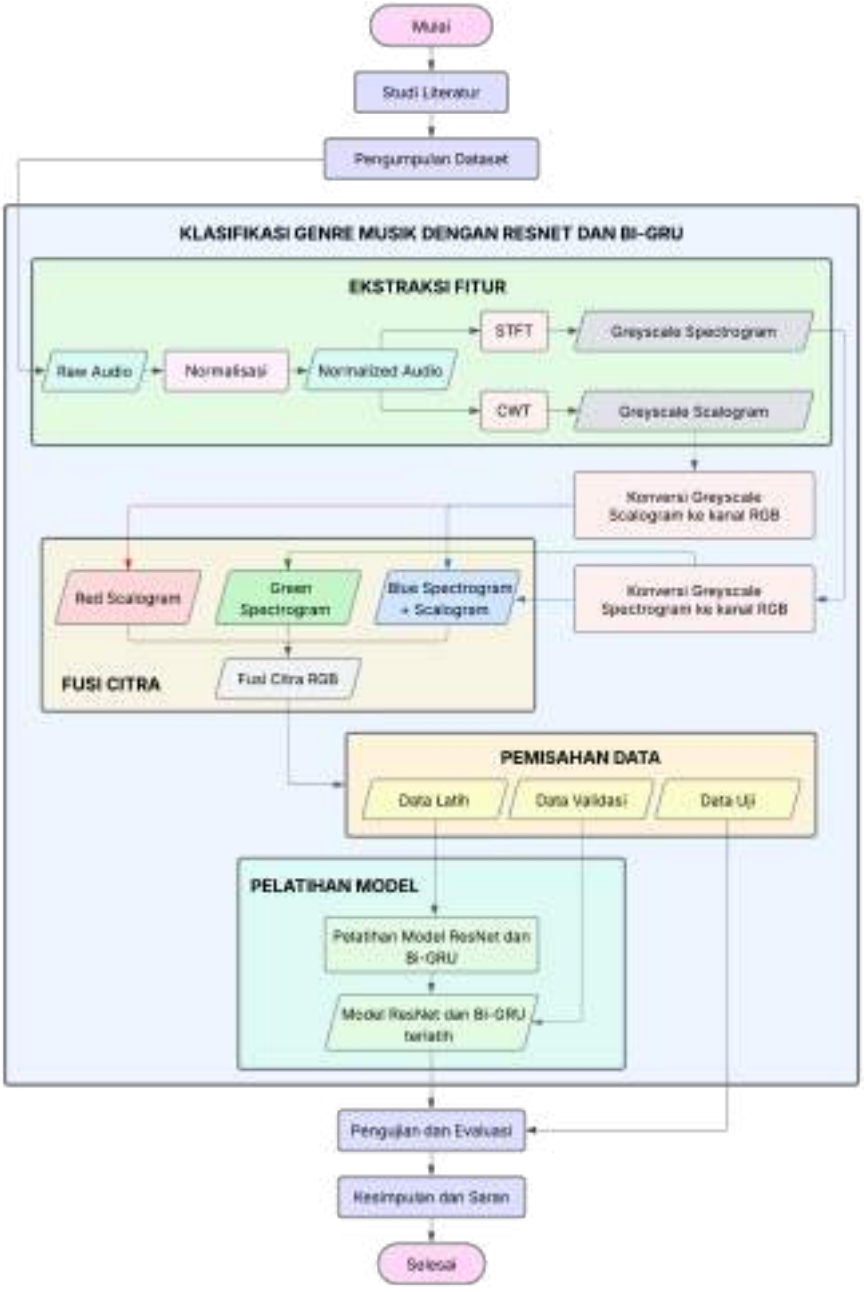
$$recall\ (R) = \frac{TP}{TP + FN} \tag{2.35}$$

4. F1-*score*
   F1-*score* digunakan untuk mengharmonisasikan presisi dan *recall* agar model tidak fokus pada satu metrik saja (Sathyanarayanan & Tantri, 2024).

$$\text{F1} - score = 2 \times \frac{precision \times recall}{precision + recall} \tag{2.36}$$

BAB III
METODOLOGI

Bab ini merupakan uraian dari langkah-langkah yang dipergunakan pada proses penelitian mengenai penerapan kombinasi metode ResNet dan Bi-GRU untuk klasifikasi genre musik berbasis fusi citra *scalogram-spectrogram* seperti yang dapat dilihat pada Gambar 3.1.



Gambar 3.1 *Flowchart* Penelitian

3.1 Studi Literatur

Pada tahap pertama ini dilakukan pengumpulan berbagai informasi sebagai bahan referensi yang menunjang proses penelitian. Studi literatur dilakukan pada jurnal terkait penelitian tentang klasifikasi genre musik dengan *deep learning*, penggunaan *scalogram* dan *spectrogram* dalam pengolahan audio visual. Studi literatur ini bertujuan untuk memahami konsep yang diperlukan untuk penelitian.

3.2 Pengumpulan Dataset

Pada penelitian ini, penulis menggunakan data sekunder dan data primer sebagai objek penelitian. Dataset GTZAN, yang dibuat oleh Tzanetakis dan Cook (Tzanetakis & Cook, 2002) yang dapat diakses pada tautan www.kaggle.com/DatasetSekunder, digunakan sebagai dataset sekunder di penelitian Tugas Akhir ini. Dataset ini berisi total 1000 file audio dengan 10 genre yang berbeda, yaitu *blues*, *classical*, *country*, *disco*, *hiphop*, *jazz*, *metal*, *pop*, *reggae*, dan, *rock*, di mana setiap genre berisi 100 file audio. Selain itu, digunakan pula dataset primer sebagai dataset tambahan yang dikumpulkan langsung oleh penulis berupa 50 lagu dengan 10 genre yang serupa dengan yang ada pada dataset GTZAN. Untuk mempermudah proses pengunduhan dan pengelolaan data, penulis terlebih dahulu mengelompokkan lagu-lagu tersebut ke dalam *playlist YouTube* yang dapat diakses pada tautan youtube.com/DatasetPrimer.

3.3 Pembuatan Program

Bagian ini menjelaskan rangkaian proses yang dilakukan dalam penelitian untuk mempersiapkan data serta melatih dan mengevaluasi model ResNet dan Bi-GRU. Proses ini mencakup tahapan pengolahan awal data audio, pembuatan citra *scalogram-spectrogram*, fusi citra, pembagian data, hingga implementasi model. Seluruh prosedur dirancang untuk memastikan model dapat mengenali pola dengan baik dan menggeneralisasi secara optimal pada data baru.

3.3.1 Normalisasi Audio

Normalisasi audio dilakukan dengan menyeragamkan amplitudo seluruh dataset ke rentang (-1,1). Selain itu, *file* dengan audio yang rusak maupun memiliki durasi terlalu pendek dihapus untuk menjaga kualitas data. Proses ini bertujuan untuk mempertahankan konsistensi dataset sehingga proses ekstraksi fitur berikutnya menjadi lebih stabil.

3.3.2 Ekstraksi Fitur

Ekstraksi fitur dilakukan untuk mendapatkan citra *scalogram* dan *spectogram*. *Scalogram* diperoleh dari ekstraksi fitur menggunakan *Continuous Wavelet Transform* (CWT), sedangkan *spectrogram* diperoleh dari ekstraksi fitur menggunakan *Short-Time Fourier Transform* (STFT). Kedua citra ini digunakan sebagai representasi visual sinyal audio pada tahap pemodelan.

3.3.3 *Cropping Image*

Proses *cropping image* adalah proses pemotongan citra *scalogram* dan *spectrogram* hasil ekstraksi fitur menjadi 10 bagian sehingga tiap citra merepresentasikan audio dengan durasi 3 detik. Langkah ini dilakukan untuk memastikan setiap citra memiliki informasi waktu–frekuensi yang cukup agar model dapat mengenali pola dengan lebih baik.

3.3.4 Fusi Citra

Proses fusi citra dilakukan dengan memfusikan 3 citra menjadi 1 citra RGB. Pada tahap ini, *grayscale scalogram* dikonversi terlebih dahulu menjadi citra berwarna merah dengan memetakan nilai intensitas *grayscale* ke kanal warna merah, sementara kanal hijau dan biru diatur bernilai nol untuk mewakili kanal R. Sementara itu, *grayscale spectrogram* dikonversi menjadi citra berwarna hijau dengan memetakan nilai intensitas *grayscale* ke kanal warna hijau, sementara kanal merah dan biru diatur bernilai nol untuk mewakili kanal G. Selain itu, hasil fusi keduanya dikonversi menjadi citra berwarna biru dengan memetakan nilai intensitas *grayscale* ke kanal warna biru, sementara kanal merah dan hijau diatur bernilai nol untuk mewakili kanal B. Tujuannya supaya model dapat melihat kombinasi pola waktu–frekuensi yang lebih kaya dalam satu citra.

3.3.5 *Data Splitting*

Setelah didapatkan citra yang difusikan, citra tersebut dibagi menjadi data latih, data validasi, dan data uji. Dari total dataset GTZAN yang telah dinormalisasi, 70% dari dataset tersebut digunakan sebagai data latih, 20% digunakan sebagai data validasi, dan 10% digunakan sebagai data uji. Sementara itu, untuk dataset primer, 10% data digunakan sebagai data latih, 20% digunakan sebagai data validasi, dan 70% digunakan sebagai data uji. Data latih digunakan untuk melatih kombinasi model ResNet dan Bi-GRU, data validasi digunakan untuk melakukan validasi terhadap kombinasi model ResNet dan Bi-GRU, sedangkan data uji digunakan untuk menguji kombinasi model ResNet dan Bi-GRU.

3.3.6 Implementasi Kombinasi Model *Residual Network* (ResNet) dan *Bidirectional Gated Recurrent Unit* (Bi-GRU)

Fokus utama penelitian ini adalah menggabungkan kekuatan representasi fitur spasial dari *scalogram* dan *spectrogram* dengan kemampuan penangkapan pola temporal menggunakan arsitektur kombinasi ResNet dan Bi-GRU. Selanjutnya, kombinasi ini akan disebut sebagai ResNet-BiGRU. Model ini dirancang dengan cara eksploratif untuk memperoleh konfigurasi paling efektif dalam melakukan klasifikasi genre musik berbasis citra hasil fusi.

Tahap awal model menggunakan ResNet sebagai *feature extractor* utama untuk mengekstraksi fitur spasial dari citra hasil fusi. *Output* dari tahap ResNet kemudian di-*flatten* menjadi bentuk sekuensial agar dapat diproses oleh lapisan Bi-GRU. Tahap Bi-GRU bertujuan untuk menangkap hubungan temporal semu antar fitur citra hasil fusi yang dihasilkan ResNet, sehingga model memperoleh pemahaman yang lebih mendalam terhadap pola dalam data.

Model dilatih dan proses pelatihannya dipantau menggunakan data validasi guna menghindari *overfitting*. Proses pelatihan dilakukan hingga model mencapai performa yang optimal untuk mengukur kinerja model terhadap data latih dan validasi. Jika hasil evaluasi belum optimal, dilakukan *fine-tuning* dengan mengatur ulang *hyperparameter* untuk meningkatkan akurasi serta mengurangi risiko *overfitting*. Setelah model mencapai kinerja terbaik, model yang telah terlatih disimpan dalam format yang sesuai agar dapat digunakan dalam tahap berikutnya. Model ResNet-BiGRU ini diharapkan dapat memperkuat klasifikasi genre musik dengan menggabungkan fitur spasial dan temporal, sehingga menghasilkan sistem klasifikasi yang lebih akurat dan andal.

3.4 Pengujian dan Simulasi

Pada tahap ini, model dipelajari untuk mengevaluasi bagaimana model tersebut berfungsi dalam melakukan klasifikasi genre musik dengan menggunakan metode fusi citra *scalogram-spectrogram*. Pengujian mencakup prediksi data uji dan analisis pengukuran kinerja menggunakan *Confusion Matrix*. Hasil akhir diperiksa untuk mengetahui kinerja model dalam mengklasifikasikan genre musik. Apabila masih memerlukan perbaikan, dilakukan analisis perbaikan seperti apa yang diperlukan. Untuk tahap awal, pengujian dilakukan menggunakan dataset sekunder. Namun jika model sudah dapat mengklasifikasikan genre musik dengan baik, maka dilakukan uji coba menggunakan dataset primer.

3.5 Kesimpulan dan Saran

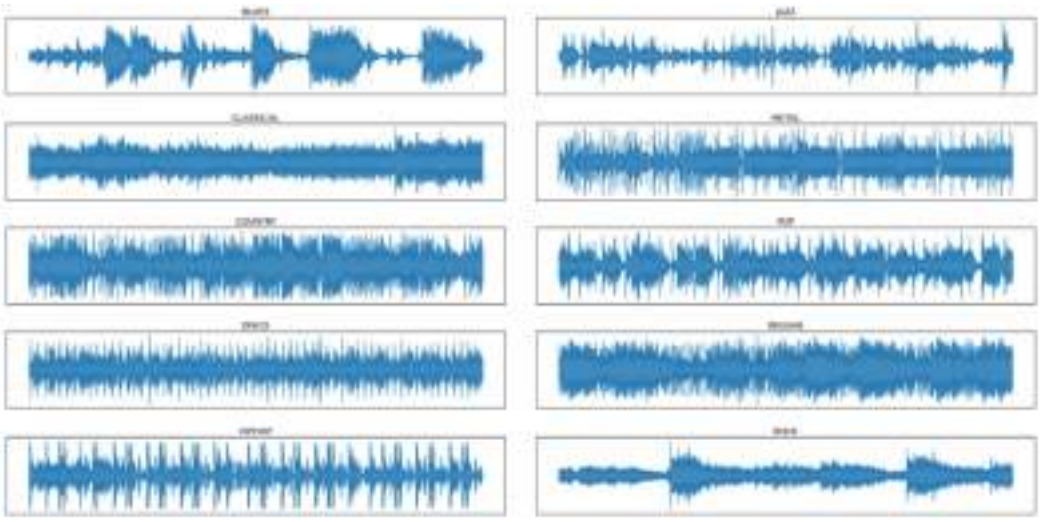
Pada tahap ini, dilakukan pengambilan kesimpulan berdasarkan hasil evaluasi dan pengujian yang telah dilakukan sebelumnya. Selain itu, dilakukan pula pemberian saran sebagai acuan untuk penelitian selanjutnya.

BAB IV
PERANCANGAN DAN IMPLEMENTASI SISTEM

Pada bab ini dijelaskan terkait pengambilan data, perancangan program, perancangan hasil klasifikasi, dan implementasi program.

4.1 Pengambilan Data

Pengambilan data pada penelitian ini melalui dua tahap, yaitu penggunaan dataset sekunder sebagai dataset utama serta dataset primer sebagai dataset tambahan yang dikumpulkan langsung oleh penulis. Dataset sekunder yang digunakan adalah dataset "GTZAN *Dataset - Music Genre Classification*", yang berisi 1.000 file audio dengan format `.wav` dengan durasi 30 detik per lagu dan terdiri dari 10 genre musik, yaitu *blues*, *classical*, *country*, *disco*, *hiphop*, *jazz*, *metal*, *pop*, *reggae*, dan, *rock*, di mana setiap genre berisi 100 file audio yang dapat diakses pada tautan www.kaggle.com/DatasetSekunder. Gambar 4.1 merepresentasikan beberapa contoh *waveforms* dari dataset GTZAN untuk masing-masing genre.



Gambar 4.1 Contoh *Waveforms* Dataset GTZAN untuk Masing-Masing Genre

Selain menggunakan dataset GTZAN sebagai data utama, penulis juga menambahkan dataset primer berupa 50 lagu yang diunduh dari *platform YouTube*. Lagu-lagu tersebut dipilih berdasarkan genre yang serupa dengan yang terdapat pada dataset GTZAN, sehingga tetap konsisten dengan tujuan penelitian. Seluruh lagu tersebut kemudian diunduh dalam format `.mp3`. Gambar 4.2 merepresentasikan beberapa contoh *waveforms* dari dataset primer untuk masing-masing genre.



Gambar 4.2 Contoh *Waveforms* Dataset Primer untuk Masing-Masing Genre

4.2 Perancangan Program

Pada subbab ini dijelaskan tentang rancangan bagaimana program dijalankan.

4.2.1 Normalisasi Audio

Pada saat pengumpulan dataset, tidak ditemukan keterangan bahwa dataset GTZAN telah melalui tahap dinormalisasi. Oleh karena itu, perlu dilakukan normalisasi untuk menyeragamkan amplitudo sinyal audio ke rentang $(-1, 1)$. Selain itu, pada tahap ini juga dilakukan penghapusan audio dengan durasi terlalu pendek dan juga audio yang rusak. Dataset primer juga melalui tahap normalisasi audio.

Algoritma 4.1 Normalisasi Audio

Input: sinyal audio raw
Output: sinyal audio normal
Proses:
Fungsi *normalize(input_folder, output_folder)*
1. Membaca setiap audio di *input_folder*
2. y_normalized = librosa.util.normalize(y)
3. *save* y_normalized

Sebagai contoh diberikan sinyal x yang telah dinormalisasi ke rentang $(-1, 1)$ dengan data sebagai berikut:

$$x = [-0.72, 0.18, -0.43, 0.95, -0.27, 0.66, -0.51, 0.24].$$

Kemudian dilakukan perhitungan untuk menentukan amplitudo maksimum dari sinyal x_n seperti yang telah tertera pada Persamaan 2.1, yaitu

$$\max(|x|) = 0.95$$

sehingga didapatkan

$$x^{norm} = \frac{x}{0.95} = \frac{[-0.72, 0.18, -0.43, 0.95, -0.27, 0.66, -0.51, 0.24]}{0.95}.$$

Hasil normalisasi sinyal tersebut adalah sebagai berikut.

$$x^{norm} = [-0.76, 0.19, -0.45, 1.00, -0.29, 0.69, -0.54, 0.25].$$

4.2.2 Perancangan Tahap Esktraksi Fitur

Pada tahap ini, dilakukan ekstraksi fitur untuk mengubah data sinyal audio menjadi data citra *grayscale spectrogram* dan juga *grayscale scalogram* berukuran 2240×224 piksel.

Data sinyal audio diekstraksi fiturnya menggunakan CWT untuk mendapatkan *power* pada setiap waktu dan skala frekuensi.

Algoritma 4.2 *CWT*

Input: sinyal, sr, nNotes, wavelet
Output: power, times, scales, freq
Proses:
Fungsi *cwt(sinyal audio, sr, nNotes, wavelet)*
1. Membuat matriks kosong dengan nama *coef*
2. Menghitung panjang sinyal
3. Menghitung *sampling period*
4. Membuat *array timestep*
5. Membangun *array scales*
6. for setiap skala di scales do:
7. wavelet_scaled = scale_wavelet(wavelet, skala)
8. coef_per_scale = convolve(sinyal, wavelet_scaled)
9. coef.append(coef_per_scale)
10. power = abs($coef$)^2
11. Konversi power ke skala desibel

Sumber: (Paramarta, 2023)

convolve pada Algoritma 4.2 adalah konvolusi 1 dimensi dari sinyal dengan kernel *mother wavelet*. Sebagai contoh diberikan sinyal x dengan panjang 8 yang diberikan perhitungan konvolusi 1 dimensi dengan *wavelet morlet* skala 1, 2, dan 3. Diberikan

$$x = [-0.72, 0.18, -0.43, 0.95, -0.27, 0.66, -0.51, 0.24].$$

Karena contoh nilai x berupa bilangan diskrit, maka dibentuklah kernel *mother wavelet* diskrit dengan persamaan berikut.

$$\psi_a[t] = \psi\left(\frac{t}{a}\right)$$

Di mana nilai t adalah nilai di sekitar 0. Diambil contoh untuk perhitungan untuk $a = 1$ dengan $t = -1, 0, 1$ sebagai berikut.

$$\psi_1[-1] = \psi_1\left(\frac{-1}{1}\right) = \psi_1(-1) = e^{-\frac{(-1)^2}{2}} \cos(5(-1)) \approx 0.6042$$
$$\psi_1[0] = \psi_1\left(\frac{0}{1}\right) = \psi_1(0) = e^{-\frac{(0)^2}{2}} \cos(5(0)) = 1.0000$$
$$\psi_1[1] = \psi_1\left(\frac{1}{1}\right) = \psi_1(1) = e^{-\frac{(1)^2}{2}} \cos(5(1)) \approx 0.6042$$

Sehingga

$$\psi_1(t) \approx \begin{bmatrix} 0.6042 \\ 1.0000 \\ 0.6042 \end{bmatrix}.$$

Dengan melakukan tahap perhitungan yang sama, diterapkan juga untuk $a = 2$ dengan $t = -2, -1, 0, 1, 2$ sehingga didapatkan

$$\psi_2\left(\frac{t}{2}\right) \approx \begin{bmatrix} 0.6042 \\ 0.8817 \\ 1.0000 \\ 0.8817 \\ 0.6042 \end{bmatrix}$$

dan untuk $a = 3$ dengan $t = -3, -2, -1, 0, 1, 2, 3$ didapatkan

$$\psi_3\left(\frac{t}{3}\right) \approx \begin{bmatrix} 0.6042 \\ 0.7826 \\ 0.9560 \\ 1.0000 \\ 0.9560 \\ 0.7826 \\ 0.6042 \end{bmatrix}$$

Selanjutnya dilakukan CWT sesuai dengan Persamaan 2.2. Pergeseran dilakukan sebanyak 8 kali, sehingga $b = 0, 1, 2, 3, 4, 5, 6, 7$. Untuk CWT dengan $a = 1$ dan $b = 0$

$$X_{CWT}(1, 0) = \frac{1}{\sqrt{1}}((0)(0.6042) + (-0.72)(1.0000) + (0.18)(0.6042)) \approx -0.6112$$

CWT dilakukan hingga $b = 7$, sehingga didapatkan untuk $a = 1$ dengan pergeseran b

$$X_{CWT}(1, b) \approx \begin{bmatrix} -0.6112 \\ -0.5148 \\ 0.2527 \\ 0.5271 \\ 0.7028 \\ 0.1887 \\ 0.0338 \\ -0.0681 \end{bmatrix}.$$

Selanjutnya, CWT dilakukan untuk $a = 2$ dan pergeseran b dengan cara perhitungan

yang sama sehingga didapatkan

$$X_{CWT}(2,b) \approx \begin{bmatrix} -0.5806 \\ -0.1838 \\ -0.0225 \\ 0.5942 \\ 0.4112 \\ 0.4888 \\ 0.0851 \\ 0.1337 \end{bmatrix}$$

dan untuk $a = 3$ dan pergeseran b

$$X_{CWT}(3,b) \approx \begin{bmatrix} -0.1792 \\ -0.1958 \\ -0.2939 \\ 0.1126 \\ 0.4545 \\ 0.3382 \\ 0.4117 \\ 0.0611 \end{bmatrix}$$

Sehingga didapatkan matriks koefisien CWT

$$X_{CWT}(a,b) = \begin{bmatrix} -0.6112 & -0.5806 & -0.1792 \\ -0.5148 & -0.1838 & -0.1958 \\ 0.2527 & -0.0225 & -0.2939 \\ 0.5271 & 0.5942 & 0.1126 \\ 0.7028 & 0.4112 & 0.4545 \\ 0.1887 & 0.4888 & 0.3382 \\ 0.0338 & 0.0851 & 0.4117 \\ -0.0681 & 0.1337 & 0.0611 \end{bmatrix}$$

Selanjutnya, *scalogram* dihitung dengan menghitung magnitudo dari hasil CWT yang direpresentasikan sebagai *power*.

$$\text{power} = \begin{bmatrix} \left(\sqrt{(-0.6112)^2}\right)^2 & \left(\sqrt{(-0.5806)^2}\right)^2 & \left(\sqrt{(-0.1792)^2}\right)^2 \\ \left(\sqrt{(-0.5148)^2}\right)^2 & \left(\sqrt{(-0.1838)^2}\right)^2 & \left(\sqrt{(-0.1958)^2}\right)^2 \\ \left(\sqrt{(0.2527)^2}\right)^2 & \left(\sqrt{(-0.0225)^2}\right)^2 & \left(\sqrt{(-0.2939)^2}\right)^2 \\ \left(\sqrt{(0.5271)^2}\right)^2 & \left(\sqrt{(0.5942)^2}\right)^2 & \left(\sqrt{(0.1126)^2}\right)^2 \\ \left(\sqrt{(0.7028)^2}\right)^2 & \left(\sqrt{(0.4112)^2}\right)^2 & \left(\sqrt{(0.4545)^2}\right)^2 \\ \left(\sqrt{(0.1887)^2}\right)^2 & \left(\sqrt{(0.4888)^2}\right)^2 & \left(\sqrt{(0.3382)^2}\right)^2 \\ \left(\sqrt{(0.0338)^2}\right)^2 & \left(\sqrt{(0.0851)^2}\right)^2 & \left(\sqrt{(0.4117)^2}\right)^2 \\ \left(\sqrt{(-0.0681)^2}\right)^2 & \left(\sqrt{(0.1337)^2}\right)^2 & \left(\sqrt{(0.0611)^2}\right)^2 \end{bmatrix}$$

$$\text{power} \approx \begin{bmatrix} 0.3736 & 0.3371 & 0.0321 \\ 0.2650 & 0.0338 & 0.0383 \\ 0.0639 & 0.0005 & 0.0864 \\ 0.2778 & 0.3531 & 0.0127 \\ 0.4939 & 0.1691 & 0.2066 \\ 0.0356 & 0.2389 & 0.1144 \\ 0.0011 & 0.0072 & 0.1695 \\ 0.0046 & 0.0179 & 0.0037 \end{bmatrix}$$

Selanjutnya, nilai `power` dikonversi ke dalam skala desibel sesuai dengan Persamaan 2.6 dengan nilai $\varepsilon = 0$ karena semua nilai `power` bukan nol.

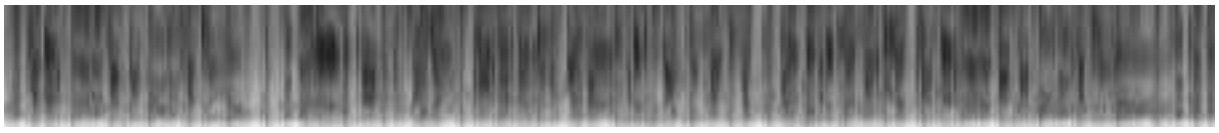
$$\text{W_dB} = 10 \times \log_{10} \left(\begin{bmatrix} 0.3736 & 0.3371 & 0.0321 \\ 0.2650 & 0.0338 & 0.0383 \\ 0.0639 & 0.0005 & 0.0864 \\ 0.2778 & 0.3531 & 0.0127 \\ 0.4939 & 0.1691 & 0.2066 \\ 0.0356 & 0.2389 & 0.1144 \\ 0.0011 & 0.0072 & 0.1695 \\ 0.0046 & 0.0179 & 0.0037 \end{bmatrix} \right)$$

$$\text{W_dB} = \begin{bmatrix} -4.276 & -4.722 & -14.930 \\ -5.768 & -14.711 & -14.168 \\ -11.945 & -33.010 & -10.635 \\ -5.563 & -4.521 & -18.962 \\ -3.064 & -7.719 & -6.849 \\ -4.485 & -6.218 & -9.416 \\ -29.586 & -21.427 & -7.708 \\ -23.372 & -7.471 & -24.318 \end{bmatrix}.$$

Selanjutnya, nilai `W_dB` direpresentasikan dengan warna sehingga menjadi citra *spectrogram* yang disimpan dalam format `.png`. Gambar 4.3 adalah contoh citra *scalogram*.

Algoritma 4.3 *Scalogram Plot*

Input: cwt_db
Proses:
Fungsi *scalogram(cwt_db)*
1. imshow(cwt_db)
2. *save scalogram*



Gambar 4.3 Contoh Citra *Scalogram*

Data sinyal audio juga diekstraksi fiturnya dengan menggunakan STFT sehingga didapatkan nilai *magnitude* berupa *power* yang merepresentasikan dua dimensi dari energi

sinyal pada dimensi waktu dan frekuensi. Parameter yang digunakan untuk STFT adalah `panjang window = 2048`, `hop size = 512`, dan `jenis window = Hann`.

Algoritma 4.4 ***STFT***

Input: sinyal, panjang window, hop size, jenis_window
Output: magnitude
Proses:
Fungsi *stft(sinyal, panjang_window, hop_size, jenis_window)*
1. Inisialisasi nilai $t = 0$
2. Membuat matriks kosong dengan nama *coef*
3. while t + panjang_window $\leq$ panjang sinyal do:
4. frame = sinyal$[t : t +$ panjang_window$]$
5. frame = frame $\times$ w # fungsi windowing
6. spectrum = DFT(frame)
7. coef.append(spectrum)
8. $t = t +$ hop_size
9. power = abs$(coef)^2$
10. Konversi power ke skala desibel

Sumber: (Paramarta, 2023)

Sebagai contoh diberikan sinyal x yang dilakukan STFT dengan `panjang window = 4` dan `hop size = 2` dengan `jenis window = Hann`. Diberikan

$$x = [-0.72, 0.18, -0.43, 0.95, -0.27, 0.66, -0.51, 0.24].$$

Dengan $N = 4$ dan $H = 2$, sinyal terbagi menjadi 3 *frame* dengan $m = 0, 1, 2$.

$$\begin{aligned} s_1 &= x(0;3) = [-0.72, 0.18, -0.43, 0.95], \text{ dengan } m = 0 \\ s_2 &= x(2;5) = [-0.43, 0.95, -0.27, 0.66], \text{ dengan } m = 1 \\ s_3 &= x(4;7) = [-0.27, 0.66, -0.51, 0.24], \text{ dengan } m = 2. \end{aligned}$$

Setelah sinyal x dibagi ke dalam beberapa *frame*, setiap *frame* dikenakan fungsi *windowing* seperti yang telah tertera pada Persamaan 2.8. Karena $N = 4$, berarti $n = 0, 1, 2, 3$. Diambil contoh perhitungan untuk $n = 0$ sebagai berikut.

$$\gamma(0) = \frac{1}{2}\left(1 - \cos\left(\frac{2\pi(0)}{3}\right)\right) = \frac{1}{2}(1 - \cos(0^\circ)) = 0$$

Dengan cara perhitungan yang sama, diterapkan juga untuk $n = 1, 2, 3$ sehingga didapatkan hasil sebagai berikut.

$$\begin{aligned} \gamma(1) &= 0.75 \\ \gamma(2) &= 0.75 \\ \gamma(3) &= 0 \end{aligned}$$

sehingga didapatkan bahwa

$$\gamma(n) = [0, 0.75, 0.75, 0].$$

Tahap selanjutnya adalah proses *frame windowing*, yaitu mengalikan setiap *frame* dengan fungsi *window* yang telah ditentukan, seperti yang tertera pada Persamaan 2.9. Pada tahap ini, nilai n menyesuaikan dengan indeks sinyal asli pada masing-masing *frame*, sehingga nilai n berbeda untuk setiap pergeseran *frame*. Diambil contoh perhitungan untuk $m = 0$ sebagai berikut.

$$\begin{aligned}
n = 0 &\rightarrow w(0)_0 = x(0)\gamma(0 - (0)(2)) = x(0)\gamma(0) = (-0.72)(0) = 0 \\
n = 1 &\rightarrow w(0)_1 = x(1)\gamma(1 - (0)(2)) = x(1)\gamma(1) = (0.18)(0.75) = 0.1350 \\
n = 2 &\rightarrow w(0)_2 = x(2)\gamma(2 - (0)(2)) = x(2)\gamma(2) = (-0.43)(0.75) = -0.3225 \\
n = 3 &\rightarrow w(0)_3 = x(3)\gamma(3 - (0)(2)) = x(3)\gamma(3) = (0.95)(0) = 0
\end{aligned}$$

sehingga didapatkan *frame windowing* untuk $m = 0$ adalah

$$\mathbf{w}(0) = [0, 0.1350, -0.3225, 0].$$

Dengan cara perhitungan yang sama, diterapkan juga untuk $m = 1$ sehingga didapatkan *frame windowing* untuk $m = 1$ adalah

$$\mathbf{w}(1) = [0, 0.7125, -0.2025, 0]$$

dan *frame windowing* untuk $m = 2$ adalah

$$\mathbf{w}(2) = [0, 0.4950, -0.3825, 0].$$

Berdasarkan Persamaan 2.9, terdapat $e^{-\frac{j2\pi kn}{N}}$ sebagai faktor eksponensial kompleks yang berfungsi sebagai fungsi basis Fourier diskrit. Untuk $N = 4$, bentuk faktor eksponensial dapat diubah terlebih dahulu ke bentuk berikut ini supaya mempermudah perhitungan.

$$e^{-\frac{j2\pi}{N}} = e^{-\frac{j2\pi}{4}} = e^{-\frac{j\pi}{2}}.$$

Dengan fungsi Euler didapatkan

$$e^{-\frac{j\pi}{2}} = \cos\left(-\frac{\pi}{2}\right) + j\sin\left(-\frac{\pi}{2}\right) = -\cos\left(\frac{\pi}{2}\right) - \sin\left(\frac{\pi}{2}\right) = -j.$$

Untuk langkah selanjutnya, dapat dikembalikan ke bentuk semula

$$e^{-\frac{j2\pi kn}{N}} = e^{-\frac{j2\pi kn}{4}} = e^{-\frac{j\pi kn}{2}} = \left(e^{-\frac{j\pi}{2}}\right)^{kn} = (-j)^{kn} = ((-j)^k)^n$$

dengan $n = 0, 1, 2, 3$ dan $k = 0, 1, 2, 3$. Diambil contoh perhitungan untuk $k = 0$ sebagai berikut.

$$\left((-j)^0\right)^n = 1^n$$

sehingga

$$\mathbf{e}(0) = \left[1^0, 1^1, 1^2, 1^3\right] = [1, 1, 1, 1].$$

Dengan cara perhitungan yang sama, diterapkan juga untuk $k = 1$ sehingga didapatkan

$$\mathbf{e}(1) = [1, -j, -1, j]$$

untuk $k = 2$

$$\mathbf{e}(2) = [1, -1, 1, -1]$$

dan untuk $k = 3$

$$\mathbf{e}(3) = [1, j, -1, -j].$$

Untuk setiap *frame* hasil *windowing*, dilakukan perkalian *dot product* antara sinyal yang sudah di-*windowing* dengan basis Fourier sesuai nilai k. Jumlahan dari hasil perkalian ini menghasilkan matriks koefisien STFT. Proses ini diulang untuk seluruh nilai $k = 0, 1, 2, 3$ pada setiap *frame*. Persamaan *dot product* dapat didefinisikan sebagai berikut.

$$X_{STFT}(m, k) = \mathbf{w}(m) + \mathbf{e}(k)$$

Diambil contoh perhitungan untuk $m = 0$ sebagai berikut.

$$\begin{aligned}
X_{STFT}(0,0) &= \mathbf{w}(0) \times \mathbf{e}(0) \\
&= (0)(1) + (0.1350)(1) + (-0.3225)(1) + (0)(1) \\
&= -0.1875 \\
X_{STFT}(0,1) &= \mathbf{w}(0) \times \mathbf{e}(1) \\
&= (0)(1) + (0.1350)(-j) + (-0.3225)(-1) + (0)(j) \\
&= 0.3225 - 0.1350j \\
X_{STFT}(0,2) &= \mathbf{w}(0) \times \mathbf{e}(2) \\
&= (0)(1) + (0.1350)(-1) + (-0.3225)(1) + (0)(-1) \\
&= -0.4575 \\
X_{STFT}(0,3) &= \mathbf{w}(0) \times \mathbf{e}(3) \\
&= (0)(1) + (0.1350)(j) + (-0.3225)(-1) + (0)(-j) \\
&= 0.3225 + 0.1350j
\end{aligned}$$

Dari perhitungan tersebut didapatkan

$$X_{STFT}(0, k) = \begin{bmatrix} 0.1875 \\ 0.3225 - 0.1350j \\ -0.4575 \\ 0.3225 + 0.1350j \end{bmatrix}.$$

Dengan cara perhitungan yang sama, diterapkan juga untuk $m = 1$ sehingga didapatkan

$$X_{STFT}(1, k) = \begin{bmatrix} 0.5100 \\ 0.2025 - 0.7125j \\ -0.9150 \\ 0.2025 + 0.7125j \end{bmatrix}$$

dan untuk $m = 2$

$$X_{STFT}(2,k) = \begin{bmatrix} 0.1125 \\ 0.3825 - 0.4950j \\ -0.8775 \\ 0.3825 + 0.4950j \end{bmatrix}.$$

Sehingga didapatkan matriks koefisien STFT

$$X_{STFT}(m,k) = \begin{bmatrix} -0.1875 & 0.5100 & 0.1125 \\ 0.3225 - 0.1350j & 0.2025 - 0.7125j & 0.3825 - 0.4950j \\ -0.4575 & -0.9150 & -0.8775 \\ 0.3225 + 0.1350j & 0.2025 + 0.7125j & 0.3825 + 0.4950j \end{bmatrix}.$$

Selanjutnya, *spectrogram* dihitung dengan menghitung magnitudo dari hasil STFT yang direpresentasikan sebagai *power*

$$\text{power} = \begin{bmatrix} \left(\sqrt{(-0.1875)^2}\right)^2 & \left(\sqrt{0.5100^2}\right)^2 & \left(\sqrt{0.1125^2}\right)^2 \\ \left(\sqrt{0.3225^2 + (-0.1350)^2}\right)^2 & \left(\sqrt{0.2025^2 + (-0.7125)^2}\right)^2 & \left(\sqrt{0.3825^2 + (-0.4950)^2}\right)^2 \\ \left(\sqrt{(-0.4575)^2}\right)^2 & \left(\sqrt{(-0.9150)^2}\right)^2 & \left(\sqrt{(-0.8775)^2}\right)^2 \\ \left(\sqrt{0.3225^2 + 0.1350^2}\right)^2 & \left(\sqrt{0.2025^2 + 0.7125^2}\right)^2 & \left(\sqrt{0.3825^2 + 0.4950^2}\right)^2 \end{bmatrix}$$

$$\text{power} \approx \begin{bmatrix} 0.0352 & 0.2601 & 0.0127 \\ 0.1222 & 0.5487 & 0.3913 \\ 0.2093 & 0.8372 & 0.7700 \\ 0.1222 & 0.5487 & 0.3913 \end{bmatrix}$$

selanjutnya, nilai `power` dikonversi ke dalam skala desibel sesuai dengan Persamaan 2.12 dengan nilai $\varepsilon = 0$ karena semua nilai `power` bukan nol.

$$\text{S_dB} = 10 \times \log_{10} \left(\begin{bmatrix} 0.0352 & 0.2601 & 0.0127 \\ 0.1222 & 0.5487 & 0.3913 \\ 0.2093 & 0.8372 & 0.7700 \\ 0.1222 & 0.5487 & 0.3913 \end{bmatrix} \right)$$

$$\text{S_dB} = \begin{bmatrix} -14.535 & -5.849 & -18.962 \\ -9.129 & -2.607 & -4.075 \\ -6.792 & -0.772 & -1.135 \\ -9.129 & -2.607 & -4.075 \end{bmatrix}.$$

Selanjutnya, nilai `S_dB` direpresentasikan dengan warna sehingga menjadi citra *spectrogram* yang disimpan dalam format `.png`. Gambar 4.4 adalah contoh citra *spectrogram*.

Algoritma 4.5 ***Spectrogram Plot***

Input: S_db, sr
Proses:
Fungsi *spectrogram(S_db, sr)*
1. specshow(S_db, sr)

Algoritma 4.5 ***Spectrogram Plot***

2. *save spectrogram*



Gambar 4.4 Contoh Citra *Spectrogram*

4.2.3 Perancangan Tahap *Cropping Image*

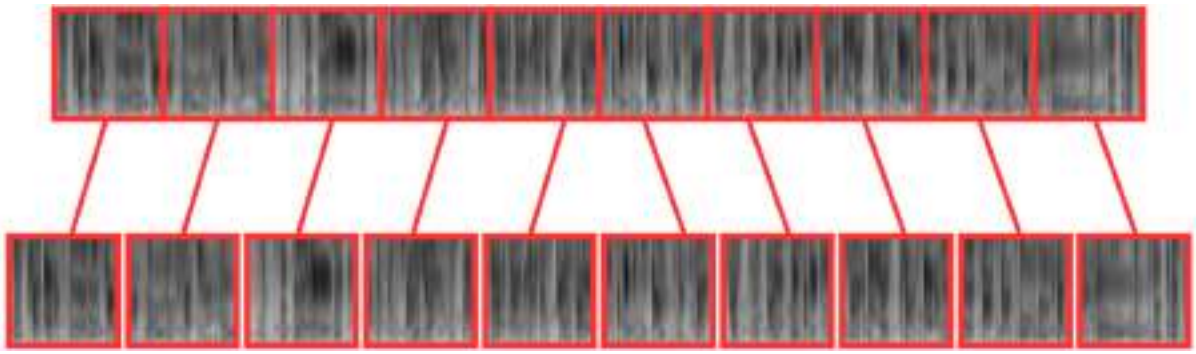
Setelah didapatkan citra *scalogram* dan *spectrogram* untuk setiap data audio, dilakukan tahap *cropping image*. Setiap citra yang berukuran 2240×244 piksel kemudian dipotong menjadi 10 bagian sehingga dihasilkan citra *scalogram* dan *spectrogram* baru yang berukuran 224×224 piksel. Citra kemudian disimpan dalam format `.png`.

Algoritma 4.6 ***Cropping Image***

Input: spectrogram, scalogram
Output: cropped_spectrogram, cropped_scalogram
Proses:
Fungsi *crop(spectrogram, scalogram)*

1. Menghitung tinggi dan lebar *spectrogram* dan *scalogram*
2. Menentukan lebar *spectrogram* dan *scalogram* hasil *cropping* sebesar 224 piksel
3. for i in range(10):
4. left = $i * 224$
5. upper = 0
6. right = left + 224
7. lower = 224
8. cropped = img.crop((left, upper, right, lower))
9. *save cropped*

Proses *cropping image* dapat dilihat pada Gambar 4.5.



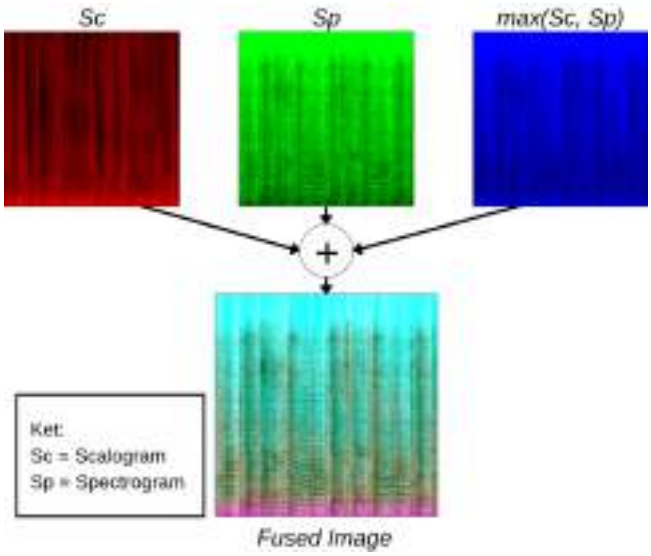
Gambar 4.5 Visualisasi *Cropping Image*

4.2.4 Perancangan Tahap Fusi Citra

Setelah dilakukan *cropping image*, citra difusikan menjadi satu macam citra menggunakan operasi aritmatika dan fungsi agregasi, yaitu *maximum*, *minimum*, *average*,

weighted average, *addition*, *subtraction*, *multiplication*, dan *division*. Berikut ini adalah penjelasan mengenai skenario fusi citra yang dilakukan untuk penelitian ini.

1. *Maximum*
   Skenario fusi dengan fungsi *maximum* dilakukan dengan menjadikan *scalogram* sebagai lapisan R, *spectrogram* sebagai lapisan G, dan nilai *maximum* dari setiap piksel *scalogram* dan *spectrogram* sebagai lapisan B. Skenario fusi dengan fungsi *maximum* dapat dilihat pada Gambar 4.6.

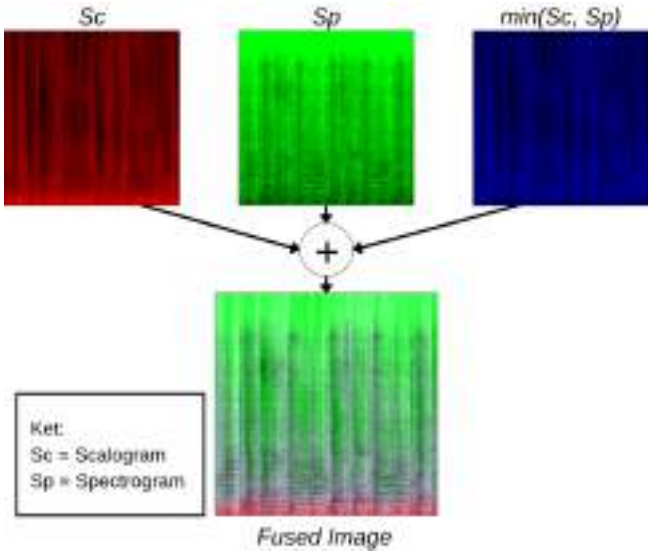


Gambar 4.6 Skenario Fusi dengan Fungsi *Maximum*

Algoritma 4.7 Fusi Citra (*Maximum*)

Input: R_scal, G_spec
Proses:
Fungsi *fusi(R_scal, G_spec)*
1. B_fused = max(R_scal, G_spec)
2. fused_image = merge(B_fused, G_spec, R_scal)
3. *save* fused_image

2. *Minimum*
   Skenario fusi dengan fungsi *minimum* dilakukan dengan menjadikan *scalogram* sebagai lapisan R, *spectrogram* sebagai lapisan G, dan nilai *minimum* dari setiap piksel *scalogram* dan *spectrogram* sebagai lapisan B. Skenario fusi dengan fungsi *minimum* dapat dilihat pada Gambar 4.7.

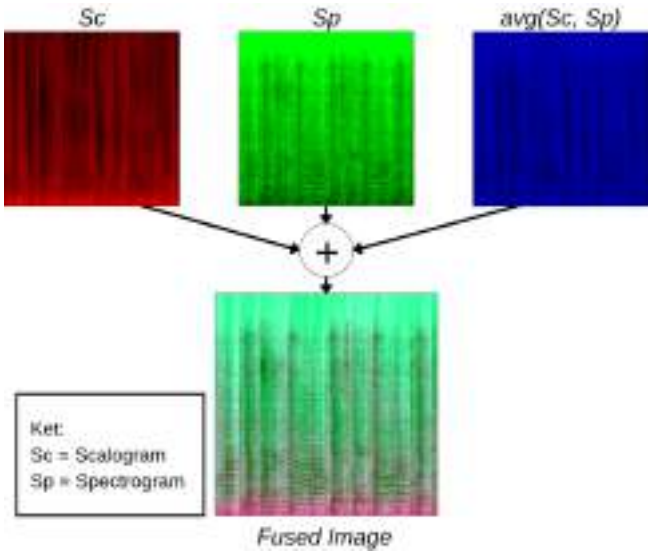


Gambar 4.7 Skenario Fusi dengan Fungsi *Minimum*

Algoritma 4.8 Fusi Citra (*Minimum*)

Input: R_scal, G_spec
Proses:
Fungsi *fusi(R_scal, G_spec)*
1. B_fused = min(R_scal, G_spec)
2. fused_image = merge(B_fused, G_spec, R_scal)
3. *save* fused_image

3. *Average*
Skenario fusi dengan fungsi *average* dilakukan dengan menjadikan *scalogram* sebagai lapisan R, *spectrogram* sebagai lapisan G, dan *average* (rata-rata) dari setiap piksel *scalogram* dan *spectrogram* sebagai lapisan B. Skenario fusi dengan fungsi *average* dapat dilihat pada Gambar 4.8.

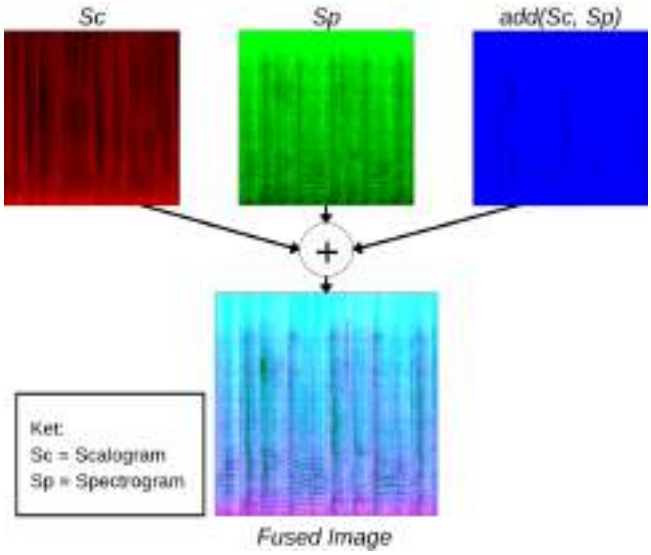


Gambar 4.8 Skenario Fusi dengan Fungsi *Average*

Algoritma 4.9 Fusi Citra (*Average*)

Input: R_scal, G_spec
Proses:
Fungsi *fusi(R_scal, G_spec)*
1. B_fused = avg(R_scal, G_spec)
2. fused_image = merge(B_fused, G_spec, R_scal)
3. *save* fused_image

4. *Addition*
Skenario fusi dengan fungsi *addition* dilakukan dengan menjadikan *scalogram* sebagai lapisan R, *spectrogram* sebagai lapisan G, dan *addition* (penjumlahan) dari setiap piksel *scalogram* dan *spectrogram* sebagai lapisan B. Skenario fusi dengan fungsi *addition* dapat dilihat pada Gambar 4.9.

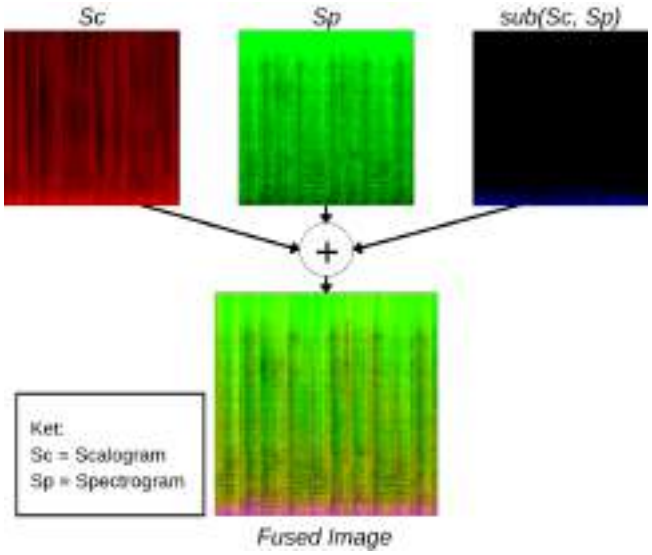


Gambar 4.9 Skenario Fusi dengan Fungsi *Addition*

Algoritma 4.10 Fusi Citra (*Addition*)

Input: R_scal, G_spec
Proses:
Fungsi *fusi(R_scal, G_spec)*
1. B_fused = add(R_scal, G_spec)
2. fused_image = merge(B_fused, G_spec, R_scal)
3. *save* fused_image

5. *Subtraction*
Skenario fusi dengan fungsi *subtraction* dilakukan dengan menjadikan *scalogram* sebagai lapisan R, *spectrogram* sebagai lapisan G, dan *subtraction* (pengurangan) dari setiap piksel *scalogram* dan *spectrogram* sebagai lapisan B. Skenario fusi dengan fungsi *subtraction* dapat dilihat pada Gambar 4.10.

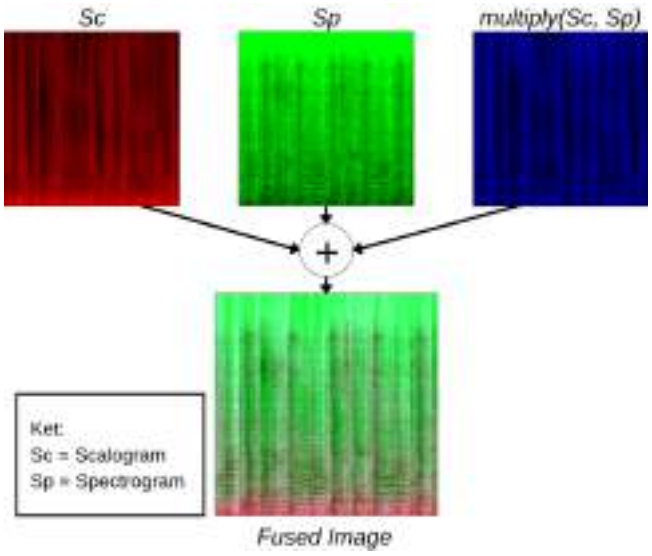


Gambar 4.10 Skenario Fusi dengan Fungsi *Subtraction*

Algoritma 4.11 Fusi Citra (*Subtraction*)

Input: R_scal, G_spec
Proses:
Fungsi *fusi(R_scal, G_spec)*
1. B_fused = subtract(R_scal, G_spec)
2. fused_image = merge(B_fused, G_spec, R_scal)
3. *save* fused_image

6. *Multiplication*
   Skenario fusi dengan fungsi *multiplication* dilakukan dengan menjadikan *scalogram* sebagai lapisan R, *spectrogram* sebagai lapisan G, dan *multiplication* (perkalian) dari setiap piksel *scalogram* dan *spectrogram* sebagai lapisan B. Skenario fusi dengan fungsi *multiplication* dapat dilihat pada Gambar 4.11.

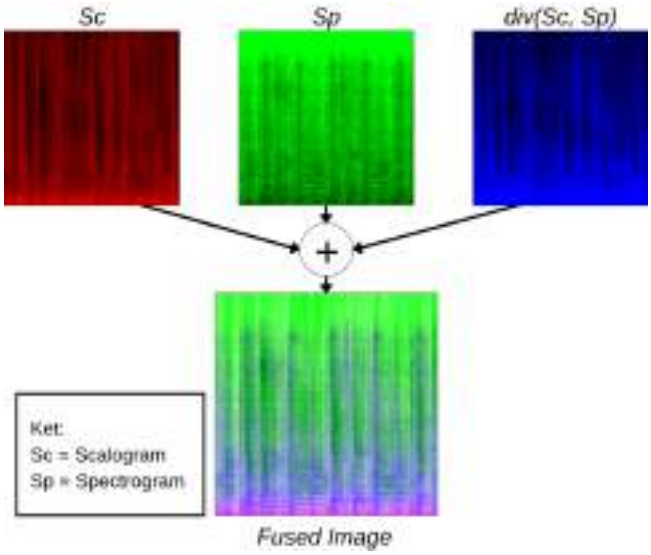


Gambar 4.11 Skenario Fusi dengan Fungsi *Multiplication*

Algoritma 4.12 Fusi Citra (*Multiplication*)

Input: R_scal, G_spec
Proses:
Fungsi *fusi(R_scal, G_spec)*
1. B_fused = R_scal ∗ G_spec
2. fused_image = merge(B_fused, G_spec, R_scal)
3. *save* fused_image

7. *Division*
Skenario fusi dengan fungsi *division* dilakukan dengan menjadikan *scalogram* sebagai lapisan R, *spectrogram* sebagai lapisan G, dan *division* (pembagian) dari setiap piksel *scalogram* dan *spectrogram* sebagai lapisan B. Skenario fusi dengan fungsi *division* dapat dilihat pada Gambar 4.12.

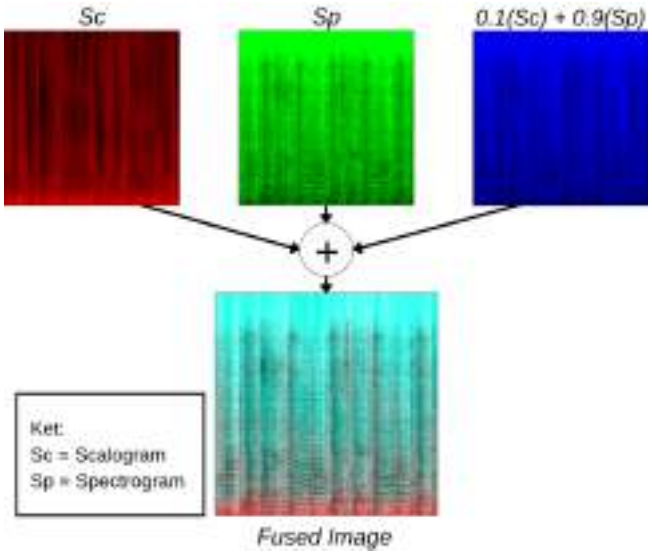


Gambar 4.12 Skenario Fusi dengan Fungsi *Division*

Algoritma 4.13 Fusi Citra (*Division*)

Input: R_scal, G_spec
Proses:
Fungsi *fusi(R_scal, G_spec)*
1. B_fused = divide(R_scal, G_spec)
2. fused_image = merge(B_fused, G_spec, R_scal)
3. *save* fused_image

8. *Weighted Average*
Skenario fusi dengan fungsi *weighted average* dilakukan dengan menjadikan *scalogram* sebagai lapisan R, *spectrogram* sebagai lapisan G, dan *weighted average* (pembobotan) yang sesuai dengan Persamaan 2.20 dari setiap piksel *scalogram* dan *spectrogram* sebagai lapisan B. Skenario fusi dengan fungsi *weighted average* dengan nilai $\alpha = 0.1$ dapat dilihat pada Gambar 4.13.



Gambar 4.13 Skenario Fusi dengan Fungsi *Weighted Average* dengan $\alpha = 0.1$

Algoritma 4.14 Fusi Citra (*Weighted Average*)

Input: R_scal, G_spec, α
Proses:
Fungsi *fusi(R_scal, G_spec, α)*
1. B_fused $= \alpha * \text{R_scal} + (1 - \alpha) * \text{G_spec}$
2. fused_image = merge(B_fused, G_spec, R_scal)
3. *save* fused_image

Semua skenario fusi yang dilakukan dalam penelitian ini ditampilkan pada Tabel 4.15.

Tabel 4.15 Skenario Fusi

Skenario	α	***Channel***		
		R	**G**	**B**
Maximum	-	*scalogram*	*spectrogram*	$\max\{scalogram, spectrogram\}$
Minimum				$\min\{scalogram, spectrogram\}$
Average				$\text{avg}\{scalogram, spectrogram\}$
Addition				$scalogram + spectrogram$
Subtraction				$scalogram - spectrogram$
Multiplication				$scalogram \times spectrogram$
Division				$scalogram \div spectrogram$
Weighted Average	0.1			$0.1(scalogram) + 0.9(spectrogram)$
	0.3			$0.3(scalogram) + 0.7(spectrogram)$
	0.5			$0.5(scalogram) + 0.5(spectrogram)$
	0.7			$0.7(scalogram) + 0.3(spectrogram)$
	0.9			$0.9(scalogram) + 0.1(spectrogram)$

4.2.5 *Data Splitting*

Citra dataset sekunder yang telah difusikan kemudian dibagi secara acak menjadi data latih, data validasi, dan data uji. Penulis menerapkan *data splitting* yang berbeda pada

masing-masing dataset. Pada dataset sekunder, data dibagi menjadi 70% data latih, 20% data validasi, dan 10% data uji. Adapun pada dataset primer, proporsi yang digunakan adalah 10% data latih, 20% data validasi, dan 70% data uji. Oleh karena itu, dari total 9.980 citra dataset sekunder dan 3.000 citra dataset primer untuk setiap metode fusi yang digunakan, hasil pembagian data dapat dilihat pada Tabel 4.16.

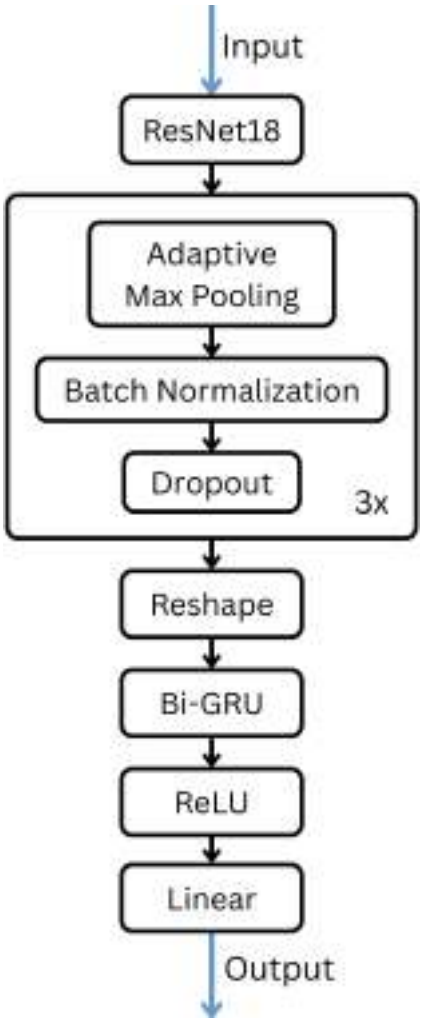
Tabel 4.16 Jumlah Dataset

Sekunder	*Stratified Sampling*	Latih		6.986
		Validasi		1.996
		Uji		998
	Group Shuffle Split	Latih		6.980
		Validasi		2.000
		Uji		1.000
Primer	*Stratified Sampling*	Latih	0:30 - 1:00	50
			1:00 - 1:30	50
			1:30 - 2:00	50
			2:00 - 2:30	50
			2:30 - 3:00	50
			Reff	50
		Validasi	0:30 - 1:00	100
			1:00 - 1:30	100
			1:30 - 2:00	100
			2:00 - 2:30	100
			2:30 - 3:00	100
			Reff	100
		Uji	0:30 - 1:00	350
			1:00 - 1:30	350
			1:30 - 2:00	350
			2:00 - 2:30	350
			2:30 - 3:00	350
			Reff	350
	Group Shuffle Split	Latih	0:30 - 1:00	10
			1:00 - 1:30	100
			1:30 - 2:00	100
			2:00 - 2:30	90
			2:30 - 3:00	0
			Reff	0
		Validasi	0:30 - 1:00	20
			1:00 - 1:30	190
			1:30 - 2:00	100

			2:00 - 2:30	110
			2:30 - 3:00	180
			Reff	0
		Uji	0:30 - 1:00	470
			1:00 - 1:30	210
			1:30 - 2:00	300
			2:00 - 2:30	300
			2:30 - 3:00	320
			Reff	500

4.2.6 Perancangan Model ResNet-BiGRU

Arsitektur yang digunakan pada penelitian ini adalah arsitektur asli model ResNet tanpa *classifier* yang dikombinasikan dengan model Bi-GRU. Setelah ResNet mengekstraksi fitur, ditambahkan layer `Adaptive Max Pooling`, `Batch Normalization`, dan `Dropout` masing-masing sebanyak 3 kali. Model ResNet-BiGRU yang digunakan pada penelitian ini dapat dilihat pada Gambar 4.14.



Gambar 4.14 Arsitektur Model ResNet-BiGRU

Tabel 4.17 *Hyperparameter* Model ResNet-BiGRU pada Penelitian Ini

Tipe	**Nilai**
input size	$224 \times 224 \times 3$
pooling type	`max pooling`
batch normalization	$512, 512, 512$
GRU input size	512
loss function	`categorical cross entropy`
activation function	`ReLu`

Tabel 4.18 *Input Shape* dan *Output Shape* Setiap *Layer*

Layer	***Input Shape***	***Output Shape***
`Input size`	$224 \times 224 \times 3$	$224 \times 224 \times 3$
`ResNet`	$224 \times 224 \times 3$	$512 \times 7 \times 7$
`Adaptive Max Pooling`	$512 \times 7 \times 7$	$512 \times 2 \times 2$
`Batch Normalization`	$512 \times 2 \times 2$	$512 \times 2 \times 2$
`Dropout`	$512 \times 2 \times 2$	$512 \times 2 \times 2$
`Adaptive Max Pooling`	$512 \times 2 \times 2$	$512 \times 2 \times 2$
`Batch Normalization`	$512 \times 2 \times 2$	$512 \times 2 \times 2$
`Dropout`	$512 \times 2 \times 2$	$512 \times 2 \times 2$
`Adaptive Max Pooling`	$512 \times 2 \times 2$	$512 \times 2 \times 2$
`Batch Normalization`	$512 \times 2 \times 2$	$512 \times 2 \times 2$
`Dropout`	$512 \times 2 \times 2$	$512 \times 2 \times 2$
`Reshape`	$512 \times 2 \times 2$	4×512
`Bi-GRU`	4×512	4×512
`ReLu`	4×512	512
`Linear`	512	10

4.2.7 Proses Perhitungan *Pooling Layer* dan *Batch Normalization*

Pada model ResNet-BiGRU, dilakukan perhitungan *Max Pooling* dan *Batch Normalization*. Contoh perhitungan dilakukan menggunakan matriks berukuran 3×3 berikut ini.

$$\mathcal{B} = \begin{bmatrix} 3 & -1 & 7 \\ -4 & 2 & -6 \\ 5 & -3 & 1 \end{bmatrix}$$

Pada contoh ini, diberikan perhitungan *Max Pooling* dengan nilai 2×2 dan nilai *stride default* yaitu 1×1.

$$MaxPooling(\mathcal{B}) = \begin{bmatrix} 3 & 7 \\ 5 & 2 \end{bmatrix}$$

Setelah dilakukan perhitungan *Max Pooling*, selanjutnya dilakukan *Batch Normalization* pada matriks tersebut. Nilai γ dan β *default* adalah $\gamma = 1$ dan $\beta = 0$. Berdasarkan Persamaan 2.22, Persamaan 2.23, Persamaan 2.24, dan Persamaan 2.25 dapat dilakukan

perhitungan sebagai berikut.

$$\mu_{\mathcal{B}} = \frac{1}{4}(3+7+5+2)$$
$$\mu_{\mathcal{B}} = 4.25$$
$$\sigma^2_{\mathcal{B}} = \frac{1}{4}((3-4.25)^2 + (7-4.25)^2 + (5-4.25)^2 + (2-4.25)^2)$$
$$\sigma^2_{\mathcal{B}} = 3.6875$$

Untuk perhitungan berikutnya, ϵ dapat diabaikan karena penyebut tidak bernilai nol.

$$\widehat{x_i} = \frac{x_i - 4.25}{\sqrt{(3.6875)^2}}$$
$$\widehat{x_i} = \frac{x_i - 4.25}{3.6875}$$

$$\widehat{x} = \begin{bmatrix} \frac{3-4.25}{3.6875} & \frac{7-4.25}{3.6875} \\ \frac{5-4.25}{3.6875} & \frac{2-4.25}{3.6875} \end{bmatrix}$$
$$\widehat{x} = \begin{bmatrix} -0.3390 & 0.7458 \\ 0.2034 & -0.6102 \end{bmatrix}$$

Karena $\gamma = 1$ dan $\beta = 0$, berarti

$$\mathrm{BN}_{\gamma,\beta}(x) = \widehat{x}$$
$$\mathrm{BN}_{\gamma,\beta}(x) = \begin{bmatrix} -0.3390 & 0.7458 \\ 0.2034 & -0.6102 \end{bmatrix}.$$

4.2.8 Perhitungan *Loss*

Output dari model ResNet-BiGRU setelah fungsi aktivasi *softmax* adalah *array* $\widehat{y}$, yaitu *array* probabilitas untuk masing-masing kelas. Misal didapatkan

$$\widehat{y} = [0.43, 0.46, 0.59, 0.44, 0.56, 0.53, 0.4, 0.51, 0.53, 0.09]$$

dan nilai kelas target (aktual) 'classical', yang ada pada indeks ke-2 sehingga *array* target adalah

$$y = [0, 1, 0, 0, 0, 0, 0, 0, 0, 0]$$

maka perhitungan *loss* dilakukan menggunakan Persamaan 2.30.

$$L = -(0\log(0.43) + 1\log(0.46) + ... + 0\log(0.53) + 0\log(0.09))$$
$$L = -\log(0.46)$$
$$L \approx 0.337242.$$

4.3 Perancangan Hasil Klasifikasi

Pada subbab ini dijelaskan perancangan proses hasil klasifikasi. Data uji yang digunakan terdiri atas data uji dari dataset sekunder yang telah mengalami proses *data*

splitting serta dataset primer. Dataset primer yang telah diunduh kemudian dipotong menjadi 5 bagian berdasarkan rentang waktu per menit sehingga diperoleh potongan audio berdurasi 30 detik, yaitu pada menit 0:30-1:00, 1:00-1:30, 1:30-2:00, 2:00-2:30, dan 2:30-3:00. Pemilihan bagian lagu tersebut didasarkan pada durasi lagu-lagu yang diunduh, yaitu sekitar 3 menit, dan terdapat beberapa bagian awal lagu yang tidak mengandung suara (kosong). Selanjutnya, setiap potongan lagu tersebut diekstraksi menjadi citra *spectrogram* menggunakan STFT dan citra *scalogram* menggunakan CWT yang kemudian seluruh citra tersebut dipotong menjadi 10 bagian. Setelah itu, citra *scalogram* dan *spectrogram* yang telah dipotong difusikan menggunakan metode fusi yang telah dijelaskan sebelumnya. Potongan citra hasil fusi selanjutnya diprediksi menggunakan model ResNet-BiGRU yang telah melalui tahap pelatihan. Hasil prediksi yang diperoleh berupa *confidence level* atau *array* probabilitas dari setiap potongan citra terhadap 10 kelas genre musik yang digunakan dalam penelitian ini.

Contoh hasil keluaran dari setiap potongan citra dapat dituliskan sebagai berikut.

$$\begin{aligned}
\text{pred}_1 &= [0.2, 0.7, 0.4, 0.9, 0.1, 0.8, 0.3, 0.1, 0.5, 0.9] \\
\text{pred}_2 &= [0.6, 0.2, 0.8, 0.3, 0.5, 0.9, 0.1, 0.4, 0.7, 0.0] \\
\text{pred}_3 &= [0.3, 0.9, 0.1, 0.4, 0.8, 0.2, 0.5, 0.7, 0.6, 0.0] \\
\text{pred}_4 &= [0.5, 0.1, 0.7, 0.2, 0.9, 0.4, 0.6, 0.8, 0.3, 0.0] \\
\text{pred}_5 &= [0.3, 0.8, 0.2, 0.5, 0.9, 0.1, 0.4, 0.6, 0.7, 0.0] \\
\text{pred}_6 &= [0.2, 0.9, 0.5, 0.7, 0.3, 0.8, 0.1, 0.6, 0.4, 0.0] \\
\text{pred}_7 &= [0.4, 0.1, 0.7, 0.9, 0.3, 0.8, 0.2, 0.6, 0.5, 0.0] \\
\text{pred}_8 &= [0.5, 0.2, 0.8, 0.1, 0.7, 0.3, 0.9, 0.6, 0.4, 0.0] \\
\text{pred}_9 &= [0.6, 0.3, 0.8, 0.2, 0.5, 0.9, 0.1, 0.4, 0.7, 0.0] \\
\text{pred}_{10} &= [0.7, 0.4, 0.9, 0.2, 0.6, 0.1, 0.8, 0.3, 0.5, 0.0]
\end{aligned}$$

Setiap indeks pada pred_i merepresentasikan nilai probabilitas pada masing-masing genre musik yang ada pada penelitian ini, yaitu ['blues', 'classical', 'country', 'disco', 'hiphop', 'jazz', 'metal', 'pop', 'reggae', 'rock']. Hasil klasifikasi genre musik untuk satu potongan audio berdurasi 30 detik diperoleh melalui rata-rata nilai *confidence level* dari seluruh potongan citra, yang secara matematis dapat dituliskan sebagai berikut (Paramarta, 2023):

$$\text{Hasil} = \sum_{i=1}^{10} \frac{\text{pred}_i}{10}$$

sehingga didapatkan

$$\text{Hasil} = [0.43, 0.46, 0.59, 0.44, 0.56, 0.53, 0.4, 0.51, 0.53, 0.09].$$

Selanjutnya, nilai *confidence level* tertinggi dari `Hasil` dikenai proses *thresholding* dengan ambang batas sebesar 0.25. Apabila $\max(Hasil) < 0.25$, maka program memberikan keluaran "*unknown*" yang menandakan bahwa genre lagu tersebut tidak dikenali oleh model. Berdasarkan contoh sebelumnya, *confidence level* terbesar bernilai 0.59 yang terdapat pada indeks ke-3, sehingga program memberikan keluaran berupa genre 'country'.

4.4 Implementasi Program

Pada subbab ini dijelaskan mengenai implementasi program yang telah dijalankan. Program tersebut diimplementasikan menggunakan bahasa pemrograman *Python* dengan memanfaatkan *platform Visual Studio Code* (VSCode) dan juga *Kaggle* sebagai *development environments*. VSCode digunakan untuk tahap *pre-processing*, mulai dari normalisasi audio, ekstraksi fitur, *cropping image*, fusi citra, dan *data splitting*. Sementara itu, *Kaggle* digunakan untuk tahap implementasi model, pelatihan dan validasi, dan pengujian.

4.4.1 Implementasi Normalisasi Audio

Normalisasi audio dilakukan dengan bantuan *library os, librosa*, dan *soundfile*. Kode Program 1 merupakan implementasi program tahap normalisasi audio.

Kode Program 1 Normalisasi Audio

```
import os
import librosa
import soundfile as sf

# Normalize audio
y, sr = librosa.load(input_filepath, sr=None, mono=True)
sf.write(output_filepath, librosa.util.normalize(y), sr)
```

4.4.2 Implementasi Ekstraksi Fitur

Ekstraksi fitur dengan mengubah data audio menjadi citra *grayscale* dilakukan dengan bantuan *library os, librosa, numpy, matplotlib*, dan *PyWavelets (pywt)*. Kode Program 2 merupakan implementasi program tahap ekstraksi fitur.

Kode Program 2 Ekstraksi Fitur

```
import os
import librosa
import librosa.display
import numpy as np
import matplotlib.pyplot as plt
import pywt

# Scalogram
y, sr = librosa.load(audio_path, sr=None)
cwtmatr, freqs = pywt.cwt(y, np.arange(1, 64), 'morl', sampling_period=1/sr)
cwt_db = librosa.power_to_db(np.abs(cwtmatr)**2, ref=np.max)

# Spectrogram
y, sr = librosa.load(audio_path, sr=None)
D = librosa.stft(y, n_fft=2048, hop_length=512, window='hann')
S_db = librosa.power_to_db(np.abs(D)**2, ref=np.max)
```

4.4.3 Implementasi *Cropping Image*

Cropping image menjadi 10 citra dilakukan dengan bantuan *library os* dan *Python Image Libraries* (PIL). Kode Program 3 merupakan implementasi program tahap *cropping image*.

Kode Program 3 *Cropping Image*

```
import os
```

```
from PIL import Image

# Define cropping coordinates
left  = i * 224
upper = 0
right = left + 224
lower = 224

# Crop images
cropped = img.crop((left, upper, right, lower))
```

4.4.4 Implementasi Fusi Citra

Fusi citra dilakukan dengan bantuan *library os, cv2*, dan *numpy*. Karena perbedaan *source code* pada setiap metode fusi citra relatif kecil, maka hanya beberapa *source code* yang dianggap mewakili dicantumkan dalam penulisan ini. Kode Program 4 merupakan implementasi proses fusi citra menggunakan fungsi agregasi berbasis nilai maksimum untuk mendapatkan citra kanal B.

Kode Program 4 Fusi Citra dengan Metode *Maximum*

```
import os
import cv2
import numpy as np

# Extract channels
R_scal = scal_img[:, :, 2]
G_spec = spec_img[:, :, 1]

# Fuse channels
B_fused = np.maximum(R_scal, G_spec).astype(np.uint8)
'''
Minimum: B_fused = np.minimum(R_scal, G_spec).astype(np.uint8)
Average: B_fused = ((R_scal + G_spec) / 2).astype(np.uint8)
Addition: B_fused = cv2.add(R_scal, G_spec)
Subtraction: B_fused = cv2.subtract(R_scal, G_spec)
Multiplication: B_fused = (R_scal + G_spec).astype(np.uint8)
'''
```

Kode Program 5 merupakan implementasi proses fusi citra menggunakan operasi aritmatika berupa pembagian untuk mendapatkan citra kanal B.

Kode Program 5 Fusi Citra dengan Metode *Division*

```
import os
import cv2
import numpy as np

# Extract channels
R_scal = scal_img[:, :, 2]
G_spec = spec_img[:, :, 1]

# Fuse channels
B_fused = np.divide(
    R_scal.astype(np.float32),
    G_spec.astype(np.float32) + 1e-8
) * 255.0
```

```
14
15 B_fused = np.clip(B_fused, 0, 255).astype(np.uint8)
```

Kode Program 6 merupakan implementasi proses fusi citra menggunakan fungsi agregasi berbasis nilai pembobotan dengan $\alpha = 0.1$ untuk mendapatkan citra kanal B.

Kode Program 6 Fusi Citra dengan Metode *Weighted Average*

```
1 import os
2 import cv2
3 import numpy as np
4
5 # Weighted parameter
6 ALPHA = 0.1
7
8 # Extract channels
9 R_scal = scal_img[:, :, 2].astype(np.float32)
10 G_spec = spec_img[:, :, 1].astype(np.float32)
11
12 # Fuse channels
13 B_fused = ALPHA * R_scal + (1 - ALPHA) * G_spec
```

Setelah mendapatkan citra kanal B, kembali dilakukan fusi citra untuk menggabungkan citra dari kanal R, G, dan, B. Kode Program 7 merupakan contoh implementasi proses fusi citra untuk mendapatkan citra gabungan dari kanal R, G, dan B, di mana citra kanal B diperoleh melalui metode fusi berbasis kanal warna.

Kode Program 7 Fusi Citra

```
1 import cv2
2 import os
3 import numpy as np
4
5 # Fuse images
6 fused_image = cv2.merge([img_B, img_G, img_R])
```

4.4.5 Implementasi *Data Splitting*

Data splitting menjadi 3 bagian yaitu data latih, data validasi, dan data uji dilakukan dengan bantuan *library os*, *shutil*, *numpy*, dan *sklearn*. Kode Program 8 dan Kode Program 9 merupakan contoh implementasi proses *data splitting* menggunakan dataset fusi pembobotan dengan nilai parameter $\alpha = 0.1$.

Stratified Sampling

Kode Program 8 merupakan contoh implementasi *data splitting* dengan metode *Stratified Sampling*.

Kode Program 8 *Splitting Data dengan Stratified Sampling*

```
1 import os
2 import shutil
3 from sklearn.model_selection import train_test_split
4
5 # Split into train and temporary sets
6 train_files, temp_files = train_test_split(
7     files, test_size=0.6, random_state=42
```

```
)

# Split temporary sets into val & test sets
val_files, test_files = train_test_split(
    temp_files, test_size=0.5, random_state=42
)
```

Group Shuffle Split

Kode Program 9 merupakan contoh implementasi *data splitting* dengan metode *Group Shuffle Split*.

Kode Program 9 *Splitting Data dengan Group Shuffle Split*

```
import os
import shutil
import numpy as np
from sklearn.model_selection import GroupShuffleSplit

groups = [f.split("_")[0] for f in files]

# Split into train and temporary sets
gss1 = GroupShuffleSplit(n_splits=1, test_size=0.6, random_state=42)
train_idx, temp_idx = next(gss1.split(files, groups=groups))

# Split temporary sets into val & test sets
gss2 = GroupShuffleSplit(n_splits=1, test_size=0.5, random_state=42)
val_idx, test_idx = next(gss2.split(temp_files, groups=temp_groups))
```

4.4.6 Implementasi Model ResNet-BiGRU

Pada tahap implementasi model, terlebih dahulu dibuat *data loader*. Selanjutnya, dilakukan pelatihan model ResNet-BiGRU.

Implementasi *Data Loader*

Data loader berfungsi untuk memuat dataset serta menerapkan augmentasi pada data latih, kemudian menyiapkan data latih, data validasi, dan data uji yang digunakan. Pembentukan *data loader* dilakukan dengan bantuan *library pytorch* dan *torchvision*. Kode Program 10 merupakan contoh implementasi pada citra dengan metode fusi *addition*.

Kode Program 10 *Data Loader*

```
from torch.utils.data import DataLoader
from torchvision import transforms, datasets

# Parameter
IMG_SIZE = (224, 224)
BATCH_SIZE = 32

# Transformation
train_transforms = transforms.Compose([
    transforms.ToTensor(),
])

val_transforms = transforms.Compose([
    transforms.ToTensor(),
])

```

```
test_transforms = transforms.Compose([
    transforms.ToTensor(),
])

# Load dataset
train_dataset = datasets.ImageFolder(root=train_dir, transform=train_transforms)
val_dataset   = datasets.ImageFolder(root=val_dir,   transform=val_transforms)
test_dataset  = datasets.ImageFolder(root=test_dir,  transform=test_transforms)

# DataLoader
train_loader = DataLoader(train_dataset, batch_size=BATCH_SIZE, shuffle=True, num_workers=2, pi
val_loader   = DataLoader(val_dataset,   batch_size=BATCH_SIZE, shuffle=False, num_workers=2, p
test_loader  = DataLoader(test_dataset,  batch_size=BATCH_SIZE, shuffle=False, num_workers=2, p
```

Implementasi Model ResNet-BiGRU

Pada tahap ini dilakukan pembentukan model ResNet-BiGRU dengan bantuan *library pytorch* dan *torchvision* yang ditunjukkan pada Kode Program 11.

Kode Program 11 Model ResNet-BiGRU

```
import torch.nn as nn
from torchvision import models

class ResGru(nn.Module):
    def __init__(self, num_classes=10, hidden_size=64, num_layers=2, bidirectional=True):
        super(ResGru, self).__init__()

        # ----- 1. Backbone ResNet18 pretrained -----
        resnet = models.resnet18(weights=models.ResNet18_Weights.IMAGENET1K_V1)
        self.feature_extractor = nn.Sequential(*list(resnet.children())[:-2])

        # ----- 2. Pooling + BN + Dropout -----
        self.pool1 = nn.AdaptiveAvgPool2d((4, 4))
        self.bn1   = nn.BatchNorm2d(512)
        self.drop1 = nn.Dropout(0.1)

        self.pool2 = nn.AdaptiveAvgPool2d((2, 2))
        self.bn2   = nn.BatchNorm2d(512)
        self.drop2 = nn.Dropout(0.1)

        self.pool3 = nn.AdaptiveAvgPool2d((1, 1))
        self.bn3   = nn.BatchNorm2d(512)
        self.drop3 = nn.Dropout(0.1)

        # ----- 3. BiGRU -----
        self.hidden_size = hidden_size
        self.num_layers = num_layers
        self.bidirectional = bidirectional
        self.num_directions = 2 if bidirectional else 1

        self.bigru = nn.GRU(
            input_size=512,
            hidden_size=hidden_size,
            num_layers=num_layers,
            batch_first=True,
            bidirectional=bidirectional
        )
```

```
38
39          # ----- 4. Fully Connected Output -----
40          self.fc = nn.Linear(hidden_size * self.num_directions, num_classes)
41
42          self.relu = nn.ReLU()
43
44      def forward(self, x):
45          # 1. Feature extraction
46          x = self.feature_extractor(x)
47
48          # 2. Pooling + BN + Dropout
49          x = self.pool1(x)
50          x = self.bn1(x)
51          x = self.drop1(x)
52
53          x = self.pool2(x)
54          x = self.bn2(x)
55          x = self.drop2(x)
56
57          x = self.pool3(x)
58          x = self.bn3(x)
59          x = self.drop3(x)
60
61          # 3. Flatten to sequence
62          x = x.view(x.size(0), -1, 512)
63
64          out, _ = self.bigru(x)
65          out = out[:, -1, :]
66
67          out = self.relu(out)
68          out = self.fc(out)
69          return out
```

Implementasi Pelatihan Model

Pada tahap ini dilakukan pelatihan model ResNet-BiGRU dengan bantuan *library* *pytorch*, *os*, dan *tqdm* yang ditunjukkan pada Kode Program 12.

Kode Program 12 *Train*

```
1  import torch
2  import os
3  from tqdm import tqdm
4  from torch.optim.lr_scheduler import ReduceLROnPlateau
5
6  device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
7
8  for epoch in range(EPOCHS):
9      model.train()
10     for images, labels in train_loader:
11         optimizer.zero_grad()
12         outputs = model(images)
13         loss = criterion(outputs, labels)
14         loss.backward()
15         optimizer.step()
16
17     model.eval()
18     with torch.no_grad():
```

```
        for images, labels in val_loader:
            outputs = model(images)
            val_loss = criterion(outputs, labels)
```

4.4.7 Implementasi Pengujian Program

Implementasi pengujian program dilakukan menggunakan data uji dari dataset sekunder yang telah mengalami *data splitting* dan dataset primer. Hasil prediksi model dibentuk menjadi *confusion matrix* dan disimpan ke format `.csv`.

Implementasi Evaluasi Model

Evaluasi model berfungsi untuk mengukur kinerja model secara keseluruhan yang ditunjukkan dalam bentuk *confusion matrix* dengan bantuan *library pytorch*, *matplotlib*, *numpy*, *seaborn*, dan *sklearn*. Kode Program 13 merupakan implementasi tahap evaluasi model.

Kode Program 13 Evaluasi Model

```
import torch
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
from sklearn.metrics import classification_report, confusion_matrix

# Initialize variables
y_true = []
y_pred = []

model.eval()
with torch.no_grad():
    for images, labels in test_loader:
        outputs = model(images)
        preds = torch.argmax(outputs, dim=1)
        y_true.extend(labels.cpu().numpy())
        y_pred.extend(preds.cpu().numpy())

test_acc = (np.array(y_true) == np.array(y_pred)).mean()
cm = confusion_matrix(y_true, y_pred)
```

Implementasi Prediksi Genre Musik

Prediksi genre musik yang didapatkan dari hasil evaluasi model disimpan ke dalam format `.csv` yang disusun dengan bantuan *library pytorch*, *numpy*, *pandas*, *os*, dan *time*. Kode Program 14 merupakan implementasi tahap prediksi genre musik.

Kode Program 14 Prediksi Genre Musik

```
import torch
import numpy as np
import pandas as pd
import os
import time

# Initialize variables
y_true = []
y_pred = []

model.eval()
```

```
with torch.no_grad():
    for images, _ in test_loader:
        outputs = model(images)
        probs = torch.softmax(outputs, dim=1)
        preds = torch.argmax(probs, dim=1)

        y_pred.extend(preds.cpu().numpy())
        confidence.extend(torch.max(probs, dim=1).values.cpu().numpy())
```

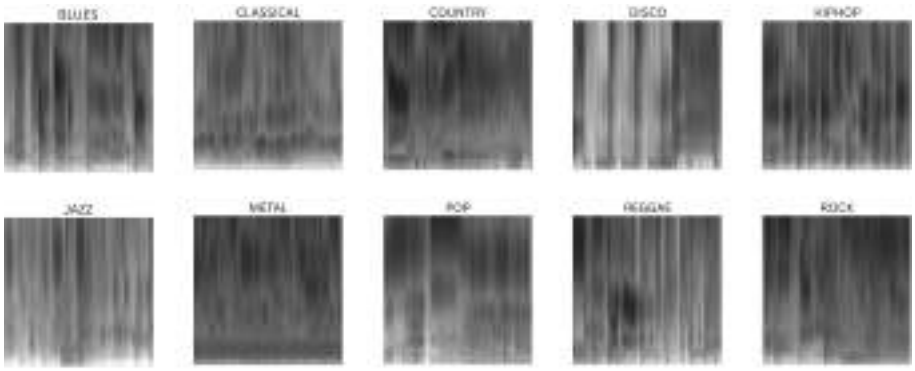
BAB V
HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil percobaan dari pelatihan dan pengujian penerapan kombinasi metode ResNet dan Bi-GRU untuk klasifikasi genre musik berbasis fusi citra *scalogram-spectrogram*, yang mencakup perbandingan beberapa konfigurasi *hyperparameter*, metode fusi terbaik, dan evaluasi kinerja model baik menggunakan dataset sekunder maupun primer.

5.1 Ekstraksi Fitur

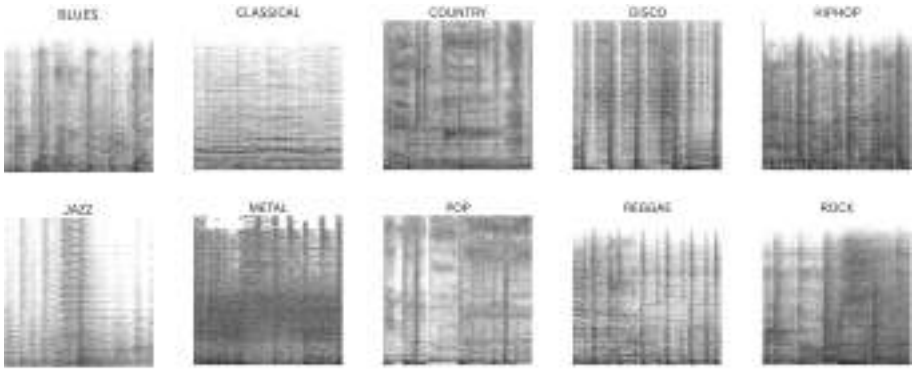
Dataset audio terlebih dahulu dinormalisasi amplitudonya ke dalam rentang $(-1, 1)$. Selanjutnya, audio `jazz.00054.wav` dihapus karena memiliki durasi yang terlalu pendek, serta audio `reggae.00086.wav` dihapus karena mengalami kerusakan data. Setelah tahap praproses tersebut, dilakukan ekstraksi fitur menggunakan *Continuous Wavelet Transform* (CWT) untuk menghasilkan citra *scalogram* dan *Short-Time Fourier Transform* (STFT) untuk menghasilkan citra *spectrogram*.

Citra *scalogram* didapatkan melalui *Continuous Wavelet Transform* (CWT) dengan *mother wavelet* yaitu *morlet*. Gambar 5.1 adalah beberapa contoh citra *scalogram* yang telah dilakukan *cropping image* untuk masing-masing genre.



Gambar 5.1 Contoh Citra *Scalogram* Masing-Masing Genre

Citra *spectrogram* didapatkan melalui *Short-Time Fourier Transform* (STFT) dengan parameter `n_fft = 2048`, `hop_size = 512`, dan `window = 'hann'`. Gambar 5.2 adalah beberapa contoh citra *spectrogram* yang telah dilakukan *cropping image* untuk masing-masing genre.

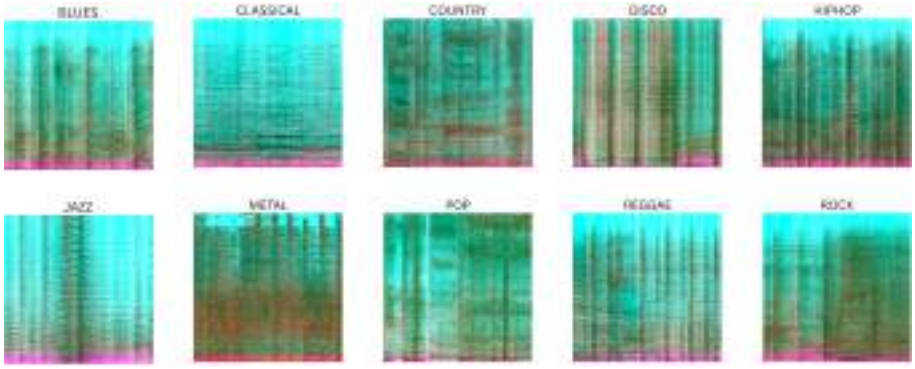


Gambar 5.2 Contoh Citra *Spectrogram* Masing-Masing Genre

Selanjutnya citra *grayscale spectrogram* dan *grayscale scalogram* dilakukan proses fusi sesuai dengan skenario yang telah dijelaskan pada Bab 4. Setiap metode fusi dibandingkan setiap performansinya di tahap pelatihan model.

1. *Maximum*

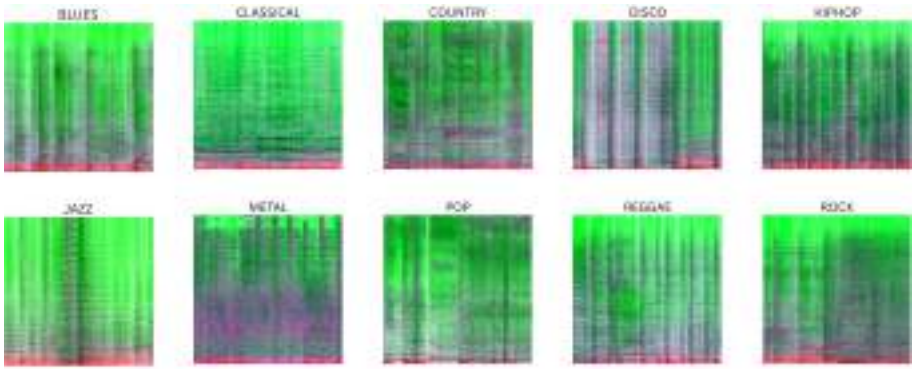
   Gambar 5.3 adalah contoh citra fusi menggunakan metode *maximum* untuk masing-masing genre.



Gambar 5.3 Contoh Citra Fusi dengan Metode *Maximum*

2. *Minimum*

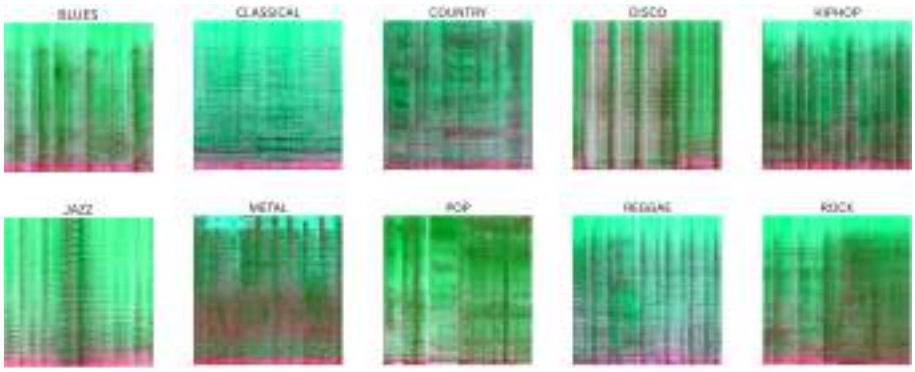
   Gambar 5.4 adalah contoh citra fusi menggunakan metode *minimum* untuk masing-masing genre.



Gambar 5.4 Contoh Citra Fusi dengan Metode *Minimum*

3. *Average*

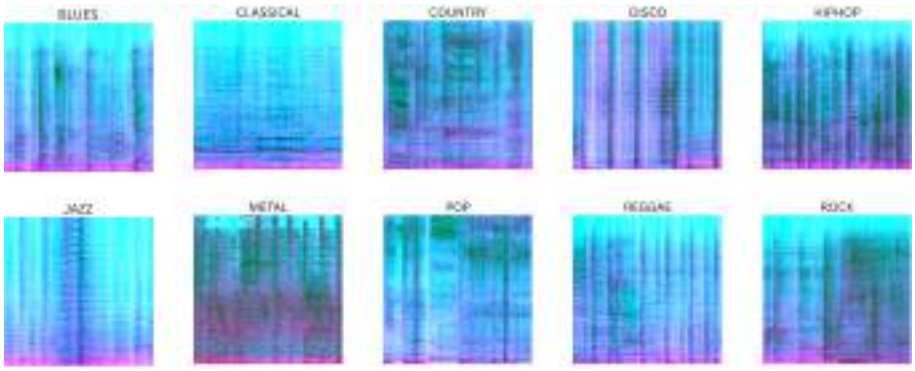
   Gambar 5.5 adalah contoh citra fusi menggunakan metode *average* untuk masing-masing genre.



Gambar 5.5 Contoh Citra Fusi dengan Metode *Average*

4. *Addition*

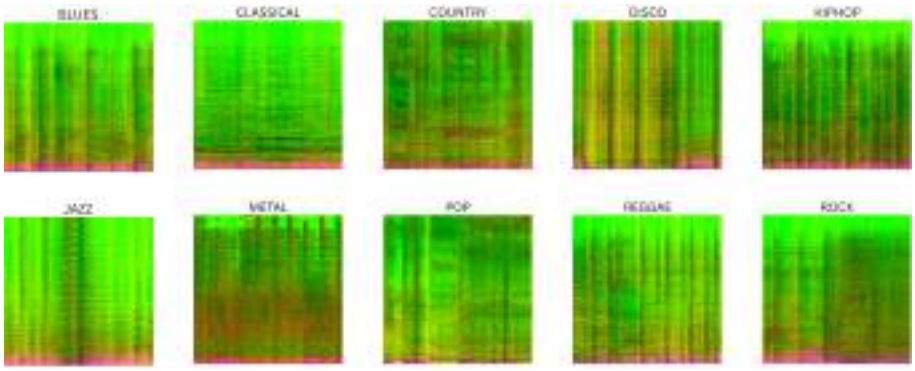
   Gambar 5.6 adalah contoh citra fusi menggunakan metode *addition* untuk masing-masing genre.



Gambar 5.6 Contoh Citra Fusi dengan Metode *Addition*

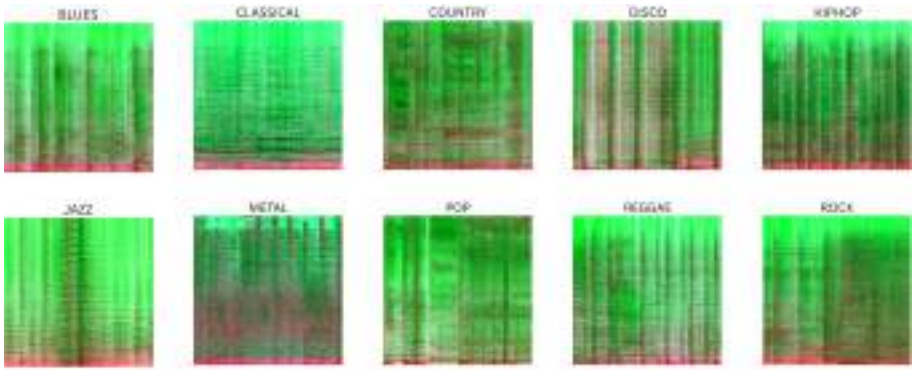
5. *Subtraction*

   Gambar 5.7 adalah contoh citra fusi menggunakan metode *subtraction* untuk masing-masing genre.



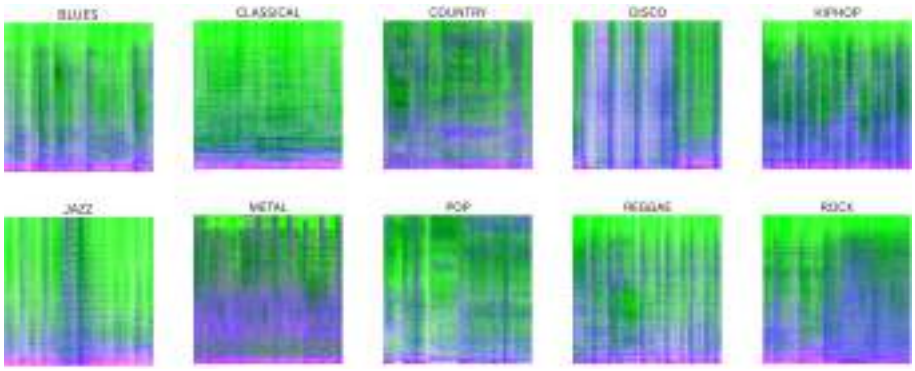
Gambar 5.7 Contoh Citra Fusi dengan Metode *Subtraction*

6. *Multiplication*
   Gambar 5.8 adalah contoh citra fusi menggunakan metode *multiplication* untuk masing-masing genre.



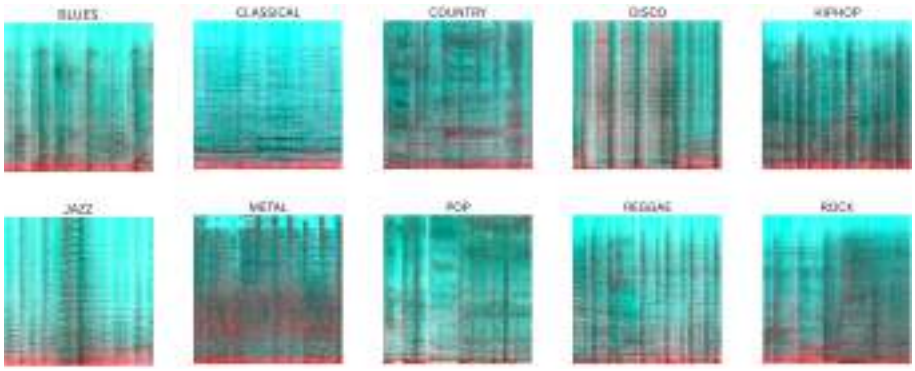
Gambar 5.8 Contoh Citra Fusi dengan Metode *Multiplication*

7. *Division*
   Gambar 5.9 adalah contoh citra fusi menggunakan metode *division* untuk masing-masing genre.



Gambar 5.9 Contoh Citra Fusi menggunakan Metode *Division*

8. *Weighted Average*
   Gambar 5.10 adalah contoh citra fusi menggunakan metode *weighted average* dengan $\alpha = 0.1$ untuk masing-masing genre.



Gambar 5.10 Contoh Citra Fusi dengan Metode *Weighted Average*

5.2 Hasil Pelatihan Model

Pelatihan model dilakukan melalui beberapa tahap. Tahap awal dimulai dengan penentuan *hyperparameter* terbaik untuk memperoleh akurasi validasi tertinggi. Data latih dan validasi yang digunakan berasal dari dataset sekunder dan dataset primer yang telah difusikan menggunakan metode *weighted average* dengan nilai parameter $\alpha = 0.1$ dan dibagi menggunakan metode *Stratified Sampling*. Selanjutnya, dilakukan perbandingan beberapa metode fusi untuk menentukan metode fusi terbaik. Metode fusi terpilih kemudian diaplikasikan pada dataset yang dibagi menggunakan metode *Group Shuffle Split*, dan hasil performansinya dibandingkan. Setelah itu, dilakukan penentuan *Pooling Layer* yang paling optimal antara *Max Pooling* dan *Average Pooling*. Tahap akhir dilakukan dengan membandingkan performansi beberapa model, yaitu ResNet, Bi-GRU, ResNet-BiGRU, dan BiGRU-ResNet. Uji coba yang dilakukan dalam penelitian ini menggunakan kombinasi model ResNet18 dan Bi-GRU dengan `optimizer = Adam` dengan `weight decay = 1e-4`, `learning rate = 1e-4` dan `reduce learning rate = 1e-7`, serta `epoch = 70`. Proses pelatihan terus dilakukan untuk menentukan epoch terbaik berdasarkan nilai *validation loss* terendah. Beberapa contoh hasil percobaan *tuning hyperparameter* dapat dilihat pada Tabel 5.1 dan Tabel 5.2.

Tabel 5.1 Hasil Akurasi Model dengan Modifikasi *Hyperparameter*

No	***Hyperparameter***		***Best Epoch***	***Learning Rate***	**Pelatihan**	**Validasi**
1	*Dropout rate*	0.1, 0.1, 0.1	68	2.5e-5	0.9982	0.9549
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
2	*Dropout rate*	0.1, 0.1, 0.1	69	1.25e-5	0.9995	0.9557
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	64				
	Batch size	32				
3	*Dropout rate*	0.1, 0.1, 0.1	56	2.5e-5	0.9993	0.9557
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	32				
4	*Dropout rate*	0.1, 0.1, 0.1	59	2.5e-5	0.9988	0.9611
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	16				



Gambar 5.11 Grafik Akurasi Model Percobaan Ke-4

Tabel 5.2 Hasil *Loss* Model dengan Modifikasi *Hyperparameter*

No	***Hyperparameter***		***Best Epoch***	***Learning Rate***	**Pelatihan**	**Validasi**
1	*Dropout rate*	0.1, 0.1, 0.1	68	2.5e-5	0.0072	0.1812
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
2	*Dropout rate*	0.1, 0.1, 0.1	69	1.25e-5	0.0036	0.1806
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	64				
	Batch size	32				
3	*Dropout rate*	0.1, 0.1, 0.1	56	2.5e-5	0.0028	0.1769
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	32				
4	*Dropout rate*	0.1, 0.1, 0.1	59	2.5e-5	0.0038	0.1594
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	16				



Gambar 5.12 Grafik *Loss* Model Percobaan Ke-4

Berdasarkan percobaan tersebut, didapatkan bahwa *hyperparameter* terbaik ditunjukkan pada percobaan ke-4, dengan hasil akurasi validasi sebesar 96.11%. Selanjutnya, dicari metode fusi yang mampu memberikan kinerja terbaik dalam klarifikasi genre musik dengan membandingkan hasil performansi menggunakan dataset dengan metode fusi *maximum*, *minimum*, *average*, *addition*, *subtraction*, *multiplication*, *division*, dan *weighted average*. Hasil performansi model untuk setiap metode fusi dituliskan pada Tabel 5.3.

Tabel 5.3 Hasil Performansi dari Setiap Metode Fusi

Fusi		**Pelatihan**		**Validasi**	
		Akurasi	***Loss***	**Akurasi**	***Loss***
Maximum		0.9966	0.0081	0.9484	0.1896
Minimum		0.9988	0.0033	0.9549	0.1828
Average		0.9986	0.0045	0.9607	0.1618
Addition		0.9992	0.0026	0.9569	0.1843
Subtraction		0.9990	0.0034	0.9488	0.1933
Multiplication		0.9952	0.0117	0.9522	0.1758
Division		0.9944	0.0165	0.9572	0.1835
Weighted Average	0.1	0.9988	0.0038	0.9611	0.1594
	0.3	0.9988	0.0028	0.9569	0.1695
	0.5	0.9985	0.0037	0.9619	0.1587
	0.7	0.9967	0.0095	0.9480	0.1969
	0.9	0.9957	0.0131	0.9484	0.2074

Hasil pelatihan masing-masing dataset dengan metode fusi *maximum*, *minimum*, *average*, *addition*, *subtraction*, *multiplication*, *division*, dan *weighted average* ditunjukkan sebagai berikut.

1. *Maximum*
   Hasil akurasi pelatihan, akurasi validasi, *loss* pelatihan, dan *loss* validasi dapat dilihat pada Tabel 5.4.

Tabel 5.4 Hasil Performansi Model Menggunakan Metode Fusi *Maximum*

Epochs	***Learning Rate***	**Pelatihan**		**Validasi**	
		Akurasi	***Loss***	**Akurasi**	***Loss***
10	1e-4	0.9455	0.1638	0.8821	0.4153
20		0.9745	0.0809	0.9029	0.3484
30		0.9830	0.0502	0.9195	0.3042
40		0.9833	0.0494	0.9145	0.3302
50	5e-5	0.9920	0.0235	0.9337	0.2534
60		0.9959	0.0148	0.9368	0.2178
70	2.5e-5	0.9984	0.0042	0.9453	0.2274
Best Epochs = 53		0.9966	0.0081	0.9484	0.1896



Gambar 5.13 Grafik Akurasi Model dengan Metode Fusi *Maximum*



Gambar 5.14 Grafik *Loss* Model dengan Metode Fusi *Maximum*

2. *Minimum*
   Hasil akurasi pelatihan, akurasi validasi, *loss* pelatihan, dan *loss* validasi dapat dilihat pada Tabel 5.5.

Tabel 5.5 Hasil Performansi Model Menggunakan Metode Fusi *Minimum*

Epochs	***Learning Rate***	**Pelatihan**		**Validasi**	
		Akurasi	***Loss***	**Akurasi**	***Loss***
10	1e-5	0.9417	0.1738	0.8937	0.3375
20		0.9721	0.0842	0.9199	0.2782
30		0.9795	0.0632	0.9033	0.3608
40	5e-5	0.9964	0.0118	0.9376	0.2261
50		0.9964	0.0152	0.9364	0.2325
60	2.5e-5	0.9979	0.0069	0.9542	0.2004
70		0.9971	0.0077	0.9453	0.2233
Best Epochs = 67		0.9988	0.0033	0.9549	0.1828



Gambar 5.15 Grafik Akurasi Model dengan Metode Fusi *Minimum*



Gambar 5.16 Grafik *Loss* Model dengan Metode Fusi *Minimum*

3. *Average*
   Hasil akurasi pelatihan, akurasi validasi, *loss* pelatihan, dan *loss* validasi dapat dilihat pada Tabel 5.6.

Tabel 5.6 Hasil Performansi Model Menggunakan Metode Fusi *Average*

Epochs	***Learning Rate***	**Pelatihan**		**Validasi**	
		Akurasi	***Loss***	**Akurasi**	***Loss***
10	1e-4	0.9411	0.1740	0.8740	0.4093
20		0.9749	0.0767	0.9168	0.3041
30		0.9797	0.0593	0.9160	0.3002
40		0.9823	0.0562	0.9318	0.2634
50	5e-5	0.9960	0.0132	0.9380	0.2476
60	2.5e-5	0.9986	0.0041	0.9545	0.1946
70		0.9979	0.0057	0.9576	0.1738
Best Epochs = 65		0.9986	0.0045	0.9607	0.1618



Gambar 5.17 Grafik Akurasi Model dengan Metode Fusi *Average*



Gambar 5.18 Grafik *Loss* Model dengan Metode Fusi *Average*

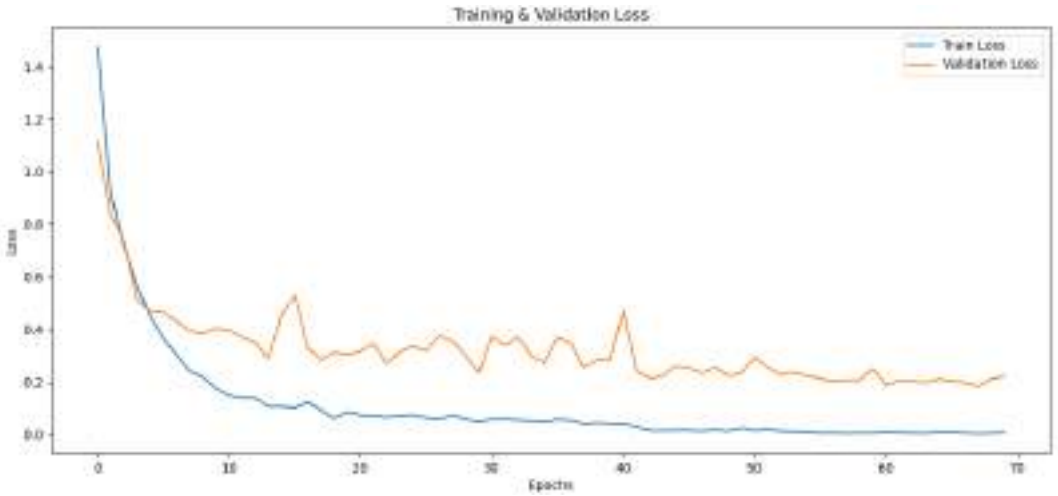
4. *Addition*
   Hasil akurasi pelatihan, akurasi validasi, *loss* pelatihan, dan *loss* validasi dapat dilihat pada Tabel 5.7.

Tabel 5.7 Hasil Performansi Model Menggunakan Metode Fusi *Addition*

Epochs	***Learning Rate***	**Pelatihan**		**Validasi**	
		Akurasi	***Loss***	**Akurasi**	***Loss***
10	1e-4	0.9411	0.1765	0.8752	0.4042
20		0.9709	0.0861	0.9160	0.3054
30		0.9834	0.0494	0.9372	0.2356
40		0.9846	0.0413	0.9180	0.2846
50	5e-5	0.9919	0.0237	0.9407	0.2340
60	2.5e-5	0.9984	0.0040	0.9411	0.2495
70		0.9977	0.0058	0.9480	0.2195
Best Epochs = 68		0.9992	0.0026	0.9569	0.1843



Gambar 5.19 Grafik Akurasi Model dengan Metode Fusi *Addition*



Gambar 5.20 Grafik *Loss* Model dengan Metode Fusi *Addition*

5. *Subtraction*
   Hasil akurasi pelatihan, akurasi validasi, *loss* pelatihan, dan *loss* validasi dapat dilihat pada Tabel 5.8.

Tabel 5.8 Hasil Performansi Model Menggunakan Metode Fusi *Subtraction*

Epochs	***Learning Rate***	**Pelatihan**		**Validasi**	
		Akurasi	***Loss***	**Akurasi**	***Loss***
10	1e-4	0.9380	0.1820	0.8760	0.3956
20		0.9708	0.0882	0.9164	0.2928
30		0.9871	0.0373	0.9041	0.3903
40		0.9849	0.0481	0.9249	0.2806
50	5e-5	0.9974	0.0093	0.9476	0.2167
60	2.5e-5	0.9975	0.0067	0.9403	0.2334
70		0.9978	0.0051	0.9484	0.2049
Best Epochs = 62		0.9990	0.0034	0.9488	0.1933



Gambar 5.21 Grafik Akurasi Model dengan Metode Fusi *Subtraction*

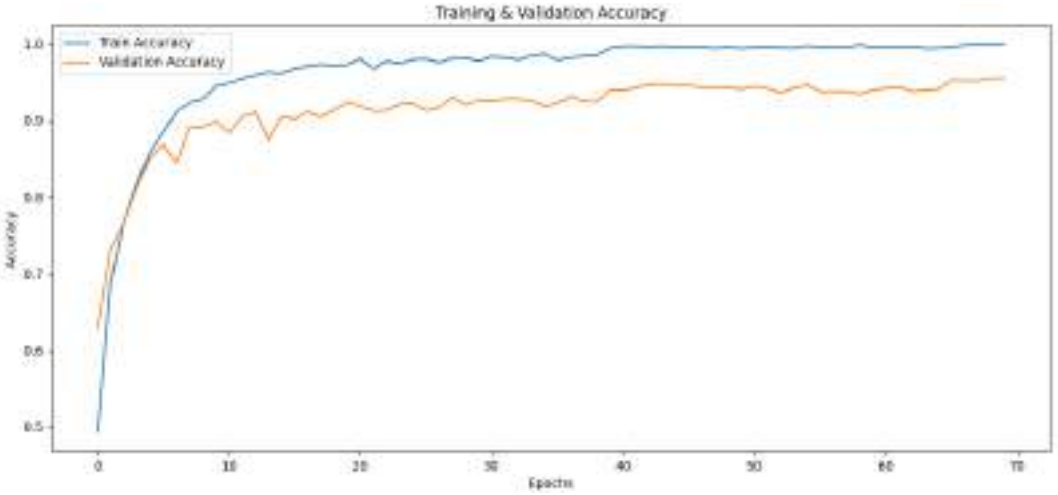


Gambar 5.22 Grafik *Loss* Model dengan Metode Fusi *Subtraction*

6. *Multiplication*
   Hasil akurasi pelatihan, akurasi validasi, *loss* pelatihan, dan *loss* validasi dapat dilihat pada Tabel 5.9.

Tabel 5.9 Hasil Performansi Model Menggunakan Metode Fusi *Multiplication*

Epochs	***Learning Rate***	**Pelatihan**		**Validasi**	
		Akurasi	***Loss***	**Akurasi**	***Loss***
10	1e-4	0.9444	0.1655	0.8991	0.3389
20		0.9727	0.0872	0.9241	0.2749
30		0.9774	0.0677	0.9268	0.2549
40	5e-5	0.9938	0.0213	0.9399	0.2181
50		0.9934	0.0162	0.9403	0.2449
60		0.9949	0.0146	0.9395	0.2396
70	2.5e-5	0.9981	0.0048	0.9542	0.1793
Best Epochs = 66		0.9952	0.0117	0.9522	0.1758



Gambar 5.23 Grafik Akurasi Model dengan Metode Fusi *Multiplication*



Gambar 5.24 Grafik *Loss* Model dengan Metode Fusi *Multiplication*

7. *Division*
   Hasil akurasi pelatihan, akurasi validasi, *loss* pelatihan, dan *loss* validasi dapat dilihat pada Tabel 5.10.

Tabel 5.10 Hasil Performansi Model Menggunakan Metode Fusi *Division*

Epochs	***Learning Rate***	**Pelatihan**		**Validasi**	
		Akurasi	***Loss***	**Akurasi**	***Loss***
10	1e-4	0.9264	0.2099	0.8621	0.4428
20		0.9739	0.0776	0.9041	0.3527
30		0.9750	0.0766	0.9268	0.2647
40		0.9861	0.0435	0.9187	0.3033
50		0.9798	0.0595	0.9110	0.3222
60	5e-5	0.9968	0.0095	0.9488	0.1972
70		0.9949	0.0153	0.9461	0.2024
Best Epochs = 66		0.9944	0.0165	0.9572	0.1835



Gambar 5.25 Grafik Akurasi Model dengan Metode Fusi *Division*



Gambar 5.26 Grafik *Loss* Model dengan Metode Fusi *Division*

8. *Weighted Average*
   Hasil akurasi pelatihan, akurasi validasi, *loss* pelatihan, dan *loss* validasi dapat dilihat pada Tabel 5.11.

Tabel 5.11 Hasil Performansi Model Menggunakan Metode Fusi *Weighted Average*

α	***Epochs***	***Learning Rate***	**Pelatihan**		**Validasi**	
			Akurasi	***Loss***	**Akurasi**	***Loss***
0.1	10	1e-4	0.9415	0.1728	0.8968	0.3229
	20		0.9668	0.0981	0.8979	0.3788
	30		0.9829	0.0524	0.9299	0.2575
	40	5e-5	0.9922	0.0240	0.9468	0.1984
	50		0.9926	0.0231	0.9395	0.2399
	60	2.5e-5	0.9981	0.0053	0.9592	0.1714
	70		0.9968	0.0091	0.9545	0.1797
	Best Epochs = 59		0.9988	0.0038	0.9611	0.1594
0.3	10	1e-4	0.9428	0.1727	0.8721	0.3956
	20		0.9719	0.0884	0.9153	0.2972
	30		0.9804	0.0587	0.9272	0.2607
	40	5e-5	0.9930	0.0226	0.9364	0.2229
	50	2.5e-5	0.9982	0.0060	0.9468	0.2056
	60		0.9979	0.0044	0.9480	0.1980
	70	1.25e-5	0.9990	0.0029	0.9553	0.1771
	Best Epochs = 69		0.9988	0.0028	0.9569	0.1695
0.5	10	1e-4	0.9430	0.1798	0.8794	0.3961
	20		0.9698	0.0917	0.9018	0.3546
	30	5e-5	0.9933	0.0196	0.9353	0.2501
	40	2.5e-5	0.9985	0.0052	0.9545	0.1896
	50		0.9978	0.0076	0.9534	0.2008
	60	1.25e-5	0.9988	0.0033	0.9565	0.1742
	70		0.9979	0.0043	0.9580	0.1683
	Best Epochs = 68		0.9985	0.0037	0.9619	0.1587
0.7	10	1e-4	0.9402	0.1788	0.8717	0.4176
	20		0.9787	0.0669	0.9052	0.3489
	30		0.9754	0.0692	0.9172	0.3058
	40		0.9881	0.0355	0.9295	0.2719
	50		0.9868	0.0379	0.9303	0.2654
	60	5e-5	0.9945	0.0189	0.9180	0.3609
	70	2.5e-5	0.9984	0.0047	0.9484	0.2115
	Best Epochs = 52		0.9967	0.0095	0.9480	0.1969
0.9	10	1e-4	0.9474	0.1661	0.8956	0.3822
	20		0.9741	0.0792	0.9187	0.3048
	30		0.9793	0.0592	0.9126	0.3042
	40		0.9806	0.0560	0.9156	0.3489
	50	5e-5	0.9955	0.0142	0.9364	0.2530
	60		0.9966	0.0111	0.9434	0.2340
	70	2.5e-5	0.9971	0.0080	0.9380	0.2406
	Best Epochs = 57		0.9957	0.0131	0.9484	0.2074



Gambar 5.27 Grafik Akurasi Model dengan Metode Fusi *Weighted Average*



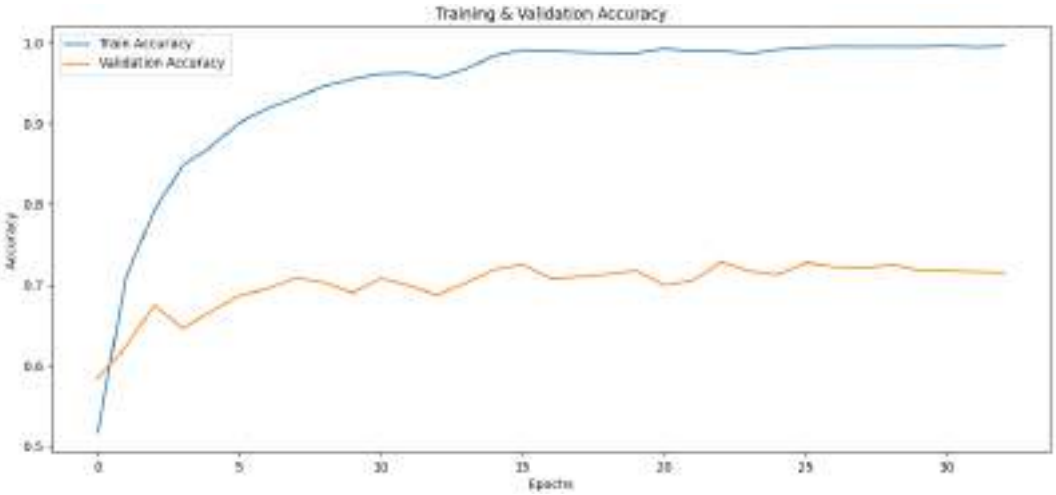
Gambar 5.28 Grafik *Loss* Model dengan Metode Fusi *Weighted Average*

Berdasarkan hasil perbandingan metode fusi tersebut, didapatkan bahwa metode fusi *weighted average* dengan $\alpha = 0.5$ menghasilkan akurasi validasi tertinggi, yaitu sebesar 96.19%, sehingga dataset tersebut yang digunakan dalam evaluasi metode pembagian data antara *Stratified Sampling* dan *Group Shuffle Split*. Hasil perbandingan performansi model berdasarkan metode *data splitting* dapat dilihat pada Tabel 5.12, sedangkan grafik performansi model menggunakan *Group Shuffle Split* dapat dilihat pada Gambar 5.29 dan Gambar 5.30.

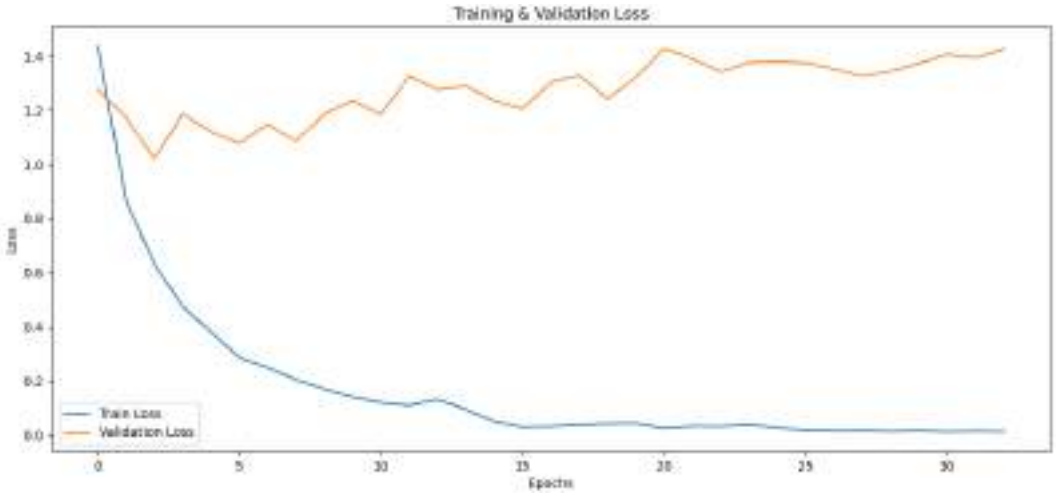
Tabel 5.12 Hasil Performansi Model Berdasarkan Metode *Split*

Pooling	***Epochs***	***Learning Rate***	**Pelatihan**		**Validasi**	
			Akurasi	***Loss***	**Akurasi**	***Loss***
Stratified Sampling	10	1e-4	0.9430	0.1798	0.8794	0.3961
	20		0.9698	0.0917	0.9018	0.3546
	30	5e-5	0.9933	0.0196	0.9353	0.2501
	40	2.5e-5	0.9985	0.0052	0.9545	0.1896

Pooling	***Epochs***	***Learning Rate***	**Pelatihan**		**Validasi**	
			Akurasi	***Loss***	**Akurasi**	***Loss***
	50		0.9978	0.0076	0.9534	0.2008
	60	1.25e-5	0.9988	0.0033	0.9565	0.1742
	70		0.9979	0.0043	0.9580	0.1683
	Best Epochs = 68		0.9985	0.0037	0.9619	0.1587
Group Shuffle Split	10	1e-4	0.9552	0.1393	0.6900	1.2374
	20	5e-5	0.9871	0.0421	0.7181	1.3238
	30	2.5e-5	0.9955	0.0141	0.7185	1.3749
	Best Epochs = 3		0.7924	0.6329	0.6750	1.0217



Gambar 5.29 Grafik Akurasi Model Menggunakan *Group Shuffle Split*



Gambar 5.30 Grafik *Loss* Model Menggunakan *Group Shuffle Split*

Dataset menggunakan *Stratified Sampling* masih menghasilkan nilai akurasi validasi yang lebih tinggi dibandingkan dengan yang menggunakan *Group Shuffle Split*. Sebelum lanjut ke tahap evaluasi dan pengujian, dilakukan perbandingan *Pooling Layer* menggunakan dataset dengan metode *Stratified Sampling* tersebut. Hasil perbandingan

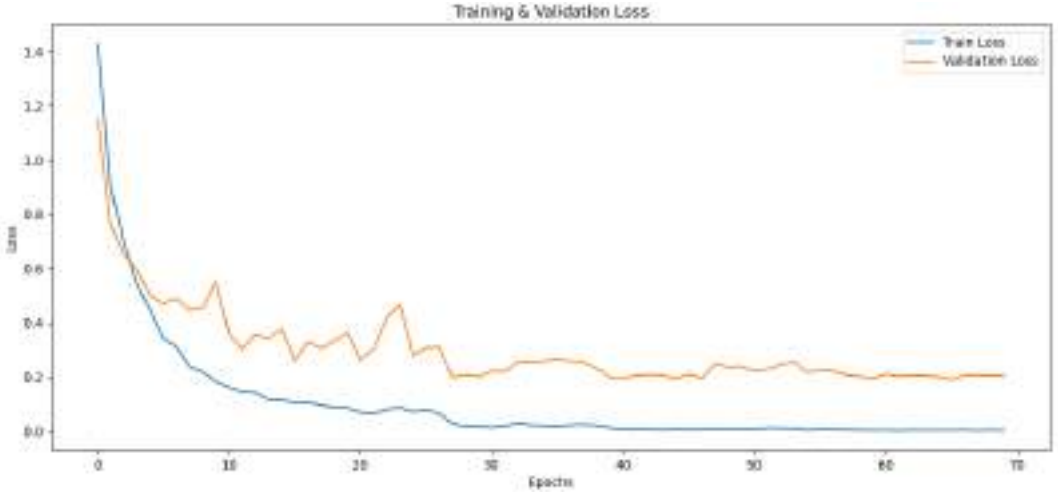
performansi model dengan modifikasi *Pooling Layer* dapat dilihat pada Tabel 5.13, dan grafik performansi model menggunakan *Average Pooling Layer* dapat dilihat pada Gambar 5.31 dan Gambar 5.32.

Tabel 5.13 Hasil Performansi Model dengan Modifikasi *Pooling Layer*

Pooling	***Epochs***	***Learning Rate***	**Pelatihan**		**Validasi**	
			Akurasi	***Loss***	**Akurasi**	***Loss***
Max Pooling	10	1e-4	0.9430	0.1798	0.8794	0.3961
	20		0.9698	0.0917	0.9018	0.3546
	30	5e-5	0.9933	0.0196	0.9353	0.2501
	40	2.5e-5	0.9985	0.0052	0.9545	0.1896
	50		0.9978	0.0076	0.9534	0.2008
	60	1.25e-5	0.9988	0.0033	0.9565	0.1742
	70		0.9979	0.0043	0.9580	0.1683
	Best Epochs = 68		0.9985	0.0037	0.9619	0.1587
Average Pooling	10	1e-4	0.9382	0.1848	0.8424	0.5499
	20		0.9712	0.0863	0.9091	0.3649
	30	5e-5	0.9946	0.0156	0.9453	0.2012
	40	2.5e-5	0.9963	0.0116	0.9492	0.1997
	50		0.9973	0.0072	0.9430	0.2382
	60	1.25e-5	0.9988	0.0034	0.9561	0.1952
	70		0.9990	0.0030	0.9526	0.2042
	Best Epochs = 66		0.9985	0.0083	0.9549	0.1906



Gambar 5.31 Grafik Akurasi Model Menggunakan *Average Pooling Layer*



Gambar 5.32 Grafik *Loss* Model Menggunakan *Average Pooling Layer*

Berdasarkan percobaan tersebut, didapatkan bahwa model dengan *Max Pooling Layer* tetap menghasilkan akurasi validasi yang lebih tinggi dibandingkan model dengan *Average Pooling Layer*. Selanjutnya, dilakukan penerapan model ResNet, Bi-GRU, ResNet-BiGRU, dan BiGRU-ResNet untuk dibandingkan nilai akurasi validasinya. Hasil performansi setiap model dapat dilihat pada Tabel 5.14.

Tabel 5.14 Hasil Performansi Model

Model	***Best Epochs***	***Learning Rate***	**Pelatihan**		**Validasi**	
			Akurasi	***Loss***	**Akurasi**	***Loss***
ResNet	54	2.5e-5	0.9984	0.0045	0.9584	0.1807
Bi-GRU	70	1e-4	0.6200	1.0757	0.5809	1.2110
ResNet-BiGRU	68	1.25e-5	0.9985	0.0037	0.9619	0.1587
BiGRU-ResNet	66	1.25e-5	0.9952	0.0199	0.8193	0.7084

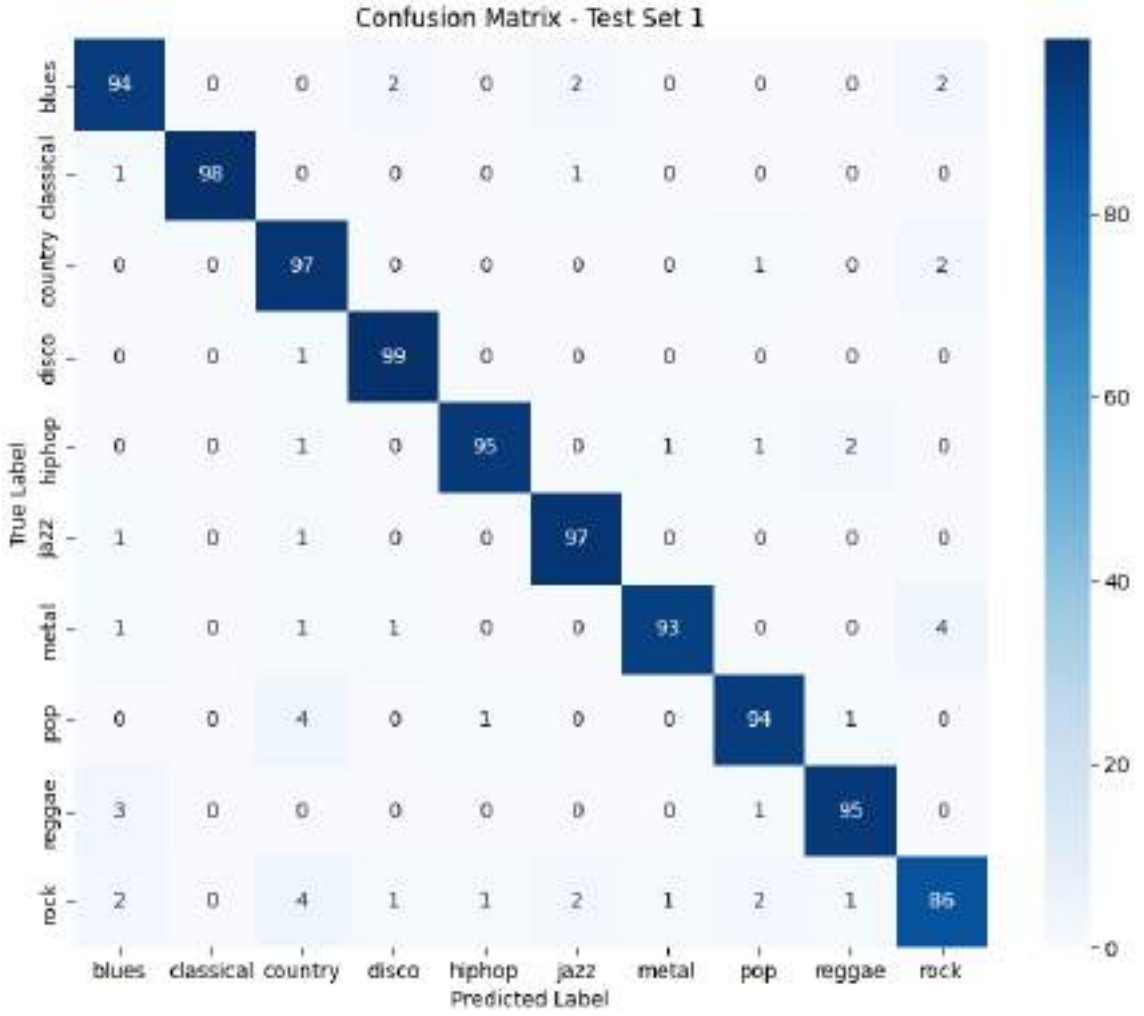
Berdasarkan perbandingan model tersebut, terbukti bahwa metode ResNet-BiGRU skenario 2 mampu menghasilkan akurasi validasi tertinggi.

5.3 Evaluasi Kinerja Model

Pengujian model dilakukan menggunakan data uji dari dataset sekunder dan dataset primer yang didapatkan melalui proses *data splitting* . Data uji tersebut telah difusikan menggunakan metode *weighted average* dengan nilai $\alpha = 0.5$ serta menggunakan kombinasi *hyperparameter* dan model terbaik yang telah didapatkan pada subbab sebelumnya.

5.3.1 Dataset Sekunder

Confusion Matrix hasil pengujian menggunakan data uji dari dataset sekunder dapat dilihat pada Gambar 5.33.



Gambar 5.33 *Confusion Matrix* Dataset Sekunder dengan *Hyperparameter* Terbaik

Berdasarkan *Confusion Matrix* tersebut, dapat dihitung nilai akurasinya berikut ini.

$$acc = \frac{94 + 98 + 97 + 99 + 95 + 97 + 93 + 94 + 95 + 86}{998} = 0.9499.$$

Nilai akurasi yang didapat menggunakan dataset sekunder adalah sebesar 0.9499 atau 94.99%. Untuk perhitungan metrik evaluasi yang lainnya, diambil contoh perhitungan pada kelas 'blues'.

1. Presisi

$$P = \frac{94}{94 + 1 + 0 + 0 + 0 + 1 + 1 + 0 + 3 + 2} = 0.9216$$

2. *Recall*

$$R = \frac{94}{94 + 0 + 0 + 2 + 0 + 2 + 0 + 0 + 0 + 2} = 0.9400$$

3. F1-*score*

$$F1 - score = 2 \times \frac{0.9216 \times 0.9400}{0.9216 + 0.9400} = 0.9307$$

Selanjutnya, penulis membandingkan metrik evaluasi model ResNet, Bi-GRU, ResNet-BiGRU, dan BiGRU-ResNet. Hasil perbandingan dapat dilihat pada Tabel 5.15.

Tabel 5.15 Metrik Evaluasi Tiap Model

Model	***Accuracy***	***Precision***	***Recall***	***F1-score***	***Testing Time***
ResNet	0.9539	0.9540	0.9540	0.9540	0.3262
Bi-GRU	0.6172	0.5950	0.5880	0.5810	0.6687
ResNet-BiGRU	0.9499	0.9500	0.9500	0.9500	0.4241
BiGRU-ResNet	0.8026	0.8060	0.8030	0.8020	0.8937

Berdasarkan tabel tersebut, didapatkan bahwa model ResNet menghasilkan performasi yang unggul baik dari nilai *accuracy*, *precision*, *recall*, maupun waktu pengujiannya. Selanjutnya, penulis menguji performansi masing-masing citra *scalogram*, *spectrogram*, dan fusi *weighted average* dengan nilai parameter $\alpha = 0.5$ sebagai *input* menggunakan kombinasi *hyperparameter* terbaik yang telah didapatkan pada subbab sebelumnya.

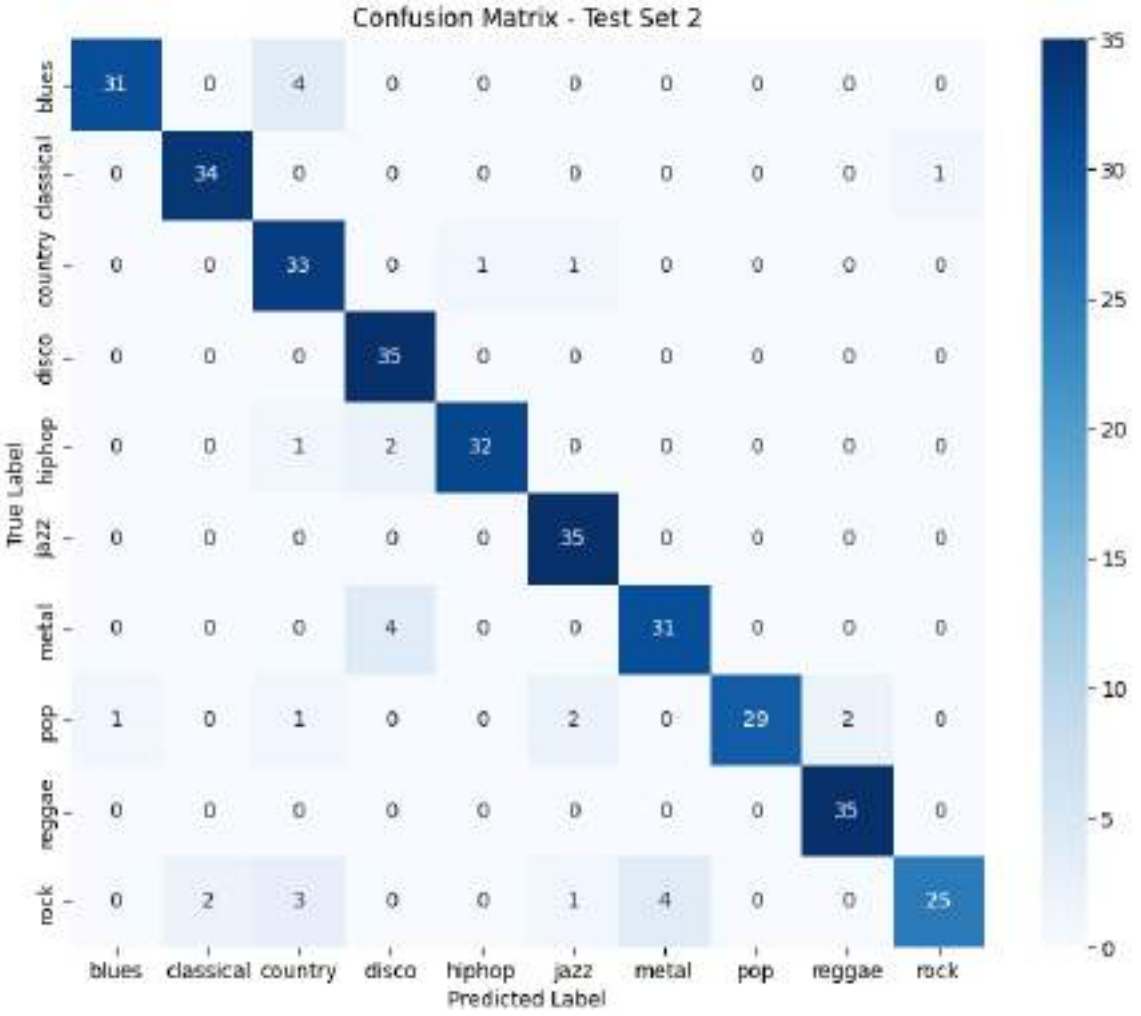
Tabel 5.16 Hasil Evaluasi Model Menggunakan *Input* Fitur yang Berbeda

Feature Input	***Accuracy***	***Precision***	***Recall***	***F1-score***	***Testing Time***
Scalogram	0.8667	0.8670	0.8670	0.8640	0.4483
Spetrogram	0.9539	0.9540	0.9540	0.9530	0.3867
Fusi	0.9499	0.9500	0.9500	0.9500	0.4241

Berdasarkan tabel tersebut, didapatkan bahwa *input spectrogram* menghasilkan metrik evaluasi yang lebih tinggi dibandingkan dengan *input* citra fusi.

5.3.2 Dataset Primer

Evaluasi kinerja model dilakukan menggunakan dataset primer dan diuji pada bagian lagu yang berbeda. Pengujian dilakukan pada bagian lagu di menit 0:30-1:00, 1:00-1:30, 1:30-2:00, 2:00-2:30, dan 2:30-3:00. *Confusion Matrix* hasil pengujian menggunakan dataset primer di menit 0:30-1:00 dapat dilihat pada Gambar 5.34.



Gambar 5.34 *Confusion Matrix* Dataset Primer dengan *Hyperparameter* Terbaik

Berdasarkan *Confusion Matrix* tersebut, dapat dihitung nilai presisi dan *recall* pada kelas 'blues' sebagai berikut.

$$P = \frac{31}{31+0+0+0+0+0+0+1+0+0} = 0.9688$$
$$R = \frac{31}{31+0+4+0+0+0+0+0+0+0} = 0.8857$$

sehingga didapatkan

$$F1 - score = 2 \times \frac{0.9688 \times 0.8857}{0.9688 + 0.8857} = 0.9254.$$

Hasil klasifikasi model terhadap beberapa dataset primer di menit 0:30-1:00 dapat dilihat pada Tabel 5.17.

Tabel 5.17 Hasil Klasifikasi Genre Musik Beberapa Dataset Primer

Genre Aktual	**Lagu**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
blues	John Mayer Gravity	0.93588	blues	0.0058
classical	Franz Liszt Liebestraum	0.99961	classical	0.0024
country	George Strait The Book	0.98266	country	0.0038
disco	Boney M Daddy Cool	0.94586	disco	0.0029
hiphop	Eminem My Name Is	0.99553	hiphop	0.0015
jazz	Andien Pulang	0.99919	jazz	0.0015
metal	Slipknot Nero Forte	0.99958	metal	0.0026
pop	Anji DIA	0.98928	pop	0.0042
reggae	MAGIC! No Way No	0.99936	reggae	0.0030
rock	The Struts Kiss This	0.99752	rock	0.0035

Contoh hasil klasifikasi pada bagian lagu yang berbeda dapat dilihat pada Tabel 5.18.

Tabel 5.18 Hasil Klasifikasi Genre Musik pada Bagian Lagu Berbeda

Genre Aktual	**Lagu**	**Bagian**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
blues	John Mayer Gravity	0:30-1:00	0.93588	blues	0.0058
		1:00-1:30	0.96617	blues	0.0056
		1:30-2:00	0.99971	blues	0.0056
		2:00-2:30	0.99587	blues	0.0061
		2:30-3:00	0.92307	blues	0.0057
		reff	0.99896	blues	0.0056
classical	Franz Liszt Liebestraum	0:30-1:00	0.99961	classical	0.0024
		1:00-1:30	0.99901	classical	0.0031
		1:30-2:00	0.99952	classical	0.0031
		2:00-2:30	0.99972	classical	0.0036
		2:30-3:00	0.99864	classical	0.0031
		reff	0.99968	classical	0.0037
country	George Strait The Book	0:30-1:00	0.98266	country	0.0038
		1:00-1:30	0.96050	country	0.0031
		1:30-2:00	0.99603	country	0.0033
		2:00-2:30	0.99925	country	0.0033
		2:30-3:00	0.99973	country	0.0034
		reff	0.99966	country	0.0034
disco	Boney M Daddy Cool	0:30-1:00	0.94586	disco	0.0029
		1:00-1:30	0.99719	disco	0.0030
		1:30-2:00	0.87155	disco	0.0029
		2:00-2:30	0.99689	disco	0.0029
		2:30-3:00	0.99412	disco	0.0030
		reff	0.98602	disco	0.0032
hiphop	Eminem My Name Is	0:30-1:00	0.99553	hiphop	0.0015

Genre Aktual	**Lagu**	**Bagian**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
		1:00-1:30	0.99929	hiphop	0.0020
		1:30-2:00	0.94963	hiphop	0.0021
		2:00-2:30	0.99942	hiphop	0.0020
		2:30-3:00	0.99872	hiphop	0.0019
		reff	0.99946	hiphop	0.0017
jazz	Andien Pulang	0:30-1:00	0.99919	jazz	0.0015
		1:00-1:30	0.99893	jazz	0.0020
		1:30-2:00	0.99959	jazz	0.0019
		2:00-2:30	0.99845	jazz	0.0019
		2:30-3:00	0.93156	jazz	0.0023
		reff	0.93967	jazz	0.0022
metal	Slipknot Nero Forte	0:30-1:00	0.99958	metal	0.0026
		1:00-1:30	0.99940	metal	0.0030
		1:30-2:00	0.99951	metal	0.0024
		2:00-2:30	0.99961	metal	0.0032
		2:30-3:00	0.99964	metal	0.0032
		reff	0.99952	metal	0.0030
pop	Anji DIA	0:30-1:00	0.98928	pop	0.0042
		1:00-1:30	0.97552	pop	0.0033
		1:30-2:00	0.94555	pop	0.0025
		2:00-2:30	0.98541	pop	0.0033
		2:30-3:00	0.93772	pop	0.0036
		reff	0.97586	pop	0.0037
reggae	MAGIC! No Way No	0:30-1:00	0.99936	reggae	0.0030
		1:00-1:30	0.95063	reggae	0.0028
		1:30-2:00	0.99928	reggae	0.0027
		2:00-2:30	0.94426	reggae	0.0027
		2:30-3:00	0.91985	reggae	0.0027
		reff	0.99643	reggae	0.0020
rock	The Struts Kiss This	0:30-1:00	0.99752	rock	0.0035
		1:00-1:30	0.99987	rock	0.0041
		1:30-2:00	0.99902	rock	0.0025
		2:00-2:30	0.99987	rock	0.0022
		2:30-3:00	0.93655	rock	0.0023
		reff	0.99987	rock	0.0024

Berdasarkan tabel tersebut, dapat dilihat bahwa model ResNet-BiGRU mampu mengklasifikasikan genre musik dengan sangat baik karena mampu memprediksi setiap bagian lagu dengan tepat. Hasil akurasi pengujian dataset primer yang diperoleh melalui metrik evaluasi dapat dilihat pada Tabel 5.19.

Tabel 5.19 Akurasi Pengujian pada Bagian Lagu Berbeda

No.	Bagian Lagu	Akurasi
1.	Menit 0:30-1:00	91.43%
2.	Menit 1:00-1:30	94.57%
3.	Menit 1:30-2:00	92.29%
4.	Menit 2:00-2:30	92.86%
5.	Menit 2:30-3:00	92.29%
6.	*Reff*	87.14%

Tabel lengkap hasil klasifikasi dengan dataset primer dapat dilihat pada Lampiran 4.

5.4 Pembahasan

Pada percobaan pertama, proses pelatihan dan validasi dilakukan menggunakan dataset sekunder yang telah difusikan dengan metode *weighted average* menggunakan nilai parameter $\alpha = 0.1$, karena konfigurasi tersebut terbukti mampu menghasilkan akurasi validasi tertinggi menurut Paramarta (2023). Selain itu, *data splitting* dilakukan menggunakan *Stratified Sampling* untuk menjaga proporsi setiap kelas dalam dataset. Percobaan diawali dengan melakukan *tuning* beberapa *hyperparameter*, yaitu *dropout*, *max pooling*, *hidden size*, dan *batch size* seperti yang telah disebutkan pada subbab sebelumnya. Tujuan dari *tuning hyperparameter* ini adalah untuk mengurangi *overfitting* dan menaikkan akurasi validasi yang dihasilkan model. Dari hasil percobaan, didapatkan bahwa kombinasi *hyperparameter* terbaik adalah dengan nilai `dropout = 0.1, 0.1, 0.1`, `max pooling = 4x4, 4x4, 4x4`, `hidden size = 256`, dan `batch size = 16`. Kombinasi *hyperparameter* tersebut mampu menghasilkan akurasi validasi sebesar 96.11%.

Selanjutnya, penulis membandingkan hasil performansi menggunakan dataset dengan metode fusi *maximum*, *minimum*, *average*, *addition*, *subtraction*, *multiplication*, *division*, dan *weighted average* dengan nilai parameter α sebesar 0.1, 0.3, 0.5, 0.7, dan 0.9. Walaupun Paramarta (2023) menyatakan bahwa metode fusi *weighted average* dengan $\alpha = 0.1$ mampu menghasilkan nilai akurasi validasi tertinggi, penulis menggunakan variasi metode fusi yang lebih beragam pada penelitian ini. Oleh karena itu, seluruh metode fusi tersebut perlu dievaluasi untuk menentukan metode fusi yang mampu menghasilkan nilai akurasi validasi tertinggi. Berdasarkan hasil pelatihan, metode *weighted average* dengan $\alpha = 0.5$ yang terbukti mampu menghasilkan nilai akurasi validasi tertinggi, yaitu sebesar 96.19%.

Setelah didapatkan kombinasi *hyperparameter* dan metode fusi terbaik, penulis mencoba mengaplikasikan kombinasi *hyperparameter* tersebut pada dataset yang menggunakan *Group Shuffle Split*. Namun, dataset tersebut ternyata hanya mampu menghasilkan akurasi validasi sebesar 67.50%.

Berikutnya, penulis mencoba memodifikasi model ResNet-BiGRU dengan mengubah *Pooling Layer* dari *Max Pooling* menjadi *Average Pooling*. Hasil akurasi model menggunakan *Average Pooling* sebenarnya cukup tinggi, yaitu sebesar 95.49%, namun masih lebih rendah dibandingkan menggunakan *Max Pooling*.

Setelah didapatkan seluruh kombinasi *hyperparameter* dan metode fusi yang dapat menghasilkan performansi terbaik, penulis menerapkan kombinasi tersebut ke model ResNet, Bi-GRU, ResNet-BiGRU, dan BiGRU-ResNet unuk dibandingkan performansinya. ResNet-BiGRU adalah kondisi dimana ResNet digunakan untuk

mengekstraksi fitur spasial dari citra hasil fusi yang kemudian fitur spasial tersebut diratakan menjadi *sequence* (urutan) sehingga dapat diproses oleh Bi-GRU untuk mempelajari dependensi *sequential* antar *patch* fitur. Selain itu, BiGRU-ResNet adalah kondisi dimana Bi-GRU digunakan terlebih dahulu untuk memodelkan dependensi temporal dari citra fusi yang direpresentasikan sebagai *sequence*, kemudian ResNet digunakan untuk ekstraksi fitur spasial dari *output* Bi-GRU. Berdasarkan percobaan tersebut, terbukti bahwa model ResNet-BiGRU mampu menghasilkan performansi terbaik dibandingkan dengan model lainnya. Model Bi-GRU hanya mampu menghasilkan akurasi validasi sebesar 58.09%, sedangkan BiGRU-ResNet sebesar 81.93%, dan ResNet sebesar 95.84%.

Berdasarkan *Confusion Matrix* pada dataset sekunder, performa model secara umum sudah cukup baik, terlihat dari tingginya jumlah prediksi benar pada hampir seluruh genre. Genre *disco* dan *classical* menunjukkan performa terbaik karena memiliki pola spektral dan temporal yang khas pada citra *scalogram* dan *spectrogram*. Musik *classical* cenderung memiliki struktur harmonik yang stabil dan minim gangguan ritmis, sedangkan *disco* didominasi ritme dan tempo yang konsisten serta pola frekuensi tinggi yang repetitif, sehingga lebih mudah dipelajari oleh model. Sebaliknya, genre *rock* memiliki performa terendah, yang diduga disebabkan oleh kemiripan karakteristik akustik dengan genre lain, khususnya *country*, sehingga terjadi tumpang tindih fitur dan menyulitkan proses klasifikasi.

Selain itu, penulis membandingkan metrik evaluasi dari model ResNet, Bi-GRU, ResNet-BiGRU, dan BiGRU-ResNet. Model ResNet mampu menghasilkan metrik evaluasi yang lebih unggul dibandingkan metode lainnya. Selanjutnya, penulis membandingkan performansi antara citra *scalogram* dan *spectrogram*. Hasil percobaan menunjukkan bahwa penggunaan *spectrogram* sebagai *input* menghasilkan nilai metrik evaluasi yang lebih tinggi dibandingkan dengan citra fusi.

Dalam penelitian klasifikasi genre musik, pemilihan metrik evaluasi menjadi penting agar performa model dapat diinterpretasikan dengan tepat. Akurasi memang sering digunakan sebagai indikator awal, namun metrik ini belum cukup mewakili performa model ketika distribusi data antar genre tidak seimbang. Untuk itu, presisi dan *recall* digunakan untuk melihat sejauh mana model mampu mengidentifikasi genre secara benar dan menangkap seluruh sampel yang seharusnya terdeteksi. Karena kedua metrik tersebut menilai aspek yang berbeda, nilai yang tinggi pada satu metrik belum tentu menunjukkan performa keseluruhan yang baik. Oleh karena itu, penelitian ini menggunakan F1-*score* sebagai metrik utama karena menggabungkan presisi dan *recall* secara seimbang, sehingga memberikan penilaian yang lebih stabil dan representatif terhadap kemampuan model dalam melakukan klasifikasi genre musik.

Berdasarkan evaluasi kinerja model menggunakan dataset primer, pemilihan bagian lagu terbukti memengaruhi kinerja model dalam menghasilkan prediksi genre. Hal itu terjadi karena beberapa lagu yang memiliki karakteristik lintas genre pada bagian tertentu. Walaupun data pada Tabel 5.18 menyatakan model mampu memprediksi setiap bagian lagu dengan tepat, Tabel 5.19 menyatakan bahwa setiap bagian lagu menghasilkan akurasi yang berbeda-beda. Bagian lagu pada menit 1:00-1:30 menghasilkan akurasi tertinggi, yaitu sebesar 94.57%. Variasi semacam ini memungkinkan model menghasilkan prediksi yang berbeda bergantung pada segmen lagu yang digunakan untuk pengujian.

BAB VI
KESIMPULAN DAN SARAN

Pada bab ini, dijelaskan kesimpulan yang dapat diambil dari Tugas Akhir ini dan saran yang akan berguna untuk penelitian selanjutnya.

6.1 Kesimpulan

Kesimpulan yang dapat diambil dari Tugas Akhir ini adalah:

1. Pada Tugas Akhir ini penulis telah berhasil menerapkan kombinasi metode ResNet sebagai *feature extractor* dan Bi-GRU sebagai model sekuensial untuk melakukan klasifikasi genre musik berbasis fusi citra *scalogram-spectrogram*.

2. Kinerja terbaik metode ResNet-BiGRU dalam mengklasifikasikan genre musik didapatkan menggunakan data fusi citra *scalogram* dan *spectrogram* dengan metode *weighted average* bernilai $\alpha = 0.5$. Model ResNet-BiGRU dimodifikasi dengan menambahkan lapisan *Adaptive Max Pooling*, *Batch Normalization*, dan *Dropout* sebanyak 3 kali setelah ResNet selesai mengekstraksi fitur. Kombinasi *hyperparameter* berupa `batch size = 16`, `hidden size = 256`, `dropout = 0.1, 0.1, 0.1`, dan `max pooling = 4x4, 4x4, 4x4` mampu menghasilkan akurasi validasi terbaik sebesar 96.19%.

6.2 Saran

Saran yang akan berguna untuk penelitian selanjutnya adalah:

1. Diperlukannya pembaruan dataset yang digunakan agar hasil klasifikasi yang dilakukan model ResNet-BiGRU relevan dengan musik yang ada pada saat ini.

2. Mempertimbangkan variasi *tuning hyperparameter* yang berbeda, seperti *learning rate*, *weight decay* dan jumlah epoch, untuk melihat pengaruhnya terhadap performa model.

3. Menambahkan proses *data augmentation* untuk meningkatkan ketahanan model terhadap variasi sinyal musik.

4. Melakukan pendekatan *multi-label classification* supaya lagu-lagu dengan lebih dari satu genre bisa diklasifikasikan dengan lebih tepat.

DAFTAR PUSTAKA

Addison, P. S. (2017). *The illustrated wavelet transform handbook: Introductory theory and applications in science, engineering, medicine and finance* (2nd ed.). CRC Press. Retrieved from https://doi.org/10.1201/9781315372556 doi: 10.1201/9781315372556

Afinda, A. M. (2024, June 29). *Hi, nice to know you, deep learning!* Blog post on Dicoding. Retrieved from https://www.dicoding.com/blog/hi-nice-to-know-you-deep-learning/

Almaghrabi, S., Clark, S., & Baumert, M. (2023, 05). Bio-acoustic features of depression: A review. *Biomedical Signal Processing and Control*, *85*, 105020. doi: 10.1016/j.bspc.2023.105020

Ashraf, M., Abid, F., Ud Din, I., Rasheed, J., Yesiltepe, M., Yeo, S. F., & Ersoy, M. (2023, 01). A hybrid cnn and rnn variant model for music classification. *Applied Sciences*, *13*, 1476. doi: 10.3390/app13031476

Aslan, Z., & Akin, M. (2022). A deep learning approach in automated detection of schizophrenia using scalogram images of eeg signals. *Physical and Engineering Sciences in Medicine*, *45*(1), 83–96.

Baldi, P., & Sadowski, P. J. (2013). Understanding dropout. *Advances in neural information processing systems*, *26*.

Balti, H., Abbes, A., & Farah, I. (2024). A bi-gru-based encoder–decoder framework for multivariate time series forecasting. *Soft Computing*, *28*. doi: 10.1007/s00500-023-09531-9

Bengio, Y., Goodfellow, I., & Courville, A. (2017). *Deep learning* (Vol. 1). MIT press Cambridge, MA, USA.

Bhardwaj, A., Srivastava, P., Vinny, P., Mehndiratta, A., Vishnu, V., & Garg, R. (2022, 03). Machine learning based reanalysis of clinical scores for distinguishing between ischemic and hemorrhagic stroke in low resource setting. *Journal of Stroke and Cerebrovascular Diseases*. doi: 10.1101/2022.03.03.22271885

Bjorck, N., Gomes, C. P., Selman, B., & Weinberger, K. Q. (2018). Understanding batch normalization. *Advances in neural information processing systems*, *31*.

Chahal, A., & Gulia, P. (2019). Machine learning and deep learning. *International Journal of Innovative Technology and Exploring Engineering*, *8*(12), 4910–4914.

Chen, J., Chen, L., & Shabaz, D. M. (2021, 08). Image fusion algorithm at pixel level based on edge detection. *Journal of Healthcare Engineering*, *2021*, 1-10. doi: 10.1155/2021/5760660

Choi, K., Fazekas, G., Sandler, M., & Cho, K. (2016). *Convolutional recurrent neural networks for music classification.* Retrieved from https://arxiv.org/abs/1609.04243

Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). *Empirical evaluation of gated recurrent neural networks on sequence modeling.* (arXiv:1412.3555)

Erbani, J., Portier, P.-E., Egyed-Zsigmond, E., & Nurbakova, D. (2024). Confusion matrices: A unified theory. *IEEE Access*, *12*, 181372-181419. doi: 10.1109/ACCESS.2024.3507199

Fardhani, S. M., Wihardi, Y., & Piantari, E. (2021). Klasifikasi genre musik dengan mel frequency cepstral coefficient dan spektogram menggunakan convolutional neural network. *JATIKOM: Jurnal Aplikasi dan Teori Ilmu Komputer*, *4*, 26–34.

GeeksforGeeks. (2025). *Activation functions in neural networks.* https://www.geeksforgeeks.org/machine-learning/activation-functions-neural-networks/. (Accessed: 2025-11-22)

Gharaibeh, K. (2021). Assessment of various window functions in spectral identification of passive intermodulation. *Electronics*, *10*(9). Retrieved from https://www.mdpi.com/2079-9292/10/9/1034 doi: 10.3390/electronics10091034

Ghosh, S., & Riad, M. (2022, 12). Attention-based cnn-bigru for bengali music emotion classification. *Indonesian Journal of Computer Science*, *11*, 801-815. doi: 10.33022/ijcs.v11i3.3111

Giri, G. A. V. M. (2024). Klasifikasi musik berdasarkan genre menggunakan metode k-nearest neighbor. *Jurnal Ilmu Komputer*, *2*, 319–326.

Golchafun. (2024). *Multiclass confusion matrix.* Retrieved 2025-08-19, from https://golchafun.medium.com/multiclass-confusion-matrix-af4b4c09462f (Medium Blog Post)

Gonzalez, R. C., & Woods, R. E. (2018). *Digi tal image processing* (4th ed.). Pearson.

Hangting, C., Zhang, P., Bai, H., Yuan, Q., Bao, X., & Yan, Y. (2018, 09). Deep convolutional neural network with scalogram for audio scene modeling. In (p. 3304-3308). doi: 10.21437/Interspeech.2018-1524

Hartono, S., Suyuti, S., Asmara, B., Ashad, B., & Hamzidah, N. (2023, 11). Analisis spektogram sinyal suara asli dan suara hasil konversi berbasis derivative gelombang glotal. *Jurnal Teknologi Elekterika*, *20*, 87. doi: 10.31963/elekterika.v20i2.4525

Hassnain, M., & Mehmood, T. (2024). Wavelet and stft transformation coupled with the windowing improves the urban sound classification. *SSRN Electronic Journal*. doi: 10.2139/ssrn.5281787

He, K., Zhang, X., Ren, S., & Sun, J. (2016, 06). Deep residual learning for image recognition. In (p. 770-778). doi: 10.1109/CVPR.2016.90

Hilmiaji, N., Lhaksmana, K., & Dwifebri Purbolaksono, M. (2021, 06). Identifying emotion on indonesian tweets using convolutional neural networks. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, *5*, 584-593. doi: 10.29207/resti.v5i3.3137

Ibitoye, O. (2021, 04). A brief review of convolutional neural network techniques for masked face recognition. In (p. 1-4). doi: 10.1109/COPA51043.2021.9541448

Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International conference on machine learning* (pp. 448–456).

Jopri, M., Abdullah, A. R., Manap, M., Yusoff, M. R., Sutikno, T., & Habban, M. F. (2017). An improved detection and classification technique of harmonic signals in power distribution by utilizing spectrogram. *Int. J. Electr. Comput. Eng*, *7*(1), 12–20.

JUANDRI, & Anwar, N. (2023). Pengenalan warna terhadap objek dengan model analisis elemen data warna gambar berbasis deep neural network. *BULLET : Jurnal Multidisiplin Ilmu*, *2*(1), 23–31.

Kavitha, C., Mani, V., Srividhya, S., Khalaf, O., & Romero, C. (2022, 03). Early-stage alzheimer's disease prediction using machine learning models. *Frontiers in Public*

Health, *10*, 853294. doi: 10.3389/fpubh.2022.853294
Keller, R. B. (2022). Decibel. In *Design for electromagnetic compatibility–in a nutshell* (pp. 23–31). Springer.
Khalifa, A. B., & Frigui, H. (2016, 10). Multiple instance fuzzy inference neural networks. *Multimedia Research Lab*. doi: 10.48550/arXiv.1610.04973
Kulkarni, A. (2022, 01). Deep convolution neural networks for image classification. *International Journal of Advanced Computer Science and Applications*, *13*. doi: 10.14569/IJACSA.2022.0130603
Lenssen, N. (2013). *Applications of fourier analysis to audio signal processing: An investigation of chord detection algorithms.* Claremont McKenna College.
Lin, J., & Qu, L. (2000). Feature extraction based on morlet wavelet and its application for mechanical fault diagnosis. *Journal of sound and vibration*, *234*(1), 135–148.
Mahadevan, S., & Barani, R. (2012). Qualitative evaluation of pixel level image fusion algorithms. In *Proceedings of the 2nd international conference on pattern recognition, informatics and medical engineering* (pp. 312–317).
Markoulidakis, I., Rallis, I., Georgoulas, I., Kopsiaftis, G., Doulamis, A., & Doulamis, N. (2021). Multiclass confusion matrix reduction method and its application on net promoter score classification problem. *Technologies*, *9*(4). Retrieved from https://www.mdpi.com/2227-7080/9/4/81 doi: 10.3390/technologies9040081
Mertins, A. (2001). *Signal analysis: Wavelets, filter banks, time-frequency transforms and applications*. Chichester: John Wiley and Sons.
Mienye, I., Swart, T., & Obaido, G. (2024, 08). Recurrent neural networks: A comprehensive review of architectures, variants, and applications. *Information*, *15*, 517. doi: 10.3390/info15090517
Mukherjee, S. (2022). *The annotated resnet-50. explaining how resnet-50 works and why it is so popular.* Medium (TDS Archive). Retrieved from https://medium.com/data-science/the-annotated-resnet-50-a6c536034758 (Published August 18, 2022; last updated February 3, 2025)
Munoz, N. A. G. (2023). *Cross validation dataset split strategies.* https://www.kaggle.com/code/nicolasgonzalezmunoz/cross-validation-dataset-split-strategies. (Section: Group Shuffle Split, Accessed: 14 December 2025)
Müller, M. (2015). *Fundamentals of music processing*. doi: 10.1007/978-3-319-21945-5
Ng, W., Zeng, W., & Wang, T. (2020, 08). Multi-level local feature coding fusion for music genre recognition. *IEEE Access*, *PP*, 1-1. doi: 10.1109/ACCESS.2020.3017661
Niroshana, S. M. I., Zhu, X., Nakamura, K., & Chen, W. (2021). A fused-image-based approach to detect obstructive sleep apnea using a single-lead ecg and a 2d convolutional neural network. *Plos one*, *16*(4).
Paramarta, I. M. (2023). *Fusi citra scalogram berbasis wavelet dan spectogram untuk klasifikasi genre musik menggunakan metode musicrecnet.*
Parwatiningtyas, D. (2010). Mengidentifikasi karakteristik objek di permukaan bumi, menggunakan metode remote sensing dengan teknik fusi pewarnaan ihs. *Jurnal Ilmiah Faktor Exacta*, *3*(3), 238–248. Retrieved from https://ejournal.unindra.ac.id/index.php/faktorexacta/article/view/25
Patro, M., & Patra, M. R. (2015, 04). A novel approach to compute confusion matrix for classification of n-class attributes with feature selection. *Transactions on Machine Learning and Artificial Intelligence*. doi: 10.14738/tmlai.32.1108
Phan, D. T. (2024). *Comparison performance of spectrogram and scalogram as input of*

acoustic recognition task. Retrieved from https://arxiv.org/abs/2403.03611

Pimenta-Zanon, M. H., Bressan, G. M., & Lopes, F. M. (2021). *Complex network-based approach for feature extraction and classification of musical genres.* Retrieved from https://arxiv.org/abs/2110.04654

Pratama, A. S. (2021). *Klasifikasi genre musik populer menggunakan metode convolutional neural network dengan data augmentation.*

Putra, I. K. A., & Setiawan, I. M. D. (2021). Aplikasi teknik fusi dengan metode pansharpening untuk analisis penggunaan lahan pada wilayah bali selatan. *Media Komunikasi Geografi*, *22*(1), 62–74. Retrieved from http://dx.doi.org/10.23887/mkg.v22i1.30978 doi: 10.23887/mkg.v22i1.30978

Qian, J. (2010). Sampling. In P. Peterson, E. Baker, & B. McGaw (Eds.), *International encyclopedia of education (third edition)* (Third Edition ed., p. 390-395). Oxford: Elsevier. Retrieved from https://www.sciencedirect.com/science/article/pii/B9780080448947013610 doi: https://doi.org/10.1016/B978-0-08-044894-7.01361-0

Qizhen, Y. (2024). Performance comparison of stft and dwt in audio denoising. In *2024 4th international signal processing, communications and engineering management conference (ispcem)* (pp. 150–154).

Ramírez, J., & Flores, M. J. (2019). Machine learning for music genre: multifaceted review and experimentation with audioset. *Journal of Intelligent Information Systems*, *55*(3), 469–499. Retrieved from http://dx.doi.org/10.1007/s10844-019-00582-9 doi: 10.1007/s10844-019-00582-9

Rasamoelina, A. D., Adjailia, F., & Sincak, P. (2020, 01). A review of activation function for artificial neural network. In (p. 281-286). doi: 10.1109/SAMI48414.2020.9108717

Ren, Y. (2025, 10). Comparative analysis of lstm and gru models for air pollution prediction in shanghai. *Advances in Economics, Management and Political Sciences*, *224*, 14-22. doi: 10.54254/2754-1169/2025.BL27885

Rusiecki, A. (2019). Trimmed categorical cross-entropy for deep learning with label noise. *Electronics Letters*, *55*(6), 319–320.

Sarno, R., Sabilla, S. I., Malikhah, Purbaya, D. P., & Ardani, M. S. H. (2023). *Machine learning dan deep learning-konsep dan pemrograman python.* CV ANDI OFFSET.

Sathyanarayanan, S., & Tantri, B. R. (2024). Confusion matrix-based performance evaluation metrics. *African Journal of Biomedical Research*, *27*(4), 4023–4031.

Setyoko, D. (2024, 12). Resnet-18 with attention mechanism-bidirectional lstm hybrid approach for music genre classification using stacking mfcc and mel-spectogram features. *The Indonesian Journal of Computer Science*, *13*. doi: 10.33022/ijcs.v13i6.4456

Sharma, S., Sharma, S., & Athaiya, A. (2017). Activation functions in neural networks. *International Journal of Engineering Applied Sciences and Technology*, *6*(12), 310–316.

SPKIT Development Team. (2023a). *Scalogram using continuous wavelet transform (cwt).* https://spkit.github.io/auto_examples/wavelet_analysis/plot_sp_scalogram_cwt_example.html. (Accessed: 14 December 2025)

SPKIT Development Team. (2023b). *Stft of audio signal.* https://spkit.github.io/auto_examples/signal_processing/plot_sp_sinusodal_model_analysis_synthesis.html. (Accessed: 14 December 2025)

Suryantara, I. G. N. (2024). *Python: Implementasi algoritma kompleks dalam era industri 5.0 dan society 5.0*. PT Elex Media Komputindo.

Suthakar, R. J., Esther, J. M., Annapoorani, D., & Samuel, F. R. S. (2014). Study of image fusion- techniques, method and applications. *International Journal of Computer Science and Mobile Computing (IJCSMC)*, *3*(11), 469–476. Retrieved from http://www.ijcsmc.com/

T G, K. K., Ogare, M., & Koolagudi, S. (2024, 07). Ecg signal classification using continuous wavelet transform scalogram and convolutional neural network. In (p. 1-8). doi: 10.1109/IConSCEPT61884.2024.10627917

Tzanetakis, G., & Cook, P. (2002). Musical genre classification of audio signals. *IEEE Transactions on Speech and Audio Processing*, *10*(5), 293-302.

Wiraguna, I. G. A. N. D., & Putri, L. A. A. R. (2023, 07). Klasifikasi genre musik menggunakan support vector machine berdasarkan spectral features. *Jurnal Nasional Teknologi Informasi dan Aplikasnya*, *1*, 933. doi: 10.24843/JNATIA.2023.v01.i03.p20

Wu, T., & Toet, A. (2014). Color-to-grayscale conversion through weighted multiresolution channel fusion. *Journal of Electronic Imaging*, *23*(4), 043004–043004.

Yadav, H., Shah, P., Gandhi, N., Vyas, T., Nair, A., Desai, S., ... Raboaca, M. S. (2023). Cnn and bidirectional gru-based heartbeat sound classification architecture for elderly people. *Mathematics*, *11*(6). Retrieved from https://www.mdpi.com/2227-7390/11/6/1365 doi: 10.3390/math11061365

Yingge, H., Ali, I., & Lee, K.-Y. (2020, 02). Deep neural networks on chip - a survey. In (p. 589-592). doi: 10.1109/BigComp48618.2020.00016

Zafar, M., Awais, M. N., & Shehzad, M. N. (2022). Computationally efficient memristor model based on hann window function. *Microelectronics Journal*, *125*, 105476. Retrieved from https://www.sciencedirect.com/science/article/pii/S0026269222001094 doi: https://doi.org/10.1016/j.mejo.2022.105476

Zhang, J. (2023). *Music genre classification with resnet and bi-gru using visual spectrograms.* Retrieved from https://arxiv.org/abs/2307.10773

DAFTAR LAMPIRAN

Lampiran 1
Performansi Model

1. Akurasi Model dengan Modifikasi *Hyperparameter*

No	***Hyperparameter***		***Best Epoch***	***Learning Rate***	**Pelatihan**	**Validasi**
1	*Dropout rate*	0.1, 0.1, 0.1	68	2.5e-5	0.9982	0.9549
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
2	*Dropout rate*	0.2, 0.2, 0.2	60	1e-4	0.9925	0.9461
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
3	*Dropout rate*	0.3, 0.3, 0.3	68	2.5e-5	0.9982	0.9530
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
4	*Dropout rate*	0.4, 0.4, 0.4	63	5e-5	0.9933	0.9441
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
5	*Dropout rate*	0.5, 0.5, 0.5	62	2.5e-5	0.9941	0.9434
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
6	*Dropout rate*	0.1, 0.1, 0.3	64	5e-5	0.9967	0.9515
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
7	*Dropout rate*	0.1, 0.3, 0.1	53	5e-5	0.9978	0.9522
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
8	*Dropout rate*	0.1, 0.3, 0.3	45	5e-5	0.9942	0.9530
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
9	*Dropout rate*	0.3, 0.1, 0.1	54	5e-5	0.9960	0.9495
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				

No	*Hyperparameter*		*Best Epoch*	*Learning Rate*	Pelatihan	Validasi
10	*Dropout rate*	0.3, 0.1, 0.3	63	5e-5	0.9967	0.9488
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
11	*Dropout rate*	0.3, 0.3, 0.1	68	5e-5	0.9973	0.9549
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
12	*Dropout rate*	0.1, 0.1, 0.1	31	5e-5	0.9967	0.9515
	Max Pooling	2x2, 2x2, 2x2				
	Hidden size (GRU)	64				
	Batch size	32				
13	*Dropout rate*	0.1, 0.1, 0.1	63	1.25e-5	0.9989	0.9503
	Max Pooling	3x3, 3x3, 3x3				
	Hidden size (GRU)	64				
	Batch size	32				
14	*Dropout rate*	0.1, 0.1, 0.1	69	1.25e-5	0.9995	0.9557
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	64				
	Batch size	32				
15	*Dropout rate*	0.1, 0.1, 0.1	58	2.5e-5	0.9981	0.9526
	Max Pooling	5x5, 5x5, 5x5				
	Hidden size (GRU)	64				
	Batch size	32				
16	*Dropout rate*	0.1, 0.1, 0.1	68	5e-5	0.9934	0.9488
	Max Pooling	1x1, 4x4, 5x5				
	Hidden size (GRU)	64				
	Batch size	32				
17	*Dropout rate*	0.1, 0.1, 0.1	69	2.5e-5	0.9973	0.9430
	Max Pooling	1x1, 5x5, 4x4				
	Hidden size (GRU)	64				
	Batch size	32				
18	*Dropout rate*	0.1, 0.1, 0.1	62	5e-5	0.9959	0.9526
	Max Pooling	4x4, 1x1, 5x5				
	Hidden size (GRU)	64				
	Batch size	32				
19	*Dropout rate*	0.1, 0.1, 0.1	52	2.5e-5	0.9982	0.9484
	Max Pooling	4x4, 5x5, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
20	*Dropout rate*	0.1, 0.1, 0.1	46	5e-5	0.9963	0.9426
	Max Pooling	5x5, 1x1, 4x4				
	Hidden size (GRU)	64				
	Batch size	32				
21	*Dropout rate*	0.1, 0.1, 0.1	67	2.5e-5	0.9986	0.9549

No	*Hyperparameter*		*Best Epoch*	*Learning Rate*	Pelatihan	Validasi
	Max Pooling	5x5, 4x4, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
22	*Dropout rate*	0.1, 0.1, 0.1	68	5e-5	0.9964	0.9353
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	16				
	Batch size	32				
23	*Dropout rate*	0.1, 0.1, 0.1	62	1e-4	0.9922	0.9472
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	32				
	Batch size	32				
24	*Dropout rate*	0.1, 0.1, 0.1	58	5e-5	0.9990	0.9549
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	128				
	Batch size	32				
25	*Dropout rate*	0.1, 0.1, 0.1	56	2.5e-5	0.9993	0.9557
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	32				
26	*Dropout rate*	0.1, 0.1, 0.1	60	2.5e-5	0.9974	0.9549
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	8				
27	*Dropout rate*	0.1, 0.1, 0.1	59	2.5e-5	0.9988	0.9611
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	16				
28	*Dropout rate*	0.1, 0.1, 0.1	58	5e-5	0.9990	0.9445
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	64				
29	*Dropout rate*	0.1, 0.1, 0.1	56	5e-5	0.9986	0.9488
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	128				
30	*Dropout rate*	0.1, 0.1, 0.1	46	5e-5	0.9985	0.9318
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	256				

2. *Loss* Model dengan Modifikasi *Hyperparameter*

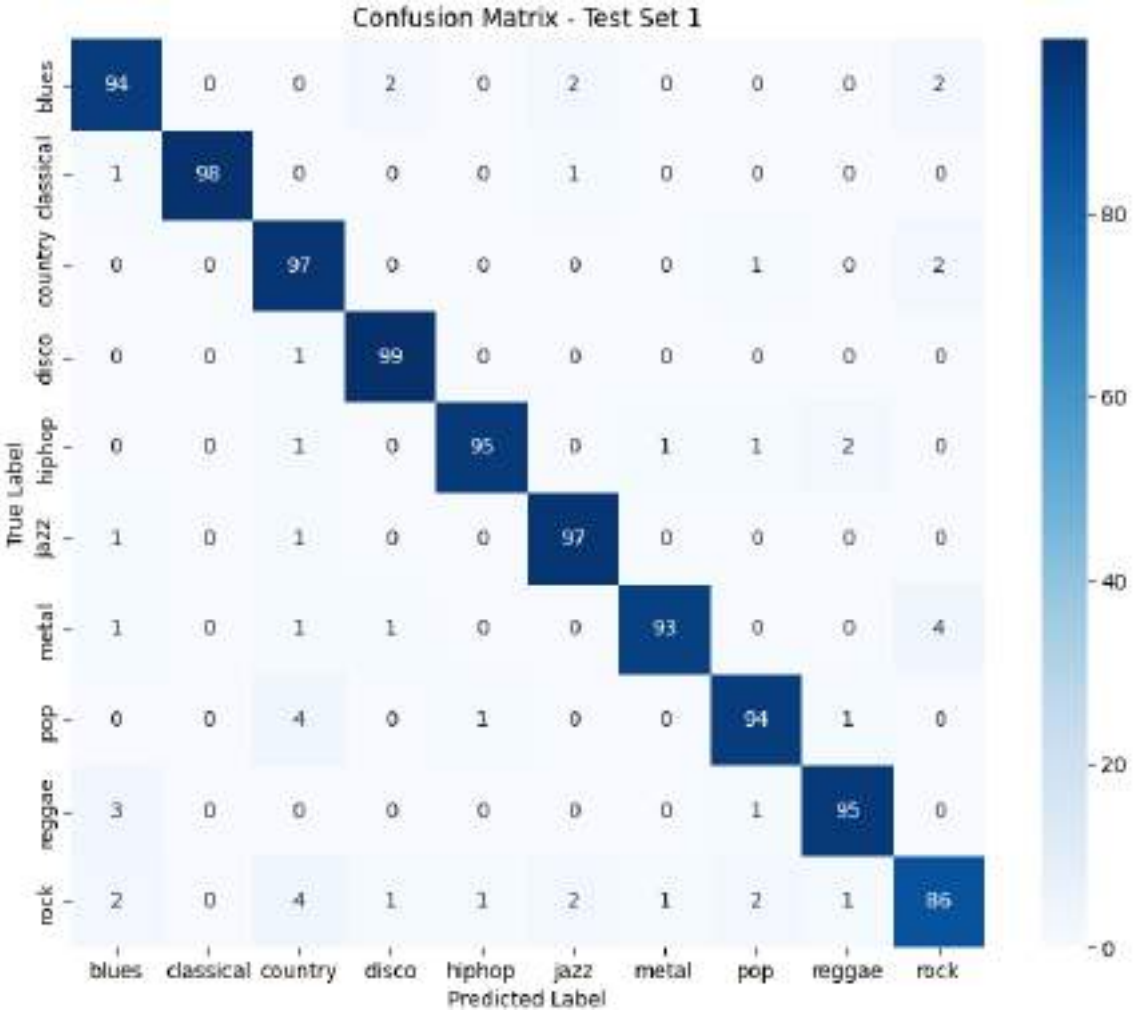
No	*Hyperparameter*		*Best Epoch*	*Learning Rate*	Pelatihan	Validasi
	Dropout rate	0.1, 0.1, 0.1				
1			68	2.5e-5	0.0072	0.1812

No	*Hyperparameter*		*Best Epoch*	*Learning Rate*	Pelatihan	Validasi
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
2	*Dropout rate*	0.2, 0.2, 0.2	60	1e-4	0.0254	0.2003
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
3	*Dropout rate*	0.3, 0.3, 0.3	68	2.5e-5	0.0088	0.2230
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
4	*Dropout rate*	0.4, 0.4, 0.4	63	5e-5	0.0243	0.2360
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
5	*Dropout rate*	0.5, 0.5, 0.5	62	2.5e-5	0.0257	0.2632
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
6	*Dropout rate*	0.1, 0.1, 0.3	64	5e-5	0.0113	0.1797
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
7	*Dropout rate*	0.1, 0.3, 0.1	53	5e-5	0.0111	0.1901
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
8	*Dropout rate*	0.1, 0.3, 0.3	45	5e-5	0.0236	0.1846
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
9	*Dropout rate*	0.3, 0.1, 0.1	54	5e-5	0.0161	0.1966
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
10	*Dropout rate*	0.3, 0.1, 0.3	63	5e-5	0.0140	0.1948
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
11	*Dropout rate*	0.3, 0.3, 0.1	68	5e-5	0.0138	0.1788
	Max Pooling	1x1, 1x1, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
12	*Dropout rate*	0.1, 0.1, 0.1	31	5e-5	0.0164	0.1737
	Max Pooling	2x2, 2x2, 2x2				

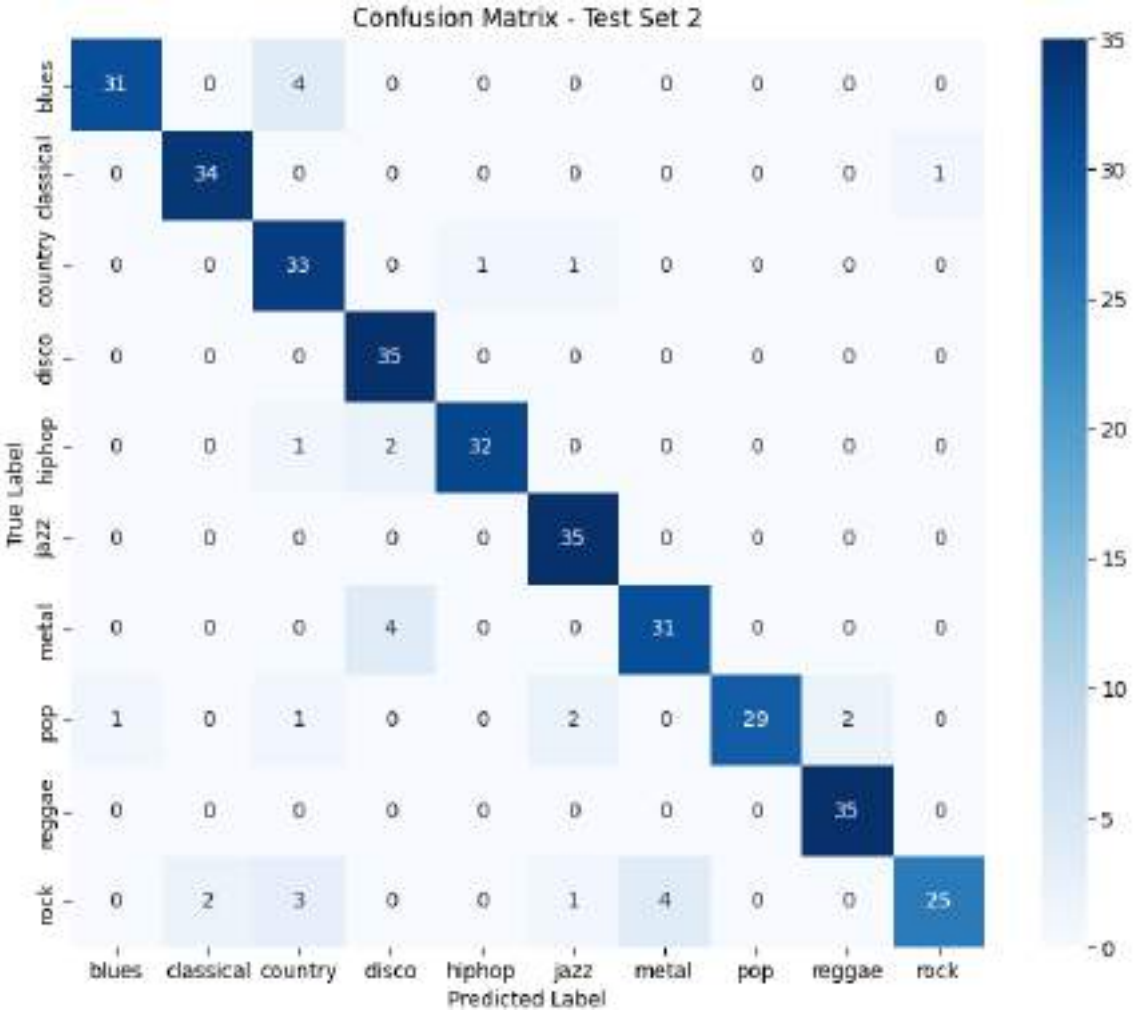
No	*Hyperparameter*		*Best Epoch*	*Learning Rate*	Pelatihan	Validasi
	Hidden size (GRU)	64				
	Batch size	32				
13	*Dropout rate*	0.1, 0.1, 0.1	63	1.25e-5	0.0046	0.1975
	Max Pooling	3x3, 3x3, 3x3				
	Hidden size (GRU)	64				
	Batch size	32				
14	*Dropout rate*	0.1, 0.1, 0.1	69	1.25e-5	0.0036	0.1806
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	64				
	Batch size	32				
15	*Dropout rate*	0.1, 0.1, 0.1	58	2.5e-5	0.0082	0.1874
	Max Pooling	5x5, 5x5, 5x5				
	Hidden size (GRU)	64				
	Batch size	32				
16	*Dropout rate*	0.1, 0.1, 0.1	68	5e-5	0.0221	0.2119
	Max Pooling	1x1, 4x4, 5x5				
	Hidden size (GRU)	64				
	Batch size	32				
17	*Dropout rate*	0.1, 0.1, 0.1	69	2.5e-5	0.0094	0.2271
	Max Pooling	1x1, 5x5, 4x4				
	Hidden size (GRU)	64				
	Batch size	32				
18	*Dropout rate*	0.1, 0.1, 0.1	62	5e-5	0.0159	0.1889
	Max Pooling	4x4, 1x1, 5x5				
	Hidden size (GRU)	64				
	Batch size	32				
19	*Dropout rate*	0.1, 0.1, 0.1	52	2.5e-5	0.0078	0.1955
	Max Pooling	4x4, 5x5, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
20	*Dropout rate*	0.1, 0.1, 0.1	46	5e-5	0.0146	0.2184
	Max Pooling	5x5, 1x1, 4x4				
	Hidden size (GRU)	64				
	Batch size	32				
21	*Dropout rate*	0.1, 0.1, 0.1	67	2.5e-5	0.0058	0.1593
	Max Pooling	5x5, 4x4, 1x1				
	Hidden size (GRU)	64				
	Batch size	32				
22	*Dropout rate*	0.1, 0.1, 0.1	68	5e-5	0.0208	0.2432
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	16				
	Batch size	32				
23	*Dropout rate*	0.1, 0.1, 0.1	62	1e-4	0.0290	0.2033
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	32				

No	*Hyperparameter*		*Best Epoch*	*Learning Rate*	Pelatihan	Validasi
	Batch size	32				
24	*Dropout rate*	0.1, 0.1, 0.1	58	5e-5	0.0041	0.1982
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	128				
	Batch size	32				
25	*Dropout rate*	0.1, 0.1, 0.1	56	2.5e-5	0.0028	0.1769
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	32				
26	*Dropout rate*	0.1, 0.1, 0.1	60	2.5e-5	0.0093	0.1658
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	8				
27	*Dropout rate*	0.1, 0.1, 0.1	59	2.5e-5	0.0038	0.1594
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	16				
28	*Dropout rate*	0.1, 0.1, 0.1	58	5e-5	0.0040	0.2124
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	64				
29	*Dropout rate*	0.1, 0.1, 0.1	56	5e-5	0.0043	0.2113
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	128				
30	*Dropout rate*	0.1, 0.1, 0.1	46	5e-5	0.0066	0.2575
	Max Pooling	4x4, 4x4, 4x4				
	Hidden size (GRU)	256				
	Batch size	256				

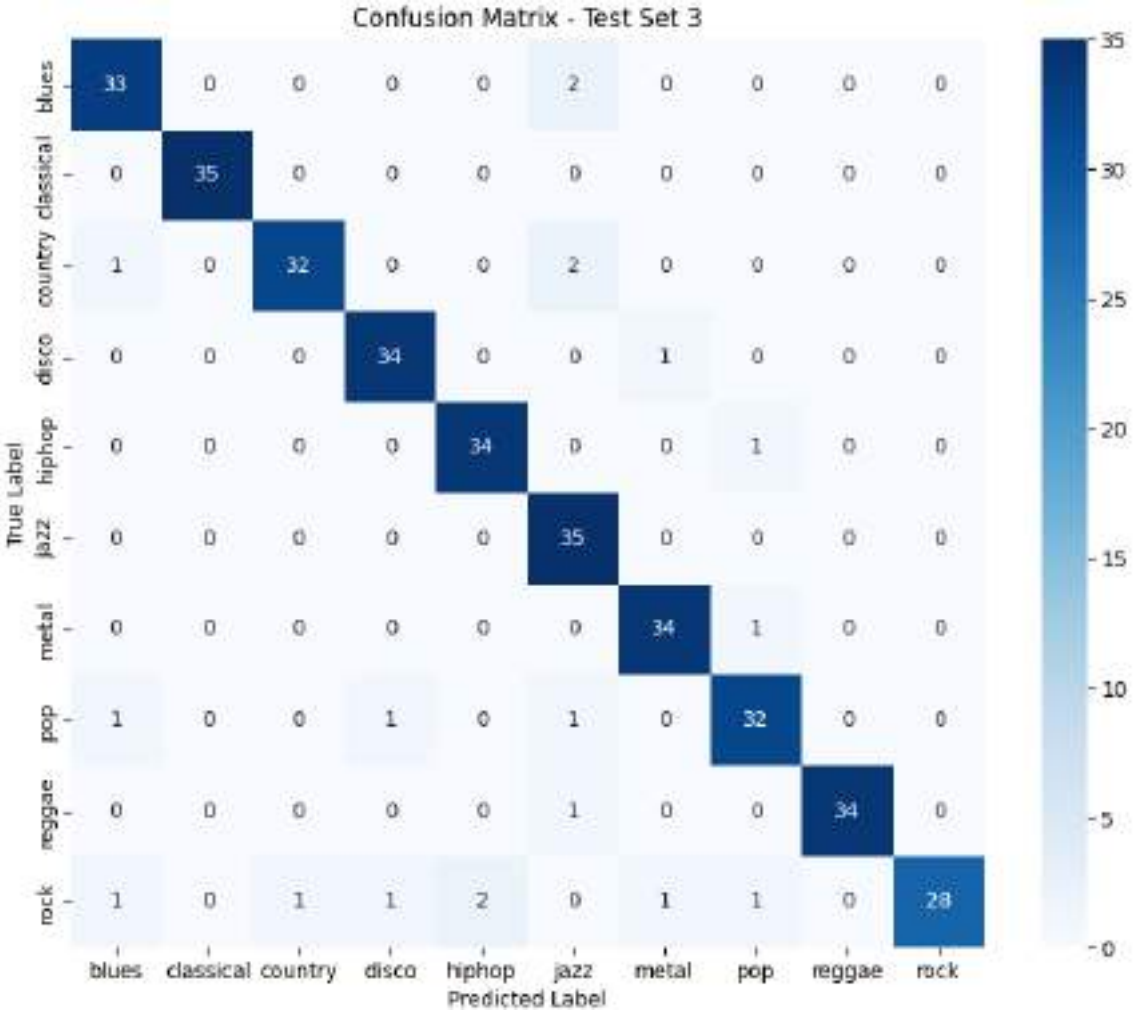
Lampiran 2
Confusion Matrix



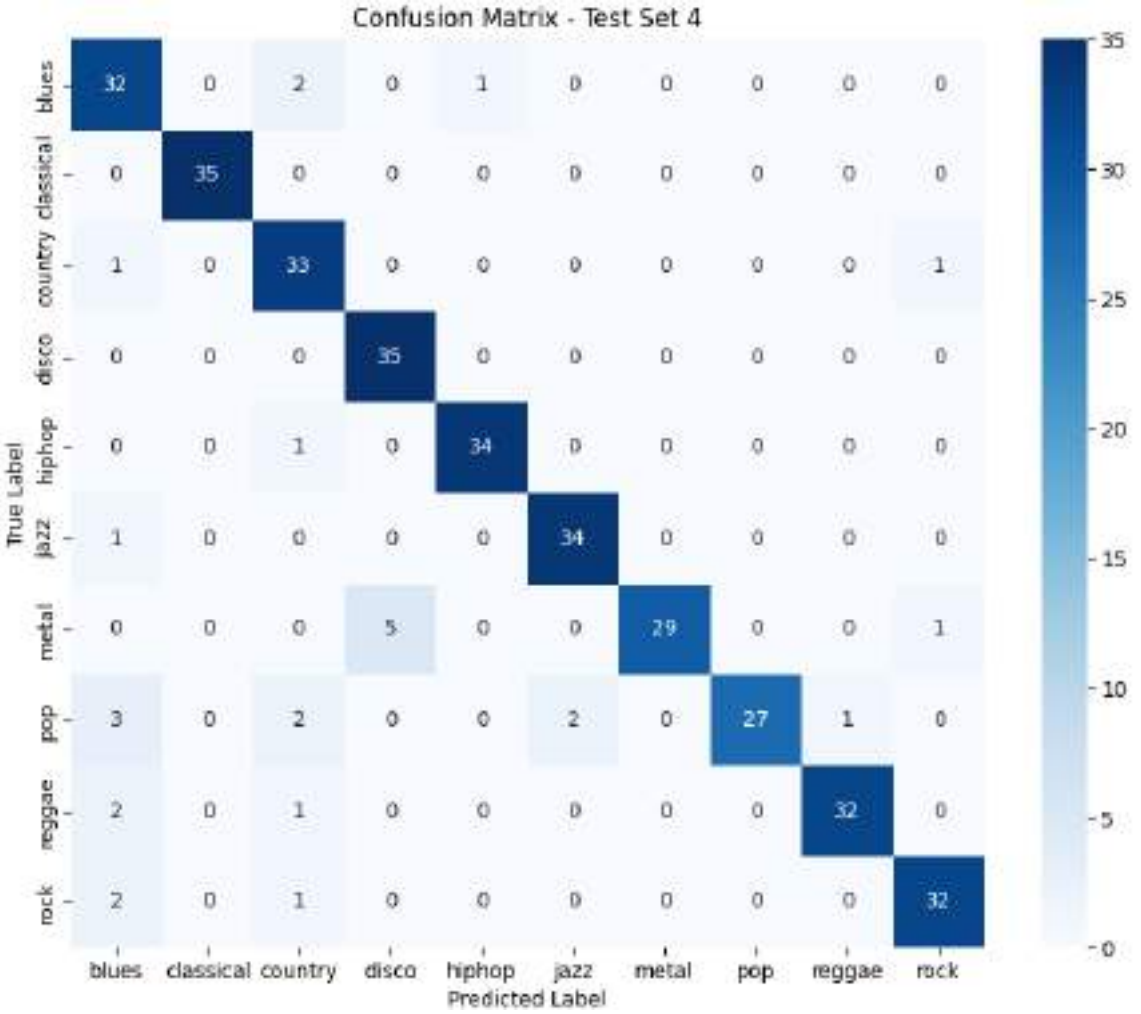
1. *Confusion Matrix* Dataset Sekunder



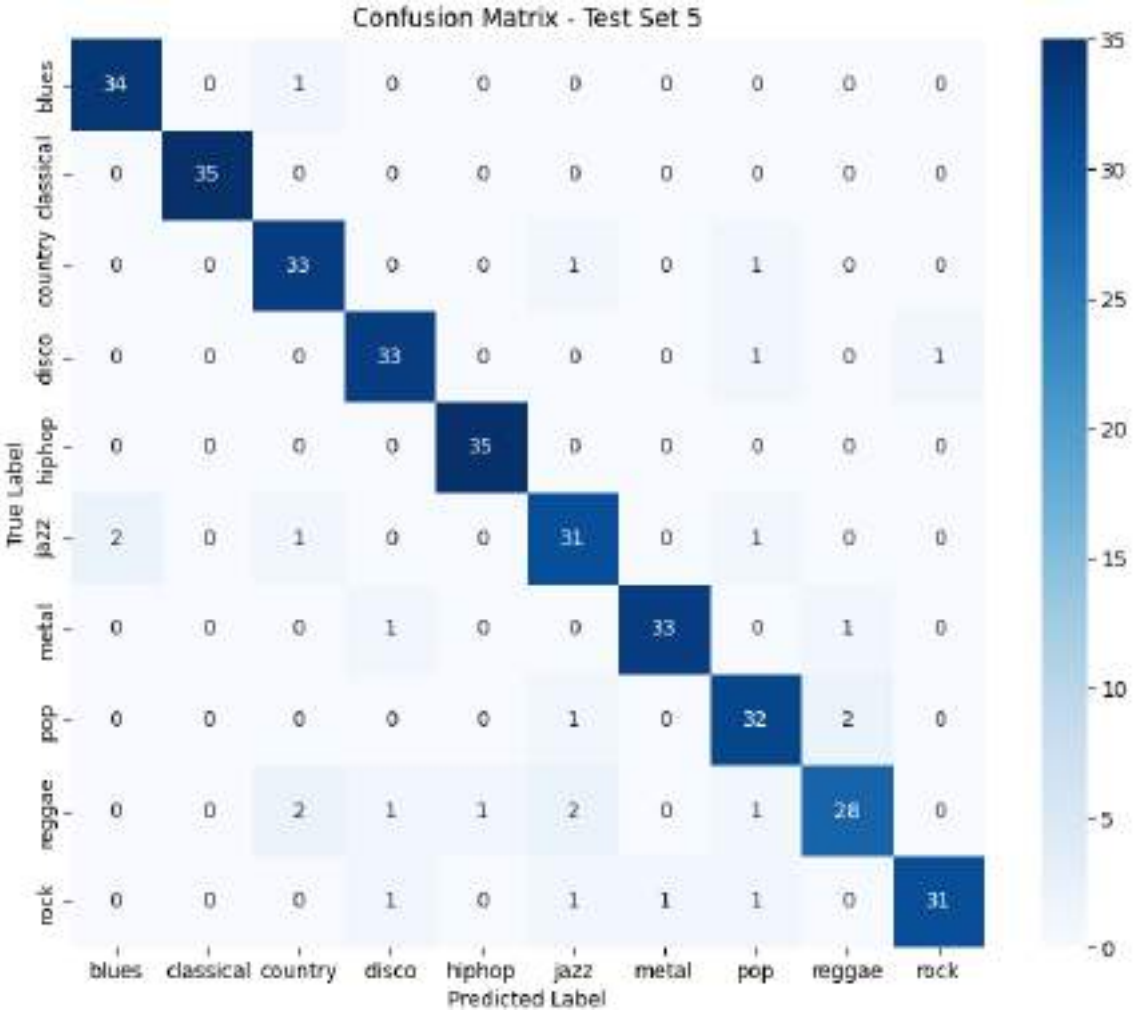
2. *Confusion Matrix* Dataset Primer pada Menit 0:30-1:00



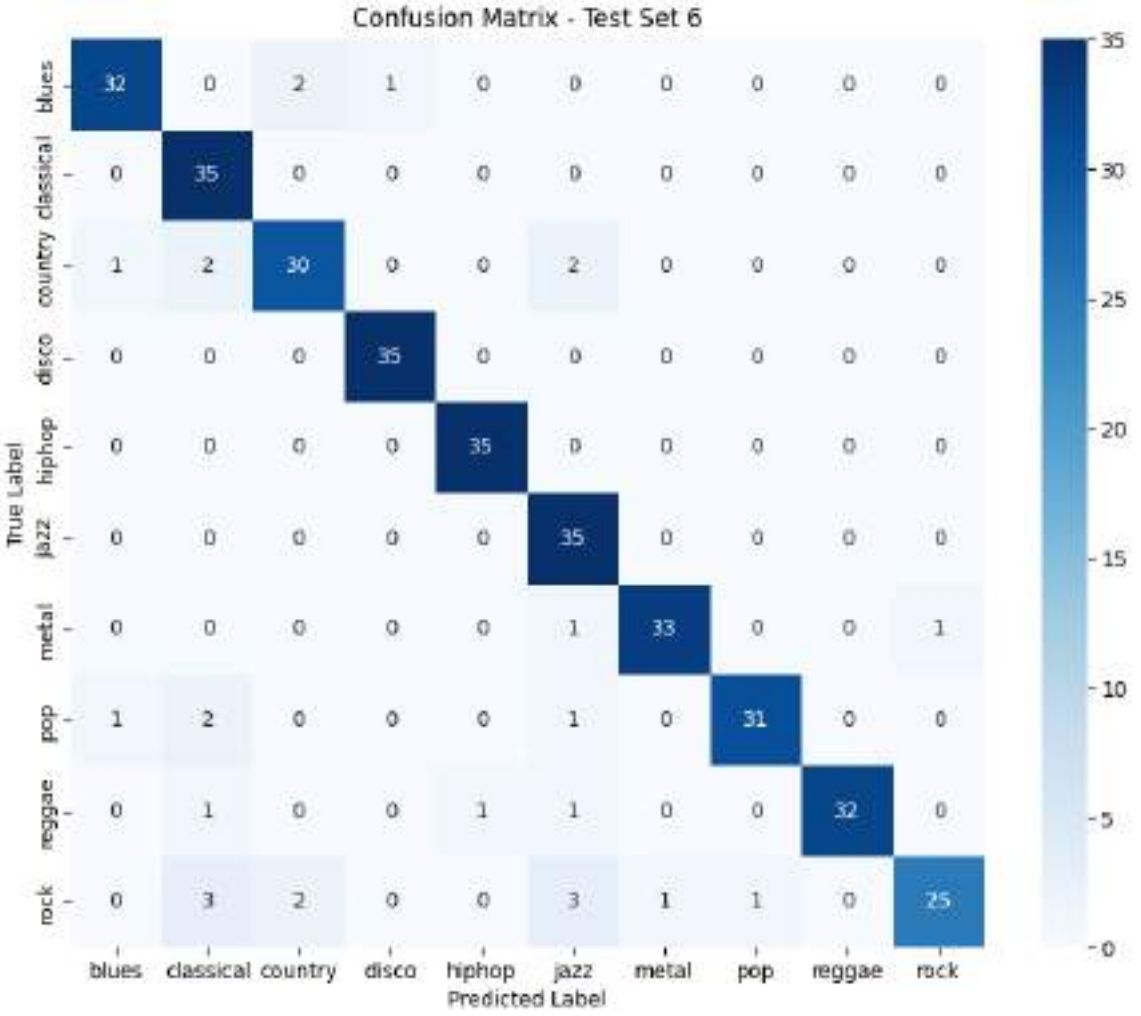
3. *Confusion Matrix* Dataset Primer pada Menit 1:00-1:30



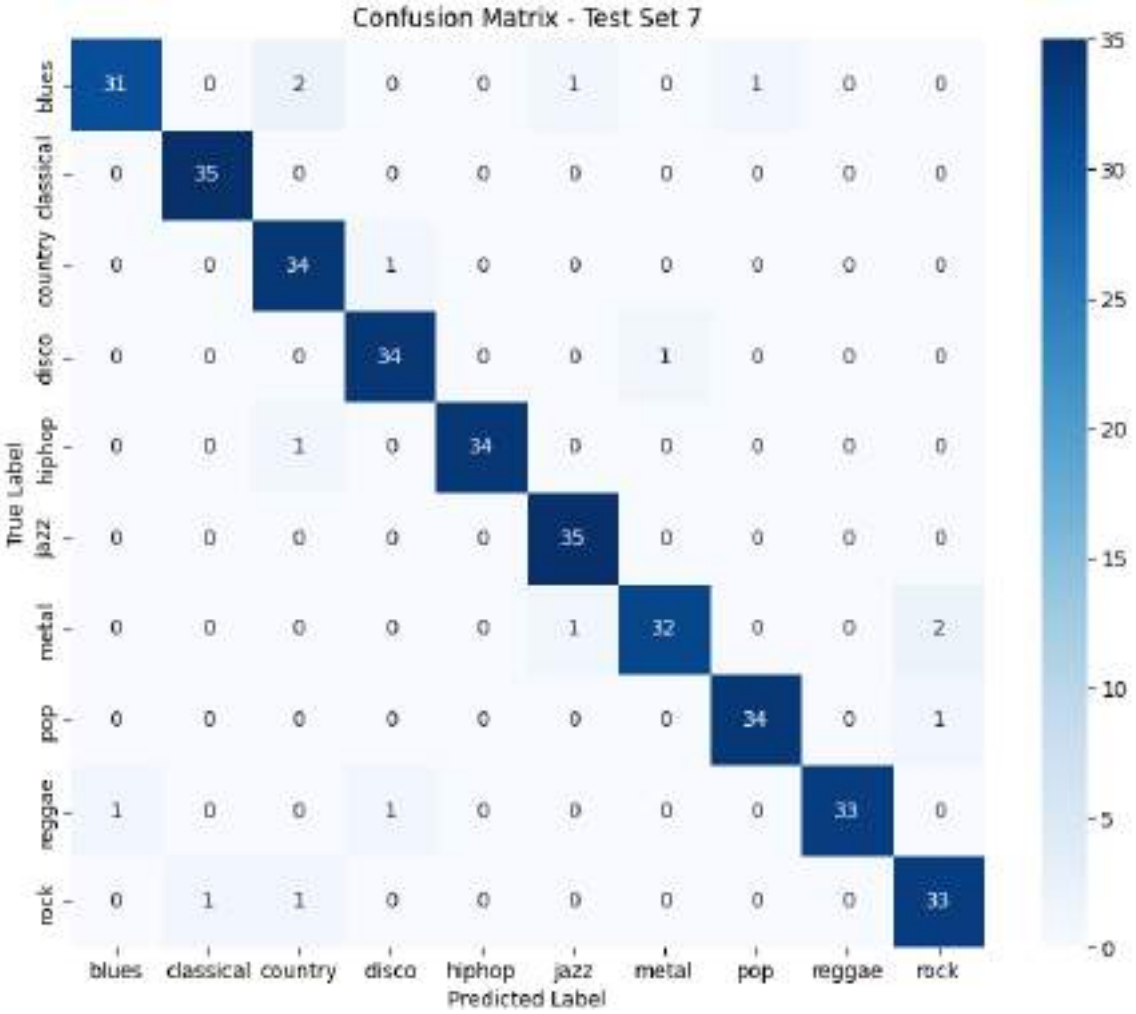
4. *Confusion Matrix* Dataset Primer pada Menit 1:30-2:00



5. *Confusion Matrix* Dataset Primer pada Menit 2:00-2:30



6. *Confusion Matrix* Dataset Primer pada Menit 2:30-3:00



7. *Confusion Matrix* Dataset Primer pada Bagian *Reff*

Lampiran 3
Metrik Evaluasi

1. Metrik Evaluasi Dataset Sekunder

Genre	*Accuracy*	*Precision*	*Recall*	*F1-score*	*Testing Time*
blues	0.9499	0.9216	0.9400	0.9307	0.0503
classical		1.0000	0.9800	0.9899	0.0398
country		0.8899	0.9700	0.9282	0.0434
disco		0.9612	0.9900	0.9754	0.0403
hiphop		0.9794	0.9500	0.9645	0.0428
jazz		0.9510	0.9798	0.9652	0.0422
metal		0.9790	0.9300	0.9539	0.0442
pop		0.9495	0.9400	0.9447	0.0443
reggae		0.9596	0.9596	0.9596	0.0365
rock		0.9149	0.8600	0.8866	0.0402

2. Metrik Evaluasi Dataset Primer pada Menit 0:30-1:00

Genre	*Accuracy*	*Precision*	*Recall*	*F1-score*	*Testing Time*
blues	0.9143	0.9688	0.8857	0.9254	0.0209
classical		0.9444	0.9714	0.9577	0.0136
country		0.7857	0.9429	0.8572	0.0159
disco		0.8537	1.0000	0.9211	0.0130
hiphop		0.9697	0.9143	0.9412	0.0105
jazz		0.8974	1.0000	0.9459	0.0106
metal		0.8857	0.8857	0.8857	0.0138
pop		1.0000	0.8286	0.9063	0.0163
reggae		0.9459	1.0000	0.9722	0.0131
rock		0.9615	0.7143	0.8197	0.0135

3. Metrik Evaluasi Dataset Primer pada Menit 1:00-1:30

Genre	*Accuracy*	*Precision*	*Recall*	*F1-score*	*Testing Time*
blues	0.9457	0.9167	0.9429	0.9296	0.0203
classical		1.0000	1.0000	1.0000	0.0138
country		0.9697	0.9143	0.9412	0.0141
disco		0.9444	0.9714	0.9577	0.0147
hiphop		0.9444	0.9714	0.9577	0.0147
jazz		0.8537	1.0000	0.9211	0.0142
metal		0.9444	0.9714	0.9577	0.0140
pop		0.9143	0.9143	0.9143	0.0129
reggae		1.0000	0.9714	0.9855	0.0153
rock		1.0000	0.8000	0.8889	0.0147

4. Metrik Evaluasi Dataset Primer pada Menit 1:30-2:00

Genre	***Accuracy***	***Precision***	***Recall***	***F1-score***	***Testing Time***
blues	0.9229	0.7805	0.9143	0.8686	0.0198
classical		1.0000	1.0000	1.0000	0.0138
country		0.8250	0.9429	0.8800	0.0146
disco		0.8750	1.0000	0.9333	0.0149
hiphop		0.9714	0.9714	0.9714	0.0163
jazz		0.9444	0.9714	0.9577	0.0127
metal		1.0000	0.8286	0.9063	0.0127
pop		1.0000	0.7714	0.8709	0.0123
reggae		0.9697	0.9143	0.9412	0.0163
rock		0.9412	0.9143	0.9276	0.0122

5. Metrik Evaluasi Dataset Primer pada Menit 2:00-2:30

Genre	***Accuracy***	***Precision***	***Recall***	***F1-score***	***Testing Time***
blues	0.9286	0.9444	0.9714	0.9577	0.0212
classical		1.0000	1.0000	1.0000	0.0153
country		0.8919	0.9429	0.9167	0.0144
disco		0.9167	0.9429	0.9296	0.0144
hiphop		0.9722	1.0000	0.9859	0.0148
jazz		0.8611	0.8857	0.8732	0.0131
metal		0.9706	0.9429	0.9565	0.0144
pop		0.8649	0.9143	0.8889	0.0143
reggae		0.9032	0.8000	0.8485	0.0158
rock		0.9688	0.8857	0.9254	0.0107

6. Metrik Evaluasi Dataset Primer pada Menit 2:30-3:00

Genre	***Accuracy***	***Precision***	***Recall***	***F1-score***	***Testing Time***
blues	0.9229	0.9412	0.9143	0.9276	0.0209
classical		0.8140	1.0000	0.8975	0.0143
country		0.8824	0.8571	0.8696	0.0149
disco		0.9722	1.0000	0.9859	0.0146
hiphop		0.9722	1.0000	0.9859	0.0126
jazz		0.8140	1.0000	0.8975	0.0156
metal		0.9706	0.9429	0.9565	0.0145
pop		0.9688	0.8857	0.9254	0.0145
reggae		1.0000	0.9143	0.9552	0.0140
rock		0.9615	0.7143	0.8197	0.0111

7. Metrik Evaluasi Dataset Primer pada Bagian *Reff*

Genre	***Accuracy***	***Precision***	***Recall***	***F1-score***	***Testing Time***
blues		0.9688	0.8857	0.9254	0.0212
classical		0.9722	1.0000	0.9859	0.0196

0.8714

Genre	***Accuracy***	***Precision***	***Recall***	***F1-score***	***Testing Time***
country		0.8947	0.9714	0.9315	0.0151
disco		0.9444	0.9714	0.9577	0.0139
hiphop		1.0000	0.9714	0.9855	0.0124
jazz		0.9459	1.0000	0.9722	0.0152
metal		0.9697	0.9143	0.9412	0.0136
pop		0.9714	0.9714	0.9714	0.0134
reggae		1.0000	0.9429	0.9706	0.0119
rock		0.9167	0.9429	0.9296	0.0111

Lampiran 4
Pengujian Menggunakan Dataset Primer

1. Klasifikasi Genre Musik Dataset Primer pada Menit 0:30-1:00

Genre Aktual	**Lagu**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
blues	John Mayer Gravity	0.93588	blues	0.0058
	Bernard A Help Me Through The Day	0.99928	blues	0.0066
	Chris Bell Cold-Hearted Woman	0.99962	blues	0.0024
	Adam Holt The End	0.87473	blues	0.0032
	Kenny Wayne S Blue on Black	0.99895	blues	0.0029
classical	Mozart Rondo Alla Turca	0.99938	classical	0.0030
	Bach Tocatta and Fugue in D Minor	0.99796	classical	0.0031
	Chopin Nocturne op. No. 2	0.99972	classical	0.0015
	Franz Liszt Liebestraum	0.99961	classical	0.0024
	Mozart Eine Kleine Nachtmusik	0.99975	classical	0.0037
country	John D Take Me Home, Country Roads	0.99866	country	0.0039
	George Strait The Book	0.98266	country	0.0038
	Luke Combs She Got the Best of Me	0.98905	country	0.0021
	Dan & Shay Speechless	0.91184	country	0.0033
	Kenny Rogers The Gambler	0.90509	country	0.0029
disco	Boney M Daddy Cool	0.94586	disco	0.0029
	Bee Gees Stayin' Alive	0.99890	disco	0.0032
	Michael J Don't Stop 'Til U Get Enough	0.99982	disco	0.0020
	Village People YMCA	0.97962	disco	0.0027
	Bee Gees Night Fever	0.99950	disco	0.0021
hiphop	Black Eyed Peas Where Is The Love	0.99579	hiphop	0.0058
	2Pac California Love	0.99977	hiphop	0.0066
	Eminem My Name Is	0.99553	hiphop	0.0024
	Grandmaster Flash The Message	0.97605	hiphop	0.0032
	Kendrick Lamar DNA.	0.97868	hiphop	0.0029
jazz	Frank Sinatra My Way	0.99857	jazz	0.0030
	Nonaria Sebusur Pelangi	0.99946	jazz	0.0031
	Andien Pulang	0.99919	jazz	0.0015
	Jessy J Tequilla Moon	0.99952	jazz	0.0024
	Norah Jones Don't Know Why	0.99786	jazz	0.0037
metal	Metallica Master of Puppets	0.99849	metal	0.0058
	Slipknot Nero Forte	0.99958	metal	0.0066
	Deftones My Own Summer	0.99952	metal	0.0024
	Lamb of God Laid to Rest	0.99956	metal	0.0032
	System Of A Down Toxicity	0.85818	disco	0.0029
pop	Vierra Seandainya	0.99790	pop	0.0030
	Nidji Hapus Aku	0.99901	pop	0.0031
	naFF Akhirnya Ku Menemukanmu	0.99649	pop	0.0015
	Anji DIA	0.98928	pop	0.0024

Genre Aktual	Lagu	*Confidence Level*	Hasil Prediksi	Waktu Testing (detik)
	Mawar de Jongh Lebih dari Egoku	0.99965	pop	0.0037
reggae	MAGIC! No Way No	0.99936	reggae	0.0058
	UB40 Red Red Wine	0.99976	reggae	0.0066
	Bob M & The Wailers Three Little Birds	0.99969	reggae	0.0024
	Jimmy Cliff Many Rivers to Cross	0.99987	reggae	0.0032
	The Clash The Guns of Brixton	0.99511	reggae	0.0029
rock	The Struts It Could Have Been Me	0.94292	rock	0.0030
	The Struts Kiss This	0.99752	rock	0.0031
	Barasuara Terbuang Dalam Waktu	0.74845	country	0.0015
	Europe The Final Countdown	0.99280	rock	0.0024
	Twenty One Pilots Jumpsuit	0.99146	rock	0.0037

2. Klasifikasi Genre Musik Dataset Primer pada Menit 1:00-1:30

Genre Aktual	Lagu	*Confidence Level*	Hasil Prediksi	Waktu Testing (detik)
blues	John Mayer Gravity	0.96617	blues	0.0056
	Bernard A Help Me Through The Day	0.98302	blues	0.0064
	Chris Bell Cold-Hearted Woman	0.99758	blues	0.0024
	Adam Holt The End	0.99045	blues	0.0031
	Kenny Wayne S Blue on Black	0.99389	blues	0.0028
classical	Mozart Rondo Alla Turca	0.99964	classical	0.0028
	Bach Tocatta and Fugue in D Minor	0.99978	classical	0.0032
	Chopin Nocturne op. No. 2	0.99950	classical	0.0019
	Franz Liszt Liebestraum	0.99901	classical	0.0031
	Mozart Eine Kleine Nachtmusik	0.99948	classical	0.0029
country	John D Take Me Home, Country Roads	0.99949	country	0.0029
	George Strait The Book	0.96050	country	0.0031
	Luke Combs She Got the Best of Me	0.98186	country	0.0019
	Dan & Shay Speechless	0.96169	country	0.0031
	Kenny Rogers The Gambler	0.98818	country	0.0030
disco	Boney M Daddy Cool	0.99719	disco	0.0030
	Bee Gees Stayin' Alive	0.99981	disco	0.0031
	Michael J Don't Stop 'Til U Get Enough	0.99983	disco	0.0019
	Village People YMCA	0.99892	disco	0.0034
	Bee Gees Night Fever	0.99966	disco	0.0032
hiphop	Black Eyed Peas Where Is The Love	0.99483	hiphop	0.0058
	2Pac California Love	0.99982	hiphop	0.0066
	Eminem My Name Is	0.99929	hiphop	0.0024
	Grandmaster Flash The Message	0.99952	hiphop	0.0032
	Kendrick Lamar DNA.	0.99918	hiphop	0.0029
jazz	Frank Sinatra My Way	0.99866	jazz	0.0030
	Nonaria Sebusur Pelangi	0.99961	jazz	0.0031

Genre Aktual	**Lagu**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
	Andien Pulang	0.99893	jazz	0.0015
	Jessy J Tequilla Moon	0.99934	jazz	0.0024
	Norah Jones Don't Know Why	0.99868	jazz	0.0037
metal	Metallica Master of Puppets	0.99911	metal	0.0058
	Slipknot Nero Forte	0.99940	metal	0.0066
	Deftones My Own Summer	0.99914	metal	0.0024
	Lamb of God Laid to Rest	0.99962	metal	0.0032
	System Of A Down Toxicity	0.99903	metal	0.0029
pop	Vierra Seandainya	0.99886	pop	0.0030
	Nidji Hapus Aku	0.99598	pop	0.0031
	naFF Akhirnya Ku Menemukanmu	0.99939	pop	0.0015
	Anji DIA	0.97552	pop	0.0024
	Mawar de Jongh Lebih dari Egoku	0.99967	pop	0.0037
reggae	MAGIC! No Way No	0.95063	reggae	0.0058
	UB40 Red Red Wine	0.99843	reggae	0.0066
	Bob M & The Wailers Three Little Birds	0.99960	reggae	0.0024
	Jimmy Cliff Many Rivers to Cross	0.98861	reggae	0.0032
	The Clash The Guns of Brixton	0.99960	reggae	0.0029
rock	The Struts It Could Have Been Me	0.97217	rock	0.0030
	The Struts Kiss This	0.99987	rock	0.0031
	Barasuara Terbuang Dalam Waktu	0.99298	rock	0.0015
	Europe The Final Countdown	0.98107	rock	0.0024
	Twenty One Pilots Jumpsuit	0.88781	rock	0.0037

3. Klasifikasi Genre Musik Dataset Primer pada Menit 1:30-2:00

Genre Aktual	**Lagu**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
blues	John Mayer Gravity	0.99971	blues	0.0056
	Bernard A Help Me Through The Day	0.92593	blues	0.0064
	Chris Bell Cold-Hearted Woman	0.99954	blues	0.0023
	Adam Holt The End	0.95257	blues	0.0029
	Kenny Wayne S Blue on Black	0.99965	blues	0.0026
classical	Mozart Rondo Alla Turca	0.99927	classical	0.0027
	Bach Tocatta and Fugue in D Minor	0.99982	classical	0.0031
	Chopin Nocturne op. No. 2	0.99960	classical	0.0019
	Franz Liszt Liebestraum	0.99952	classical	0.0031
	Mozart Eine Kleine Nachtmusik	0.99947	classical	0.0031
country	John D Take Me Home, Country Roads	0.99961	country	0.0032
	George Strait The Book	0.99603	country	0.0033
	Luke Combs She Got the Best of Me	0.99927	country	0.0020
	Dan & Shay Speechless	0.99389	country	0.0032
	Kenny Rogers The Gambler	0.99925	country	0.0029

Genre Aktual	**Lagu**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
disco	Boney M Daddy Cool	0.87155	disco	0.0029
	Bee Gees Stayin' Alive	0.99751	disco	0.0029
	Michael J Don't Stop 'Til U Get Enough	0.99987	disco	0.0018
	Village People YMCA	0.99852	disco	0.0037
	Bee Gees Night Fever	0.99977	disco	0.0036
hiphop	Black Eyed Peas Where Is The Love	0.99445	hiphop	0.0058
	2Pac California Love	0.99895	hiphop	0.0066
	Eminem My Name Is	0.94963	hiphop	0.0024
	Grandmaster Flash The Message	0.99960	hiphop	0.0032
	Kendrick Lamar DNA.	0.99516	hiphop	0.0029
jazz	Frank Sinatra My Way	0.99939	jazz	0.0030
	Nonaria Sebusur Pelangi	0.99927	jazz	0.0031
	Andien Pulang	0.99959	jazz	0.0015
	Jessy J Tequilla Moon	0.99960	jazz	0.0024
	Norah Jones Don't Know Why	0.98013	jazz	0.0037
metal	Metallica Master of Puppets	0.97680	metal	0.0058
	Slipknot Nero Forte	0.99951	metal	0.0066
	Deftones My Own Summer	0.91636	metal	0.0024
	Lamb of God Laid to Rest	0.99960	metal	0.0032
	System Of A Down Toxicity	0.92357	disco	0.0029
pop	Vierra Seandainya	0.99931	pop	0.0030
	Nidji Hapus Aku	0.99359	pop	0.0031
	naFF Akhirnya Ku Menemukanmu	0.93157	pop	0.0015
	Anji DIA	0.94555	pop	0.0024
	Mawar de Jongh Lebih dari Egoku	0.99960	pop	0.0037
reggae	MAGIC! No Way No	0.99928	reggae	0.0058
	UB40 Red Red Wine	0.99964	reggae	0.0066
	Bob M & The Wailers Three Little Birds	0.99950	reggae	0.0024
	Jimmy Cliff Many Rivers to Cross	0.90864	reggae	0.0032
	The Clash The Guns of Brixton	0.98636	reggae	0.0029
rock	The Struts It Could Have Been Me	0.96797	rock	0.0030
	The Struts Kiss This	0.99902	rock	0.0031
	Barasuara Terbuang Dalam Waktu	0.93821	rock	0.0015
	Europe The Final Countdown	0.98520	rock	0.0024
	Twenty One Pilots Jumpsuit	0.98853	rock	0.0037

4. Klasifikasi Genre Musik Dataset Primer pada Menit 2:0-2:30

Genre Aktual	**Lagu**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
blues	John Mayer Gravity	0.99587	blues	0.0061
	Bernard A Help Me Through The Day	0.98263	blues	0.0070
	Chris Bell Cold-Hearted Woman	0.99936	blues	0.0024

Genre Aktual	**Lagu**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
	Adam Holt The End	0.99864	blues	0.0030
	Kenny Wayne S Blue on Black	0.99928	blues	0.0028
classical	Mozart Rondo Alla Turca	0.99946	classical	0.0030
	Bach Tocatta and Fugue in D Minor	0.99978	classical	0.0035
	Chopin Nocturne op. No. 2	0.99961	classical	0.0022
	Franz Liszt Liebestraum	0.99972	classical	0.0036
	Mozart Eine Kleine Nachtmusik	0.99923	classical	0.0030
country	John D Take Me Home, Country Roads	0.99226	country	0.0030
	George Strait The Book	0.99925	country	0.0033
	Luke Combs She Got the Best of Me	0.87356	country	0.0020
	Dan & Shay Speechless	0.98369	country	0.0032
	Kenny Rogers The Gambler	0.99352	country	0.0029
disco	Boney M Daddy Cool	0.99689	disco	0.0029
	Bee Gees Stayin' Alive	0.99964	disco	0.0032
	Michael J Don't Stop 'Til U Get Enough	0.99981	disco	0.0020
	Village People YMCA	0.99986	disco	0.0033
	Bee Gees Night Fever	0.99956	disco	0.0030
hiphop	Black Eyed Peas Where Is The Love	0.96661	hiphop	0.0051
	2Pac California Love	0.99970	hiphop	0.0066
	Eminem My Name Is	0.99942	hiphop	0.0024
	Grandmaster Flash The Message	0.99955	hiphop	0.0032
	Kendrick Lamar DNA.	0.99006	hiphop	0.0029
jazz	Frank Sinatra My Way	0.99976	jazz	0.0030
	Nonaria Sebusur Pelangi	0.99946	jazz	0.0031
	Andien Pulang	0.99845	jazz	0.0015
	Jessy J Tequilla Moon	0.99960	jazz	0.0024
	Norah Jones Don't Know Why	0.88459	jazz	0.0037
metal	Metallica Master of Puppets	0.97751	metal	0.0058
	Slipknot Nero Forte	0.99961	metal	0.0066
	Deftones My Own Summer	0.93365	metal	0.0024
	Lamb of God Laid to Rest	0.99433	metal	0.0032
	System Of A Down Toxicity	0.99885	metal	0.0029
pop	Vierra Seandainya	0.97471	pop	0.0030
	Nidji Hapus Aku	0.99950	pop	0.0031
	naFF Akhirnya Ku Menemukanmu	0.94738	pop	0.0015
	Anji DIA	0.98541	pop	0.0024
	Mawar de Jongh Lebih dari Egoku	0.99964	pop	0.0037
reggae	MAGIC! No Way No	0.94426	reggae	0.0058
	UB40 Red Red Wine	0.99704	reggae	0.0066
	Bob M & The Wailers Three Little Birds	0.99941	reggae	0.0024
	Jimmy Cliff Many Rivers to Cross	0.99594	reggae	0.0032
	The Clash The Guns of Brixton	0.99729	reggae	0.0029
rock	The Struts It Could Have Been Me	0.99427	rock	0.0030
	The Struts Kiss This	0.99987	rock	0.0031

Genre Aktual	Lagu	*Confidence Level*	Hasil Prediksi	Waktu Testing (detik)
	Barasuara Terbuang Dalam Waktu	0.56428	rock	0.0015
	Europe The Final Countdown	0.98144	rock	0.0024
	Twenty One Pilots Jumpsuit	0.92646	rock	0.0037

5. Klasifikasi Genre Musik Dataset Primer pada Menit 2:30-3:00

Genre Aktual	Lagu	*Confidence Level*	Hasil Prediksi	Waktu Testing (detik)
blues	John Mayer Gravity	0.92307	blues	0.0057
	Bernard A Help Me Through The Day	0.99957	blues	0.0066
	Chris Bell Cold-Hearted Woman	0.99955	blues	0.0025
	Adam Holt The End	0.99903	blues	0.0033
	Kenny Wayne S Blue on Black	0.99541	blues	0.0029
classical	Mozart Rondo Alla Turca	0.99922	classical	0.0029
	Bach Tocatta and Fugue in D Minor	0.99984	classical	0.0033
	Chopin Nocturne op. No. 2	0.99951	classical	0.0019
	Franz Liszt Liebestraum	0.99864	classical	0.0031
	Mozart Eine Kleine Nachtmusik	0.99952	classical	0.0030
country	John D Take Me Home, Country Roads	0.92975	country	0.0031
	George Strait The Book	0.99973	country	0.0034
	Luke Combs She Got the Best of Me	0.94472	country	0.0020
	Dan & Shay Speechless	0.99924	country	0.0033
	Kenny Rogers The Gambler	0.99833	country	0.0030
disco	Boney M Daddy Cool	0.99412	disco	0.0030
	Bee Gees Stayin' Alive	0.99899	disco	0.0036
	Michael J Don't Stop 'Til U Get Enough	0.98424	disco	0.0022
	Village People YMCA	0.99975	disco	0.0032
	Bee Gees Night Fever	0.99769	disco	0.0026
hiphop	Black Eyed Peas Where Is The Love	0.99828	hiphop	0.0058
	2Pac California Love	0.99982	hiphop	0.0066
	Eminem My Name Is	0.99872	hiphop	0.0024
	Grandmaster Flash The Message	0.99956	hiphop	0.0032
	Kendrick Lamar DNA.	0.99960	hiphop	0.0029
jazz	Frank Sinatra My Way	0.93146	jazz	0.0030
	Nonaria Sebusur Pelangi	0.99917	jazz	0.0031
	Andien Pulang	0.93156	jazz	0.0015
	Jessy J Tequilla Moon	0.92441	jazz	0.0024
	Norah Jones Don't Know Why	0.99922	jazz	0.0037
metal	Metallica Master of Puppets	0.99851	metal	0.0058
	Slipknot Nero Forte	0.99964	metal	0.0066
	Deftones My Own Summer	0.99954	metal	0.0024
	Lamb of God Laid to Rest	0.99966	metal	0.0032
	System Of A Down Toxicity	0.99814	metal	0.0029

Genre Aktual	Lagu	*Confidence Level*	Hasil Prediksi	Waktu Testing (detik)
pop	Vierra Seandainya	0.97986	pop	0.0030
	Nidji Hapus Aku	0.97130	pop	0.0031
	naFF Akhirnya Ku Menemukanmu	0.94640	pop	0.0015
	Anji DIA	0.93772	pop	0.0024
	Mawar de Jongh Lebih dari Egoku	0.94886	pop	0.0037
reggae	MAGIC! No Way No	0.91985	reggae	0.0058
	UB40 Red Red Wine	0.98250	reggae	0.0066
	Bob M & The Wailers Three Little Birds	0.99769	reggae	0.0024
	Jimmy Cliff Many Rivers to Cross	0.96081	reggae	0.0032
	The Clash The Guns of Brixton	0.99821	reggae	0.0029
rock	The Struts It Could Have Been Me	0.99980	rock	0.0030
	The Struts Kiss This	0.93655	rock	0.0031
	Barasuara Terbuang Dalam Waktu	0.99940	rock	0.0015
	Europe The Final Countdown	0.99950	rock	0.0024
	Twenty One Pilots Jumpsuit	0.80379	jazz	0.0037

6. Klasifikasi Genre Musik Dataset Primer pada Bagian *Reff*

Genre Aktual	Lagu	*Confidence Level*	Hasil Prediksi	Waktu Testing (detik)
blues	John Mayer Gravity	0.99896	blues	0.0056
	Bernard A Help Me Through The Day	0.99880	blues	0.0064
	Chris Bell Cold-Hearted Woman	0.99589	blues	0.0023
	Adam Holt The End	0.93903	blues	0.0031
	Kenny Wayne S Blue on Black	0.99916	blues	0.0037
classical	Mozart Rondo Alla Turca	0.99942	classical	0.0051
	Bach Tocatta and Fugue in D Minor	0.99948	classical	0.0053
	Chopin Nocturne op. No. 2	0.99968	classical	0.0023
	Franz Liszt Liebestraum	0.99968	classical	0.0037
	Mozart Eine Kleine Nachtmusik	0.99967	classical	0.0032
country	John D Take Me Home, Country Roads	0.99972	country	0.0032
	George Strait The Book	0.99966	country	0.0034
	Luke Combs She Got the Best of Me	0.96791	country	0.0020
	Dan & Shay Speechless	0.99831	country	0.0033
	Kenny Rogers The Gambler	0.94212	country	0.0032
disco	Boney M Daddy Cool	0.98602	disco	0.0032
	Bee Gees Stayin' Alive	0.93737	disco	0.0033
	Michael J Don't Stop 'Til U Get Enough	0.97858	disco	0.0021
	Village People YMCA	0.98595	disco	0.0029
	Bee Gees Night Fever	0.99956	disco	0.0023
hiphop	Black Eyed Peas Where Is The Love	0.99134	hiphop	0.0058
	2Pac California Love	0.99934	hiphop	0.0066
	Eminem My Name Is	0.99946	hiphop	0.0024

Genre Aktual	**Lagu**	***Confidence Level***	**Hasil Prediksi**	**Waktu Testing (detik)**
	Grandmaster Flash The Message	0.99817	hiphop	0.0032
	Kendrick Lamar DNA.	0.99928	hiphop	0.0029
jazz	Frank Sinatra My Way	0.99925	jazz	0.0030
	Nonaria Sebusur Pelangi	0.99956	jazz	0.0031
	Andien Pulang	0.93967	jazz	0.0015
	Jessy J Tequilla Moon	0.99925	jazz	0.0024
	Norah Jones Don't Know Why	0.99191	jazz	0.0037
metal	Metallica Master of Puppets	0.99806	metal	0.0058
	Slipknot Nero Forte	0.99952	metal	0.0066
	Deftones My Own Summer	0.99915	metal	0.0024
	Lamb of God Laid to Rest	0.95399	metal	0.0032
	System Of A Down Toxicity	0.99004	metal	0.0029
pop	Vierra Seandainya	0.98783	pop	0.0030
	Nidji Hapus Aku	0.99950	pop	0.0031
	naFF Akhirnya Ku Menemukanmu	0.99950	pop	0.0015
	Anji DIA	0.97586	pop	0.0024
	Mawar de Jongh Lebih dari Egoku	0.99963	pop	0.0037
reggae	MAGIC! No Way No	0.99643	reggae	0.0058
	UB40 Red Red Wine	0.96008	reggae	0.0066
	Bob M & The Wailers Three Little Birds	0.99973	reggae	0.0024
	Jimmy Cliff Many Rivers to Cross	0.95410	reggae	0.0032
	The Clash The Guns of Brixton	0.95584	reggae	0.0029
rock	The Struts It Could Have Been Me	0.99985	rock	0.0030
	The Struts Kiss This	0.99987	rock	0.0031
	Barasuara Terbuang Dalam Waktu	0.99971	rock	0.0015
	Europe The Final Countdown	0.94558	rock	0.0024
	Twenty One Pilots Jumpsuit	0.89535	rock	0.0037

UCAPAN TERIMA KASIH

Penyelesaian penulisan Tugas Akhir ini tidak lepas dari orang-orang terdekat penulis yang telah mendukung dan memotivasi penulis. Oleh sebab itu, penulis mengucapkan terima kasih kepada:

1. Adik tercinta yaitu Gabriella Adytha Putri yang selalu memberikan kasih sayang dan dukungan selama menempuh perkuliahan penulis di Institut Teknologi Sepuluh Nopember.
2. Sahabat-sahabat terbaik saya di tempat yaitu Maria Eleos T. Pakan, Kezia Patricia Zefanya, Natalie Quinta C., dan Rhachela Essy Christina yang meskipun terpisah jarak dan waktu, selalu hadir memberikan semangat, doa, serta perhatian yang tulus selama proses penyusunan Tugas Akhir ini.
3. Teman-teman Laboratorium Pemrograman dan Komputasi Visual yang telah setia menemani dan menghibur penulis selama proses penyusunan Tugas Akhir ini.
4. Rekan-rekan mahasiswa yang selalu memberikan semangat, dukungan, dan kebersamaan yang menyenangkan selama proses perkuliahan hingga penyusunan Tugas Akhir ini.

Penulis juga mengharapkan kritik dan saran yang membangun dari berbagai pihak untuk penyempurnaan isi Tugas Akhir ini. Akhir kata, semoga Tugas Akhir ini bermanfaat bagi semua pihak yang bersangkutan.

Surabaya, 21 Januari 2026

Angela Adytha Putri

Dipindai dengan CamScanner

BIODATA PENULIS



Penulis bernama Angela Adytha Putri, lahir di Jakarta pada tanggal 18 September 2003. Penulis tinggal di Tangerang Selatan bersama kedua orang tua dan seorang adik perempuan. Sebelum duduk di bangku perkuliahan, penulis telah menempuh pendidikan formal, yaitu di SD Katolik Stella Maris BSD (2009 – 2015), SMP Katolik Stella Maris BSD (2015 – 2018), dan SMA Negeri 3 Kota Tangerang Selatan (2018 – 2021). Setelah lulus SMA, penulis melanjutkan pendidikan ke jenjang S1 di Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember Surabaya melalui jalur mandiri. Selama menjadi mahasiswa, penulis aktif mengikuti kegiatan di dalam maupun di luar lingkungan ITS. Penulis aktif dalam beberapa kepanitiaan seperti kepanitiaan Olimpiade Matematika Institut Teknologi Sepuluh Nopember (OMITS) dan Aksi Nirwasita. Selain itu, penulis juga aktif sebagai anggota *staff* UKM Bridge ITS dan aktif mengikuti pelatihan-pelatihan yang diselenggarakan oleh pihak luar kampus ITS. Penulis dengan senang hati menerima kritik dan saran yang bersifat membangun demi perbaikan di masa mendatang mengenai Tugas Akhir ini. Penulis dapat dihubungi melalui email angel.adytha@gmail.com untuk keperluan akademik maupun komunikasi terkait penelitian.